不変性テストを用いた強化学習方策の代理説明におけるスプリアス依存の検出

要旨

強化学習で学習したブラックボックス方策（Oracle policy）に手を加えず、構造制約付きの蒸留モデル（Surrogate model）を事後的に配置する**分離（decoupling）により、性能を低下させることなく任意の解釈可能モデルの説明品質を事後的に診断する枠組みを提案する。本研究の中心的主張は三点に集約される。第一に、Surrogate model の行動一致率（AA）が高いことは説明候補となるための必要条件**に過ぎない。第二に、分布シフト下での不変性を追加の評価軸として用いることで、「高 AA だが誤っている」状態を識別できる。第三に、再現性と不変性の二軸評価は Surrogate model の内部構造を問わないため、任意の解釈可能モデルを共通の土台で比較できる。CartPole 拡張環境とスプリアス GridWorld を用いた実験により、スプリアス依存を複製した Surrogate model が訓練分布では高 AA を示しながら分布シフト下で崩壊するケースと、スプリアスのない環境で AA が相対的に保たれるケースを実験的に示す。なお、本枠組みはスプリアス依存を検出するが、その不在を確認する機能は持たない。

1. 序論

説明可能なモデルは性能が低く、高性能なモデルは解釈しにくいというトレードオフは XAI の根本的制約として長く指摘されてきた。決定木や線形モデルは構造が読みやすい一方で強化学習のような逐次意思決定では性能が大きく劣り、LIME[^8] や SHAP[^4] のような事後的説明手法は元のモデルに手を加えないが、元の方策の振る舞いをどれだけ忠実に捉えているかは自明でない（Chen et al., 2022[^1]）。説明を対話的・共同構成的なプロセスとして捉える近年の研究（Mindlin et al., 2025[^2]）は、静的な説明の限界を浮き彫りにしている。先行研究との詳細な関係は Section 2 で整理する。

本研究はこのトレードオフを**分離（decoupling）**によって回避する。強化学習で学習した高性能な方策（Oracle policy）には一切手を加えず、その横に構造制約付きの蒸留モデル（Surrogate model）を事後的に配置する。性能は Oracle policy が担い、説明の構造的な候補は Surrogate model が担う。なお「Surrogate model」という用語は最適化文脈では目的関数を近似するモデルを指すことがあるが、本論文では XRL の慣例（Vasic et al., 2019[^3]; Bastani et al., 2018[^6]）に従い、学習済み方策を事後的に模倣する解釈可能モデルを指す。各用語の厳密な定義は Section 3 で与える。

しかし、Surrogate model が高い AA で Oracle policy を模倣できたとして、その説明を信頼してよいか。方策蒸留の先行研究（Bastani et al., 2018[^6]; Vasic et al., 2019[^3]）は AA の最大化をゴールとしてきたが、高 AA の代理モデルが元の方策と同じスプリアス依存を写し取っている場合を検出する仕組みを持たない。RL では方策の行動選択が次の状態遷移を規定し、一つの誤りが後続の行動列全体を崩壊させうるため、スプリアス依存を忠実に再現した Surrogate model は分布シフト下で壊滅的に失敗する。本研究は、説明可能性を**再現性**（訓練分布上での行動一致）と**分布シフト下での不変性**（シフト後の AA と方策性能の維持）の両面から診断する枠組みを提案する。本研究の貢献は以下の三点にある。

1. 説明可能性と性能のトレードオフを分離によって回避し、Oracle policy の性能を損なわずに任意の Surrogate model の説明品質を事後的に評価する枠組みを提案する。Surrogate model の内部構造を問わないため、決定木・MoET・線形モデルをはじめ将来の解釈可能モデルも共通の評価軸で横断比較できる。
2. 再現性（AA）と不変性（分布シフト下の AA・J_S）を組み合わせた二段階評価方法論を提供し、「高 AA だが誤っている」状態を数値から識別できることを実験的に示す（実験 2 が直接的証拠、実験 3 が対照的証拠）。
3. CartPole とスプリアス GridWorld を用いた実験で、構造制約の強さ・入力分布・依存構造に応じて再現性と不変性がどう変化するかを示し、主実験環境を超えて評価ロジックが適用できるという初期的な証拠を示

す。付録レベルの予備的検証として、LunarLander-v3 および MuJoCo Hopper-v5 への適用（付録4・5）により連続物理系への拡張可能性を示唆するが、連続制御タスクへの本格的な検証は今後の課題とする。

2. 関連研究

2.1 方策蒸留と代理モデル

ブラックボックス方策を解釈可能なモデルで近似する研究は方策蒸留の文脈で進められてきた。Vasic ら（2019）の MoET は、ニューラルネットワーク方策をソフトゲーティング付きの決定木混合モデルに蒸留し、解釈可能性と精度を両立する。Bastani ら（2018）[^6]の決定木蒸留や線形モデルによる近似（Kolter & Ng, 2009[^7]）も同様に、方策の行動を保存しながら構造的な単純さを実現することを目標とする。これらの研究は AA の最大化を達成の証拠とするが、高 AA の代理モデルが元の方策と同じスプリアス依存を写し取っている場合を検出する仕組みを持たない。本研究はこの欠落を不変性の評価で補う。

2.2 事後的説明手法と Faithfulness

LIME（Ribeiro et al., 2016[^8]）と SHAP（Lundberg & Lee, 2017[^4]）は個々の予測に対する局所的な特徴寄与を算出する手法として広く用いられる。これらの手法は「方策が現在どの特徴に依存しているか」を示すが、その依存が分布変化に対して有効かどうかを問わない。Faithfulness に関する研究（Alvarez-Melis & Jaakkola, 2018[^9]; Samek et al., 2017[^10]）は訓練分布内での説明の忠実性を評価しようとするが、訓練分布外での忠実性維持は問われない。本研究の不変性の概念は、分布外での faithfulness の維持を直接評価する点でこれらを補完する。Comprehensiveness faithfulness（DeYoung et al., 2020[^20]）を同一実験に適用した比較実験（付録6）では、この相補関係を定量的に実証する。

2.3 不変性と分布シフトの解釈可能性

IRM（Arjovsky et al., 2019[^5]）は複数環境で一貫して有効な特徴表現を学習することでスプリアス相関への依存を回避しようとする学習戦略である。概念ボトルネックモデル（Koh et al., 2020[^11]）は人間が定義した概念を中間表現として用い、説明の因果的な意味を高める。事後的概念ボトルネックモデル（Yuksekgonul et al., 2023[^13]）はこれを再学習なしに任意の学習済みモデルへ適用可能にし、事後評価という立場を共有する点で本研究と方向性が近い。これらが解釈可能な表現を付与することを目的とするのに対し、本研究は学習済み方策について依存がスプリアスかどうかを事後的に測定する枠組みを提供する点で異なる。

なお、分布シフト下でのモデル評価という操作は OOD ロバスト性研究（Gulrajani & Lopez-Paz, 2021[^15]; Sagawa et al., 2020[^16]）でも用いられるが、目的が根本的に異なる。OOD ロバスト性研究はシフト後の性能向上を目指す訓練戦略を問う。本枠組みは訓練戦略を変えるものではなく、分布シフトを既存の蒸留済み Surrogate model の説明品質を診断するための事後的ツールとして用いる。目的はロバスト性の実現ではなく、任意の解釈可能モデルに対して共通の評価軸を提供する評価方法論の確立にある。

2.4 RL における説明可能性

強化学習の文脈では、注意機構の可視化（Greydanus et al., 2018[^12]）などの手法が提案されてきた。Puiutta & Veith（2020）[^17]は RL の説明可能性研究を包括的にサーベイし、説明の対象と形式の多様性を整理している。本研究はこれらの手法と直接競合するものではなく、「生成した説明が方策の行動を本当に捉えているか」という横断的な問いに答える評価軸として位置づけられる。Mindlin ら（2025[^2]）が指摘する「対話的・共同構成的な説明」の文脈では、人間との対話の前段として、説明候補が分布変化に対して有効かを自動的に評価しておくことが、よりよい対話の土台を与えると考えられる。本研究の枠組みはその前段評価として機能しうる。

3. 背景と定義

3.1 方策

状態空間 $\mathcal{S}$、行動空間 A に対し、確率的方策を $\pi_O(a \mid s)$ と表す。π_O を **Oracle policy** と呼び、強化学習で学習されたブラックボックス方策で、内部表現の意味付けを与えない。

3.2 構造制約付きモデル

Surrogate model は π_O を模倣する構造制約付きモデルである。状態 s を制約された中間表現 $z \in Z$ に写像する関数 ϕ と、行動分布を出力する関数 D により、

$$z = \phi(s), \qquad \pi_S(a \mid s) = D(\phi(s))$$

と書ける。Z は低次元・単純・解釈可能な表現空間であり、具体例として線形モデル、深さ制限付き決定木、MoET（Vasic et al., 2019[^3]）が挙げられる。本枠組みは π_S の具体的な実装を問わない。決定木・MoET・線形モデルのいずれを選んでも、あるいは将来登場する新たな解釈可能モデルを採用しても、再現性と不変性という同一の評価軸で比較できる。唯一の要件は、採用するモデルが再現性指標と互換な出力形式を持つことである：離散行動空間では AA のための離散行動出力、連続行動空間では R^2 および ε-agreement のための実数値行動出力が必要となる。本研究では Surrogate model を、方策の振る舞いの保存可能性を測る構造ボトルネックの同定ツールとして位置づける。

3.3 説明可能性の評価枠組み

本研究では Surrogate model による説明の質を二段階で評価する。

第一段階：再現性の確認。 Surrogate model が π_O の行動を訓練分布上で十分に再現できなければ、そのモデルは方策の近似としてそもそも成立しない。再現性の指標は行動空間の種類に応じて定義する。離散行動空間では行動一致率（AA）を用いる：$\mathrm{AA}(D) = \mathbb{E}_{s \sim D}[\mathbf{1}[\pi_O(s) = \pi_S(s)]]$。連続行動空間では、離散的な一致という概念が直接適用できないため、AA を決定係数（R^2）として再定義する（連続出力の誤差を捉える ε-agreement を補助指標として併用する場合もある）。いずれの指標が高いことも、意味のある説明候補となるための**必要条件**である。実証的な目安として、AA > 0.9（離散）または $R^2 > 0.9$（連続）を高再現性の基準とする。ただし、極端な物理パラメータシフトではこれらの指標が低下する場合があり、この閾値はすべての条件で普遍的に達成されることを意味しない。

第二段階：不変性の検査。 高 AA を達成した Surrogate model であっても、スプリアス依存を含む方策から蒸留された場合、その依存構造ごと写し取り、訓練分布では高 AA を示しながら分布シフト下で崩壊する。分布シフト $D_{\text{train}} \to D_{\text{shift}}$ に対し、$\left(\mathrm{AA}(D_{\text{shift}}),\, ;\, J_S(D_{\text{shift}})\right)$ の組を不変性の評価指標として報告する。

不変性の診断は以下の判定基準に基づく。スプリアス依存の疑いが強い場合とは、$\mathrm{AA}(D_{\text{shift}}) > \theta_{\text{AA}}$ かつ $J_S(D_{\text{shift}}) < \alpha \times J_S(D_{\text{train}})$ が成立する状態をいう。すなわち、Surrogate model が Oracle policy の行動を高い一致率で再現し続けているにもかかわらず、方策性能が大幅に劣化している状態であり、両者がともにスプリアス特徴に依存していることを示唆する。逆に、スプリアス依存が認められない場合とは、$\mathrm{AA}(D_{\text{shift}})$ が低下しても $J_S(D_{\text{shift}})$ が壊滅的な崩壊を示さない状態をいう。本論文では $\theta_{\text{AA}} = 0.9$、$\alpha = 0.8$ を用いた。これらの閾値は本実験環境における実験的目安であり、環境やタスクに応じた調整が必要である。

不変性が高いことは依存の**因果的正当性**を保証しない。検証した分布シフトの範囲で依存が有効に機能していることの証拠に留まる。この評価枠組みは「高 AA を達成した Surrogate model がスプリアス依存を写し取っているかどうか」を検出する実験的な診断ツールとして機能する。なお、ここでの「不変性」は分布シフト下での AA・J_S の維持を意味し、不変特徴表現の学習を目指す IRM（Arjovsky et al., 2019[^5]）の不変性とは異なる概念である。

4. 提案枠組み

4.1 学習手順

二段階学習を採用する。まず DQN（Mnih et al., 2015[^14]）で π_O を学習する。次に π_O を固定し、そのロールアウトから収集した (s, a) ペアを教師信号として Surrogate model を行動複製（behavioral cloning; Bastani et al.,

2018[^6]）で蒸留する。複数目的の同時最適化を避けることで、Surrogate model の性能を純粋な再現能力として解釈しやすくする。蒸留データと評価データは独立したシードで収集し、蒸留の記憶ではなく再現の汎化を測る。

4.2 Surrogate Model の候補

構造制約の強さを比較するため、線形モデル（ロジスティック回帰）、深さ制限付き単一決定木、MoET の三種を候補として位置づける。本研究では MoET を主に用い、専門家数 K と深さ d のグリッドサーチで制約の強さを連続的に調整することで再現性の構造的上限を観察する。加えて実験4・5で三種を同一条件下で定量比較し、構造の種類が AA の分布依存性に与える影響を調べる（詳細は付録1・2参照）。

4.3 評価指標

- **Action Agreement（AA）**: $\mathrm{AA}(D) = \mathbb{E}_{s\sim D}[\mathbf{1}[\pi_O(s) = \pi_S(s)]]$。再現性の指標。
- **方策性能（J_S）**: $J_S(D) = \mathbb{E}_{s_0 \sim D,; \tau \sim \pi_S}!\left[\sum_{t=0}^{T} r_t\right]$。不変性評価の指標。

5. 実験

5.1 実験の目的と主張との対応

以下の六点を実証するために実験を設計した。各実験が本研究のどの主張の証拠となるかを明示する。

1. **構造制約の強度が再現性に構造的な上限を課すこと**（実験 1：基準実験として、構造制約と AA の関係を確認する）。
2. **スプリアス環境で「再現性高・不変性低」の状態を検出できること**（実験 2：中心的主張の直接的証拠）。
3. **スプリアスのない環境で相対的に不変性が高い状態を観察できること**（実験 3：実験 2 との対照的証拠）。
4. **構造の種類が分布シフト下での再現性に影響すること**（実験 4・5：補強的証拠。実験 6：モデル構造差がデータ量でなく構造に由来することの確認）。
5. **連続力学系・複雑環境への拡張可能性を検証すること**（実験 7・8：LunarLander-v3 および MuJoCo Hopper-v5 への適用と評価軸の妥当性確認）。
6. **訓練分布内の忠実性評価（Comprehensiveness faithfulness）では検出できないスプリアス依存を本枠組みが補完的に診断できること**（実験 9：付録6参照）。

各条件は乱数シード10本（42, 123, 456, 789, 1011, 1314, 1617, 1920, 2223, 2526）で実行し、平均±標準偏差を報告する。蒸留データと評価データは独立したシードで収集する。分布シフトの種別（物理パラメータ変更 vs. スプリアス特徴の反転）は、検出すべき現象の性質に基づいて選択した。分布シフトの選択基準の形式化は今後の課題である。

5.2 実験1：CartPole ノイズ拡張

CartPole-v1[^18]（Brockman et al., 2016）の状態（4次元）に独立なガウスノイズを $N \in 0, 4, 8, 16$ 次元追加した拡張状態で DQN[^14] を学習（200,000 ステップ、EvalCallback によるベストモデル保存）する。EvalCallback は 5,000 ステップごとにモデルを評価し、最良性能のモデルを保存することで DQN 学習後期の性能崩壊を防ぐ。Surrogate model には MoET（$K \in 2, 3, 4$, $d \in 1, 2, 3, 4, 5$ の全組み合わせ）を用いる。スプリアス依存を扱わない基準実験として、構造制約による再現性の構造的上限を観察する。

DQN はシード間で J の分散が大きく、一部のシードでは EvalCallback 後も基準値（$J \geq 450$）に達しない場合がある（10シード中 2 シード程度）。本研究は学習済み oracle が与えられた条件で surrogate の再現性と不変性を評価する枠組みであり、oracle の学習成否そのものは評価の前提条件であって評価対象外とする。シード間での J の分散は oracle の性能指標として Table 2 等で報告する。

5.3 実験2：Spurious GridWorld

5×5 グリッドに配置したエージェントの位置 (x, y) とスプリアス変数 c を状態とし、ゴール位置を直接観測しない GridWorld 環境を設計する。状態空間は 3 次元（$x, y \in [0, 1]$ に正規化、$c \in 0, 1$）、行動空間は 4 方向の離散行動（上下左右）である。報酬はゴール到達時 $+1.0$、各ステップ -0.01 のペナルティとし、エピソード上限は 100 ステップである（$J = -1.000$ はゴール未到達で全ステップを消費した場合の累積ペナルティに対応する）。ゴールは $(0, 0)$ と $(4, 4)$ の 2 箇所のいずれかにエピソードごとランダムに配置される。c はスプリアスノイズ確率 $p \in 0.0, 0.2, 0.5$ で制御される：確率 $1 - p$ でゴールの方向を正しく示し、確率 p でランダムな値をとる。$p = 0$ の場合 c は決定論的にゴールを指し、スプリアス相関が最大になる意図的な強設定である。$p = 0.2, 0.5$ は c の信頼性が部分的に低下する条件であり、実世界のスプリアス相関の強さに幅を持たせる目的で設定した。方策はいずれの p 条件でも c への依存を学習するため、分布シフトとして c を操作すると性能が変化する。評価条件は訓練分布（train）、c をランダム化した条件（random_c）、c を反転した条件（reversed_c）の3種類である（200,000 ステップ学習）。全 p 条件で 10 シード全てが収束し（$p = 0.0$ で $J_{\text{oracle}} \approx 0.97$）、除外シードはない。

5.4 実験3：CartPole 物理パラメータシフト

スプリアス特徴を含まない CartPole（$N = 0$）を対象とし、訓練後に物理パラメータを変えることで分布シフトを与える。重力 $g \in 9.8, 5.0, 20.0$ とポール半長 $\ell \in 0.5, 0.25, 1.0$ を独立に変化させた5条件（train, gravity_lo, gravity_hi, pole_short, pole_long）で評価する。Oracle policy は実験1の $N = 0$ 学習済みモデルを再利用し、Surrogate model には最良設定の MoET（$K = 4, d = 5$）を用いる。pole_long（$\ell = 1.0$）は訓練時の2倍のポール長であり、Oracle policy 自体が OOD で機能しなくなる可能性がある極端な条件として扱う。

5.5 追加実験（実験4〜9）

実験 1--3 で確立した評価枠組みの汎用性を補強的に検証する実験として、実験 4〜9 を実施した。各実験の詳細な設定と結果は付録に記載する。

実験4（CartPole モデル比較；付録1参照）。 実験1と同じ CartPole ノイズ拡張環境（$N \in 0, 4, 8, 16$）で、MoET（$K = 4, d = 5$）、単一決定木（$d = 5$）、ロジスティック回帰の三種を比較し、構造の種類が AA に与える影響を調べる。10シード、蒸留 10,000 サンプル。$N = 0$ では MoET が最も高い AA（0.915）を示し、Linear（0.842）との差は統計的に有意であった（$p_{\text{adj}} < 0.001$）。

実験5（GridWorld モデル比較；付録2参照）。 実験2と同じ Spurious GridWorld（$p \in 0.0, 0.2, 0.5$、評価条件 train / random_c / reversed_c）で同三種を比較する。MoET と Tree はほぼ同等の AA を示し、Linear は全条件で低い傾向がある。$p = 0.5$ の reversed_c 条件では MoET（0.940）と Linear（0.742）の差が最も顕著となった。

実験6（蒸留データ量の感度分析；付録3参照）。 蒸留サンプル数 $n \in 1\text{k}, 5\text{k}, 10\text{k}, 20\text{k}$ を変化させ、CartPole（$N = 0$）と GridWorld（$p \in 0.0, 0.5$）の両環境で MoET・Tree・Linear を比較する。GridWorld $p = 0.5$ の reversed_c 条件では MoET と Linear の AA の差がデータ量を 20 倍にしても解消されず、構造差がデータ量の不足ではなくモデル構造に起因することを確認した。

実験7（LunarLander-v3 への拡張；付録4参照）。 主実験の枠組みが連続物理系に適用可能かを LunarLander-v3 で検証する。PPO oracle（$J_{\text{oracle}} = 260 \pm 13$）に対し、主実験の三種に GBT を追加した四種で蒸留する。重力係数 $g \in -10.0, -3.0, -11.5$ を分布シフト条件とし、AA と J_S で評価する。GBT は AA=0.870±0.021 を達成し、唯一機能的な方策性能を示した（$J_S = 236.8 \pm 18.8$）。10 シード全てが収束した（J_{oracle} の範囲：238〜281；除外シードなし）。

実験8（MuJoCo Hopper-v5 への拡張；付録5参照）。 連続行動空間における評価軸の妥当性を MuJoCo Hopper-v5 で検証する。TD3 oracle（$J_{\text{oracle}} \approx 3500$）に対し、RegTree（$d \in 5, 12$）の構造制約ボトルネック確認を経て、GBT + DAgger による蒸留を適用する。R^2 および ε-agreement を再現性の指標として用い、重力係数と摩擦係数スケールを分布シフト条件とする。Oracle policy は RL Zoo の事前学習済み TD3 モデルであるため oracle の収束判定は不要であり、蒸留 10 シードは全て正常に完了した（除外シードなし）。

実験9（Comprehensiveness Faithfulness との比較；付録6参照）。 既存の訓練分布内忠実性評価手法である Comprehensiveness faithfulness（DeYoung et al., 2020[^20]）を実験2と同一条件（Spurious GridWorld, MoET $K = 4, d = 5$, 10シード）に適用し、本枠組みの不変性評価と比較する。Comprehensiveness は Oracle の c 依存度（$p = 0.0$ で 0.484、$p = 0.5$ で 0.103）を訓練分布上で正しく反映するが、$p = 0.0$ で reversed_c 下の J_S が壊滅的（-1.00 ± 0.00）になることは予測できない。不変性評価が訓練分布内評価の gap を補完することを実証する。

5.6 実装詳細とハイパーパラメータ

Oracle policy には stable-baselines3[^19]（Raffin et al., 2021）を使用し、Surrogate model は scikit-learn（決定木・線形モデル）、PyTorch（MoET ゲーティング層）、および sklearn.ensemble（GBT）で実装した。全実験で蒸留データ 10,000 サンプル（評価用 5,000 サンプルは独立シードで収集）を標準設定とした。

Table A1: Oracle policy の主要ハイパーパラメータ

アルゴリズム	環境	主要設定
DQN	CartPole-v1	lr=2.3×10⁻³, batch=64, buffer=100k, train_freq=256, gradient_steps=128, exploration_fraction=0.16, 500k steps, EvalCallback（5k steps ごと）
DQN	Spurious GridWorld	SB3 デフォルト, learning_starts=1,000, 200k steps
PPO	LunarLander-v3	n_envs=8, rollout n_steps=1024/env, batch=64, n_epochs=4, ent_coef=0.01, 1M steps
TD3	MuJoCo Hopper-v5	RL Zoo 事前学習済みモデル（Hopper-v3_1）を使用

Table A2: Surrogate model の主要ハイパーパラメータ

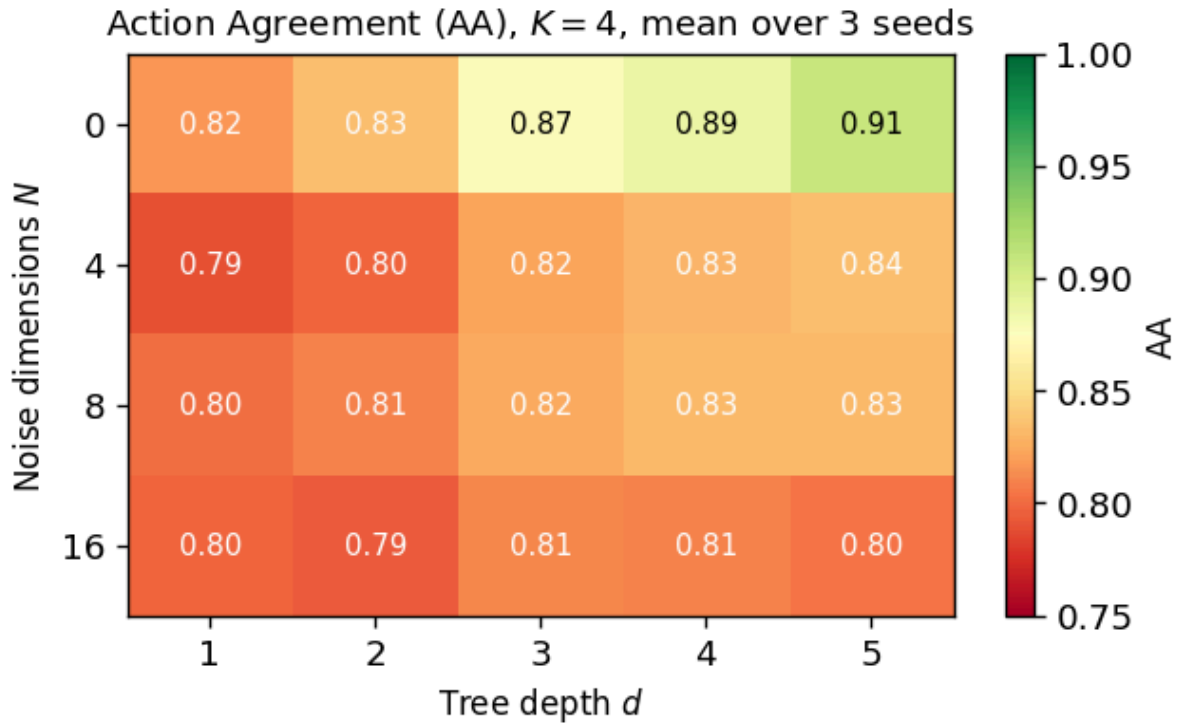
モデル	主要設定
MoET	$K = 4, d = 5$（best config）, soft gating, Adam lr=1×10⁻³, 蒸留 100 epoch
単一決定木	DecisionTreeClassifier, max_depth=5
線形モデル	LogisticRegression, C=1.0（sklearn デフォルト）
GBT	HistGradientBoostingClassifier, max_iter=300, lr=0.1, max_depth=無制限
RegTree (Hopper)	DecisionTreeRegressor, max_depth=12（exp011）/ 5（exp012）
GBT+DAgger (Hopper)	HistGradientBoostingRegressor（行動次元ごと独立）, max_iter=300, lr=0.1, max_depth=無制限；DAgger 10 イテレーション × 10,000 サンプル（計 110,000）

6. 結果

6.1 実験1：再現性の構造的上限

ノイズ次元を追加すると MoET の再現性は深さとともに改善するが、上限が低下する。$N = 0$ で $K = 4, d = 5$ のとき AA=0.915±0.028、$N = 16$ では AA=0.820±0.032 にとどまる（Figure 1）。入力空間の複雑さに応じて AA の到達上限が変化することを示す。なお、ここで報告する実験1の AA 値（0.915±0.028）は exp004 データセットを正規ソースとして用いている。exp004 は実験4（付録1）と共通のシードセットを使用しており、両実験の数値

の出典として一元化されている。別シードセットで実施した exp001 では同条件（$N = 0, K = 4, d = 5$）で AA=0.910±0.016 が得られている。



6.2 実験2：再現性高・不変性低の実証

実験2（$p = 0.0$）では c が確定的にゴール方向を符号化するため、合理的な学習器は c に依存する方策を習得する。この設定では Surrogate model が c 依存を複製し、reversed_c 条件で崩壊することは設計上の帰結である。本実験の意義はこの帰結の実証ではなく、グラウンドトゥルースが明確な制御された環境において提案フレームワークの診断基準が正しく機能することの確認にある。

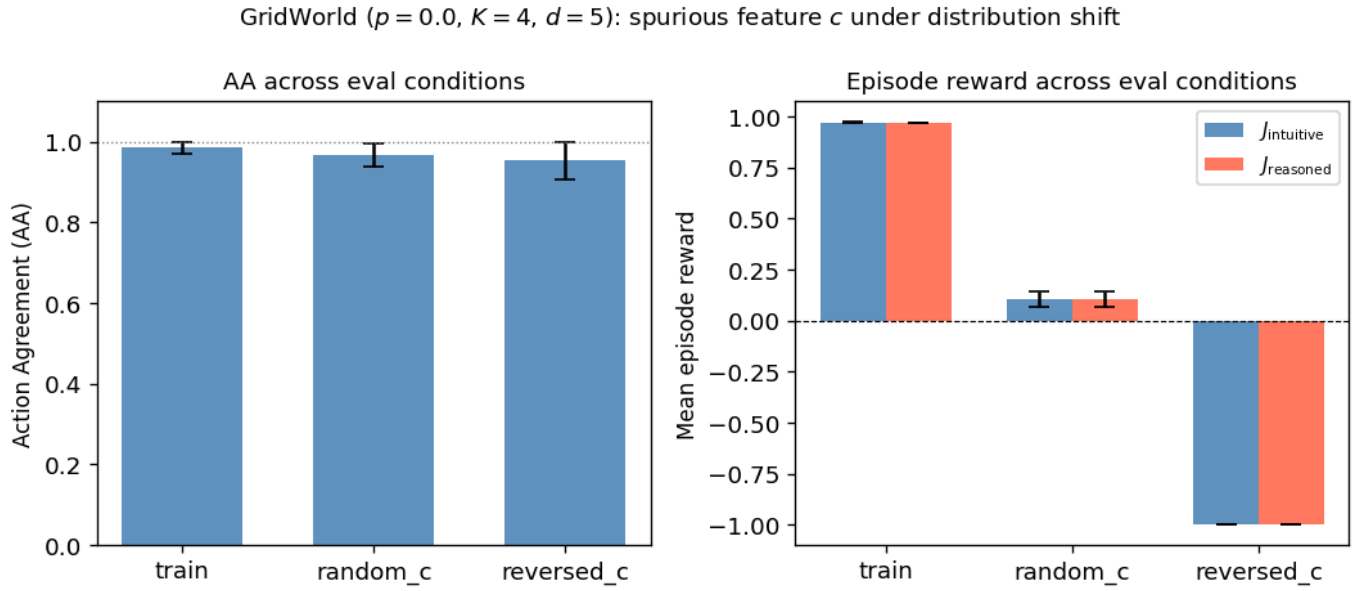
train 条件では AA が高く（最良設定 $K = 4, d = 5$ で 0.988±0.011）、J もほぼ一致する。reversed_c 条件では AA=0.942（95% CI: [0.902, 0.982]）を維持したまま $J_{\text{oracle}} = J_{\text{surrogate}} = -1.000$ まで崩壊する（Figure 2）。$J_S = -1.000$ は全 10 シードで例外なく観測された（分散ゼロ）。これは reversed_c 条件では Surrogate が決定論的に誤ったゴールへ向かうため、ランダム性が介在せず結果が確定するためである。train vs reversed_c の AA 差（Δ=0.046）は Welch t 検定で $p_{\text{adj}} = 0.030$（$d = 1.14$）と有意であった（Holm–Bonferroni 補正済み）。なお $p_{\text{adj}} = 0.030$ は有意閾値を下回るものの margin は小さく、$n = 10$ での限界として解釈する必要がある。また、95% CI 下限 0.902 は診断閾値 $\theta_{\text{AA}} = 0.9$ をわずか 0.002 上回るに過ぎず、境界近傍の推定である。$n = 10$、Cohen の $d = 1.14$、$\alpha = 0.05$ における検出力は約 0.55〜0.65 と推算され、真の効果が存在しても 35〜45% の確率で検出できない水準である。J_S の崩壊は全シード一致という自明な事実であり統計検定によらない。Section 3.3 の判定基準に照らすと、$\text{AA}(D_{\text{shift}}) = 0.942 > \theta_{\text{AA}} = 0.9$ かつ $J_S(D_{\text{shift}}) = -1.000 \ll \alpha \times J_S(D_{\text{train}})$ であり、スプリアス依存の疑いが強いケースに該当する。Surrogate model が Oracle policy のスプリアス依存をそのまま複製した結果として解釈される。random_c 条件でも AA=0.965±0.031 と高水準を維持するが、J は両者とも低水準に留まる。c をランダム化しても Oracle policy と Surrogate model の双方がスプリアス特徴 c に依存した行動を取り続けるため、互いの行動は一致するが環境内での性能は崩壊する。すなわち random_c 条件も同様にスプリアス依存の判定基準を満たしており、本枠組みが複数種類の分布シフトで一貫してこの状態を識別できることを示す。

SHAP[^4]（KernelExplainer）を同一の Oracle policy に適用した場合、スプリアス特徴 c の重要度は train（Mean |SHAP| = 0.0181）と reversed_c（Mean |SHAP| = 0.0178）でほぼ同値となる（Figure 4）。SHAP は「方策が何に依存しているか」を示すが、「その依存が分布シフト後に維持されるか」を問わない。本枠組みはこの隙間を不変性の評価によって補完する。

MoET エキスパート木の可視化。 実験2（$p = 0.0$, $K = 4$, $d = 5$, seed=42）の MoET を再蒸留し、エキスパートの決定木構造を抽出した。特徴量は agent_x, agent_y $\in [0, 1]$（正規化済み位置）と $c \in 0, 1$（スプリアス特徴）の 3 次元、行動は 0=上, 1=下, 2=左, 3=右 の 4 値である。

```
|--- c <= 0.50             # root: スプリアス特徴で最初に分岐
|   |--- agent_y <= 0.12
|   |   |--- class: 2     # 左移動（ゴール (0,0) 左上 へ向かう）
|   |--- agent_y >  0.12
|   |   |--- agent_x <= 0.38
|   |   |   |--- class: 0 # 上移動
|   |   |--- agent_x >  0.38
|   |   |   |--- ...      # 位置に応じた左・上移動
|--- c >  0.50             # c=1: ゴール (4,4) 右下 へ向かう
|   |--- agent_y <= 0.88
|   |   |--- agent_x <= 0.62
|   |   |   |--- ...      # 位置に応じた右・下移動
|   |   |--- agent_x >  0.62
|   |   |   |--- class: 1 # 下移動
|   |--- agent_y >  0.88
|   |   |--- class: 3     # 右移動
```

根ノードの分岐条件が $c \leq 0.5$ であり、MoET がスプリアス特徴 c を方策の一次的な判断基準として獲得していることが木構造から直接読み取れる。$c = 0$ のサブ木はゴール $(0, 0)$（左上）への誘導行動（左・上）を学習し、$c = 1$ のサブ木はゴール $(4, 4)$（右下）への誘導行動（右・下）を学習している。4 エキスパートはいずれも同一の木構造を学習しており（ゲートは Expert 0 に集中）、本環境では実質単一の決定木として機能する。この木構造は「なぜ reversed_c で AA が高いまま J が崩壊するか」を直接説明する：Surrogate model は Oracle policy の c 依存を忠実に複製しており、c が反転した分布では双方が誤ったゴールへ向かい続けるためである。なお、上記は代表例として seed=42 の結果を示したものであり、確認した全 10 シードで根ノードの c 分岐と同一のエキスパート構造が再現された。



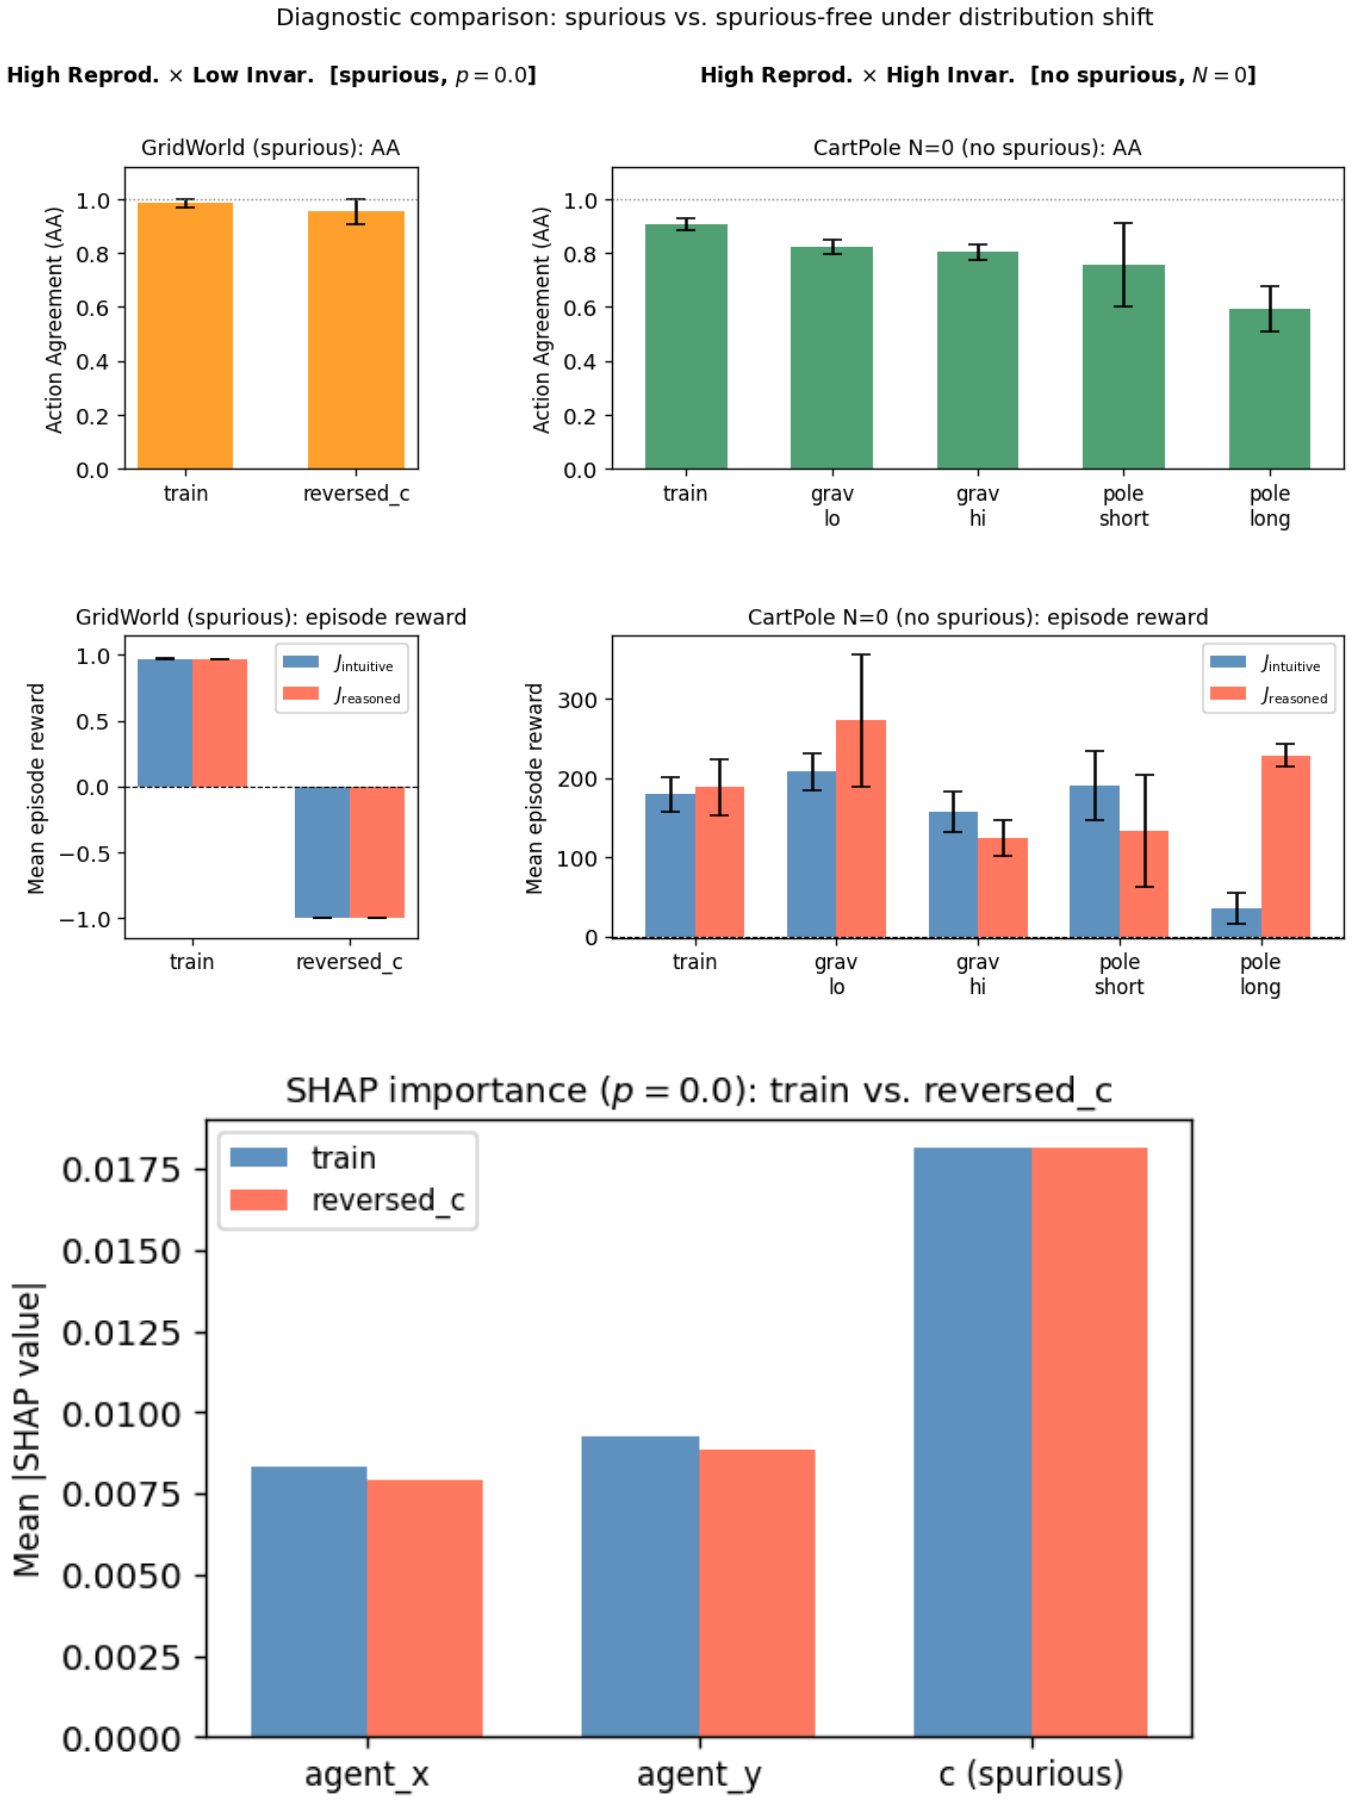
6.3 実験3：スプリアスのない環境における不変性の比較観察

Table 2 に結果を示す。上段が全 10 シード平均±標準偏差、下段が収束成功シード（$J_{\text{oracle}} \geq 450$、8 シード）のみの集計値である。10 シード中 2 シード（seed=2223, 2526）が DQN の確率的収束に失敗した（$J_{\text{oracle}} < 200$）ため、両者を併記する。

評価条件	シード数	AA	J_{oracle}	$J_{\text{surrogate}}$
train ($g = 9.8$, $\ell = 0.5$)	10	0.915±0.028	428.1±148.5	417.9±143.5
train ($g = 9.8$, $\ell = 0.5$)	8（収束）	0.919±0.029	498.4±3.8	484.9±26.3
gravity_lo ($g = 5.0$, $\ell = 0.5$)	10	0.883±0.049	436.5±134.0	425.8±120.8
gravity_lo ($g = 5.0$, $\ell = 0.5$)	8（収束）	0.901±0.028	500.0±0.0	474.4±69.6
gravity_hi ($g = 20.0$, $\ell = 0.5$)	10	0.861±0.063	336.2±180.1	347.4±177.7
gravity_hi ($g = 20.0$, $\ell = 0.5$)	8（収束）	0.880±0.046	390.4±157.5	410.0±134.7
pole_short ($g = 9.8$, $\ell = 0.25$)	10	0.846±0.115	406.8±161.4	361.1±156.0
pole_short ($g = 9.8$, $\ell = 0.25$)	8（収束）	0.890±0.041	477.3±50.5	418.2±112.5
pole_long ($g = 9.8$, $\ell = 1.0$)	10	0.759±0.078	376.5±160.5	426.5±133.8
pole_long ($g = 9.8$, $\ell = 1.0$)	8（収束）	0.773±0.082	447.9±62.4	488.7±22.5

全条件で J_{oracle} と $J_{\text{surrogate}}$ がともに大きく正の値に留まり、実験2の reversed_c 条件（$J = -1.000$）のような壊滅的な崩壊は見られない（Figure 3）。Section 3.3 の判定基準に照らすと、いずれの条件でも $J_S(D_{\text{shift}}) \geq \alpha \times J_S(D_{\text{train}})$ が成立し、スプリアス依存を示す条件には該当しない。収束成功 8 シードに限ると J_{oracle} の分散が大幅に縮小し（train: 148.5 → 3.8）、AA も概ね 0.01〜0.04 程度上昇する。この範囲での変動は主要な結論を変えない。重力変化は CartPole の運動方程式に対するスケーリング的な外乱であるのに対し、ポール長の変化は振り子の慣性モーメントを直接変形させる質的に異なる外乱である。この二種で同様の傾向が見られたことは、この特性が重力シフト固有の偶然でない可能性を示唆する。gravity_lo, gravity_hi では $J_{\text{surrogate}}$ が J_{oracle} をわずかに上回る場合があり、蒸留の正則化効果の可能性を示唆する。

pole_long（$\ell = 1.0$）では AA が 0.759（収束 8 シードでは 0.773）と全条件で最低値を示し、train との差は統計的に有意であった（Welch t: $p_{\text{adj}} = 0.0004$, $d = 2.65$）。他のシフト条件は Holm–Bonferroni 補正後に有意差が確認されなかった（gravity_hi: $p_{\text{adj}} = 0.087$；gravity_lo: $p_{\text{adj}} = 0.186$；pole_short: $p_{\text{adj}} = 0.186$）。
$J_{\text{oracle}} = 376.5$ に対して $J_{\text{surrogate}} = 426.5$ という逆転が生じており、Surrogate model がポール長の変化に対して Oracle policy より適応的に振る舞っていることを示す。この逆転現象の解釈については Section 8 で論じる。



7. 議論

本枠組みの中心的な主張は、忠実性（faithfulness）は正当性（validity）を含意しないという点にある。behavioral cloning によってスプリアス依存が複製されること自体は蒸留の構造から自明だが、その複製が AA の数値上は見え

ないという点が問題の核心である。実験2が示した通り、スプリアス相関が存在する場合 Surrogate model は誤った依存を複製し、訓練分布では高 AA を示しながら分布シフト下で両者ともに失敗する。不変性の評価——$(\mathrm{AA}(D_{\text{shift}}), ; J_S(D_{\text{shift}}))$ の組の観察——を加えることで初めてこの状態を数値から識別できる。実験3はこの対照として、スプリアスのない環境では同じ枠組みが壊滅的崩壊を示さないことを確認した。本研究の貢献は複製が起きることの指摘ではなく、それを定量的・体系的に検出する枠組みの提供にある。

IRM（Arjovsky et al., 2019[^5]）や関連する不変学習の研究は、スプリアス依存を訓練時に排除することを目的とする。本枠組みは訓練戦略を変えるものではなく、学習済み方策と学習済み Surrogate model の組に対して事後的に適用できる点が異なる。実践的な含意として、既存の蒸留ベースの XRL システムに分布シフト下での評価を追加するだけで本枠組みが利用可能となる。

主要主張に対して Welch t 検定（Holm–Bonferroni 補正）による形式的検定を実施した（詳細は `experiments/results/pvalue_summary.csv`）。実験2の train vs reversed_c の差は AA で $p_{\text{adj}} = 0.030$（$d = 1.14$）と有意であり、スプリアス検出の核心的な主張を統計的に支持する。J_S の崩壊は全 10 シードで -1.000（分散ゼロ）であり、統計検定によらず自明である。閾値 θ_{AA} および α の恣意性については本節後半の感度分析（Table 6・7）で対応し、いずれの閾値設定でも定性的結論が変わらないことを確認した。実験3（非スプリアス）では全体の傾向として J の壊滅的崩壊が見られず、pole_long 条件での AA 低下のみ有意（$p_{\text{adj}} = 0.0004$, $d = 2.65$）であった。

実験4・5のモデル比較（付録1・2参照）では、木構造モデルが線形モデルより分布シフト下での再現性を安定して維持する傾向が見られた。ただし、多重補正後に統計的に有意な差が確認されたのは一部の条件に限られるため、この傾向の一般化には慎重さが必要である。実験6の感度分析（付録3参照）はこの傾向を補強し、GridWorld $p = 0.5$ の reversed_c 条件において MoET と Linear の AA の差が蒸留データを 20 倍にしても解消されないことを示した。Tree と MoET の類似した挙動は、MoET のゲーティング層よりも木の分岐構造自体が再現性の鍵である可能性を示唆する。ただし診断デモ（実験2）では分布シフト下での AA が $\theta_{\text{AA}} = 0.9$ を超えることが必要であり、Tree（reversed_c での AA=0.887、閾値未達）より高い AA を維持する MoET $K = 4, d = 5$ を主要 Surrogate として選択した。なお、$\theta_{\text{AA}} = 0.85$ に設定すれば Tree も基準を満たすことが感度分析（Table 6）で確認できる。

SHAP は「現在の方策がどの特徴に依存しているか」を示す点で有用だが、その依存が環境の変化に対して維持されるかどうかは問えない。本研究の不変性の評価は SHAP を置き換えるものではなく、SHAP だけでは見えない情報——依存の有効性——を補完的に提供する。既存の Faithfulness 評価手法である Comprehensiveness faithfulness（DeYoung et al., 2020[^20]）との比較（付録6）では、Comprehensiveness が訓練分布内での特徴依存度を捉える一方、本枠組みの不変性評価がその依存の有効性を補完的に診断することを定量的に実証している。

AA > 0.9 という閾値の恣意性に対しては、閾値を 0.85・0.90・0.95 と変化させた感度分析で対応する。Table 6 に主要条件の AA 平均値と各閾値に対する超過判定を示す。

Table 6: AA 閾値感度分析（主要条件）

実験	評価条件	AA (mean)	> 0.85	> 0.90	> 0.95
実験3（CartPole）	train（全10）	0.915	✓	✓	—
実験3（CartPole）	train（収束8）	0.919	✓	✓	—
実験3（CartPole）	gravity_lo（全10）	0.883	✓	—	—
実験3（CartPole）	gravity_lo（収束8）	0.901	✓	✓	—
実験3（CartPole）	gravity_hi（全10）	0.861	✓	—	—
実験3（CartPole）	gravity_hi（収束8）	0.880	✓	—	—
実験3（CartPole）	pole_short（全10）	0.846	✓	—	—

実験	評価条件	AA (mean)	> 0.85	> 0.90	> 0.95
実験3（CartPole）	pole_short（収束8）	0.890	✓	—	—
実験3（CartPole）	pole_long（全10）	0.759	—	—	—
実験3（CartPole）	pole_long（収束8）	0.773	—	—	—
実験2（GridWorld, $p = 0.0$）	train	0.988	✓	✓	✓
実験2（GridWorld, $p = 0.0$）	reversed_c	0.942	✓	✓	—

閾値を 0.85・0.90・0.95 のいずれに設定しても定性的な結論は変わらない。AA > 0.9 を「高い行動一致率」の実験的目安として用いることは本データの範囲で妥当である。

$\alpha = 0.8$ の恣意性に対しても同様の感度確認を行った。$\alpha \in 0.7, 0.8, 0.9$ で変化させたときの検出判定を Table 7 に示す。

Table 7: α 感度分析（$J_S(D_{\text{shift}})/J_S(D_{\text{train}})$ と検出判定）

実験	評価条件	AA	J_S/J_{train}	$\alpha = 0.7$	$\alpha = 0.8$	$\alpha = 0.9$
実験2（$p = 0.0$）	reversed_c	0.942	−1.03	検出	検出	検出
実験2（$p = 0.0$）	random_c	0.965	0.06	検出	検出	検出
実験3（非スプリアス）	gravity_hi	0.861	0.83	—	—	—
実験3（非スプリアス）	pole_short	0.846	0.86	—	—	—
実験3（非スプリアス）	gravity_lo	0.883	1.02	—	—	—
実験7（LunarLander, GBT）	gravity_hi	0.878	0.87	—	—	—
実験7（LunarLander, GBT）	gravity_lo	0.712	0.58	—	—	—

検出判定は「$\mathrm{AA}(D_{\text{shift}}) > \theta_{\text{AA}}$ かつ $J_S(D_{\text{shift}}) < \alpha \times J_S(D_{\text{train}})$」の両条件が成立した場合。実験3・実験7 のシフト条件はいずれも $\mathrm{AA} < \theta_{\text{AA}} = 0.9$ であるため、α の値によらず非検出となる。特に実験7 の gravity_lo は J_S 比=0.58 と閾値に近い水準まで低下しているが、AA 条件を満たさないため非検出となる。このように、検出は J_S 比だけでなく AA との組み合わせ判定によって決まる。本データセットではスプリアス条件の J_S 比（−1.03, 0.06）と非スプリアス条件（0.58–1.02）の間に大きな分離があり、$\alpha \in 0.7, 0.8, 0.9$ のいずれでも定性的な結論は変わらない。$\alpha = 0.8$ は保守的な中間点として妥当である。

スプリアス依存の検出は、その後の対処法と組み合わせてはじめて実用的な意義を持つ。本枠組みは検出に特化しており、対処そのものを提供するものではないが、検出結果は以下のような後続アクションを示唆する：観測空間からスプリアス特徴を除去する、環境の報酬関数や状態空間を再設計してスプリアス相関を取り除く、あるいは IRM のような不変学習手法で Oracle policy を再訓練する。どのアクションが最適かは環境・タスクの性質に依存し、本研究の範囲では実証的に評価していないが、検出結果が後続のデバッグ・改善サイクルの出発点となることを意図している。

本研究の本質的な貢献は、特定の説明可能性手法の提案ではなく、RL 方策に対する**説明品質の評価方法論**の提供にある。どの Surrogate model を選ぶかは研究者・実務者の目的に委ねられ、本枠組みはその選択を定量的に評価する共通の土台を提供する。「説明と呼べる候補が存在するか（再現性）」「その説明が捉えた依存は検証した範囲で有効か（不変性）」という二つの問いに数値で答えることで、XRL における説明手法の比較・選択・改善のサイクルを支える評価基盤を構築することが本研究の目指すところである。

8. 限界

本研究の枠組みには四つの具体的な限界がある。

第一に、主実験は CartPole と GridWorld という小規模な離散制御環境に限定されている。実験 7（付録4参照）では GBT Surrogate model が AA = 0.870 と機能的な方策性能（$J_S = 237$）を達成し、連続力学系への枠組みの拡張可能性を示した。実験 8（付録5参照）では、MuJoCo Hopper-v5 に対して GBT+DAgger が $R^2 = 0.968 \pm 0.004$ を達成し Stage 1 基準（$R^2 > 0.9$）を通過するとともに、J_S が oracle 比 99.7% に達し、連続行動空間においても Stage 1 通過と機能的方策性能を同時に達成した。分布シフト下では R^2 が大幅に低下し（gravity_hi: 0.326、gravity_lo: 0.056）、フレームワークがこの劣化を検出した。また、pole_long 条件（CartPole 実験3）および gravity_lo 条件（Hopper 実験8）での $J_{\text{surrogate}} > J_{\text{oracle}}$ 逆転は蒸留の正則化効果として興味深いが、そのメカニズムの解明も今後の課題である。

第二に、各条件の統計的信頼性は乱数シード10本に基づいており、特に pole_short 条件（AA 標準偏差 0.115）ではシフト後の挙動にばらつきが残る。主要比較に対する Welch t 検定（Holm–Bonferroni 補正）を実施し、中心的主張（実験2 スプリアス検出）や pole_long の有意な AA 低下について統計的支持を確認したが、pole_short・gravity 条件は補正後に有意差を確認できていない（gravity_hi: $p_{\text{adj}} = 0.087$；gravity_lo および pole_short: $p_{\text{adj}} = 0.186$）。これらの比較については解釈に慎重さが必要である。

第三に、本枠組みは Oracle policy が評価分布上でも動作することを前提とする。本実験では pole_long 条件でも Oracle policy は $J_{\text{oracle}} = 376.5$ と動作しており、Surrogate model が $J_{\text{surrogate}} = 426.5$ と逆転する現象が観察された。この逆転は蒸留の正則化効果（より単純な構造への圧縮がシフト後の汎化を助ける）を示唆するが、メカニズムの解明は今後の課題である。仮に Oracle policy が OOD で機能不全に陥る条件では、AA の低下が Surrogate model の不変性の欠如によるものか Oracle policy の失敗に伴う必然的な乖離かを区別できないため、注意が必要である。

第四に、分布シフトの選択（重力・ポール長・c の反転）は恣意的であり、どのようなシフトを選ぶかが不変性の評価結果に影響しうる。実問題への適用において「何をシフトすべきか」は自明でなく、本枠組みの適用に際しての実践的な問いとなる。SHAP[^4] のような特徴重要度手法は依存度の高い特徴をシフト操作の対象として優先する手がかりを提供し、IRM[^5] は複数の訓練環境が利用可能な場合にスプリアス候補の事前絞り込みに応用できる。ただしこれらはシフト候補の探索を補助するものであり、網羅的な選択基準の形式化は今後の課題として残る。

9. 結論

本研究は、強化学習方策の説明可能性を再現性（訓練分布上での行動一致）と不変性（分布シフト下での AA・J_S の維持）の二軸で評価する枠組みを提案した。Oracle policy に手を加えず Surrogate model を事後的に配置する分離の設計により、説明可能性と性能のトレードオフを回避しつつ、任意の解釈可能モデルを共通の評価軸で比較できる。

CartPole とスプリアス GridWorld を用いた実験により、高 AA を維持しながら分布シフト下で崩壊する「再現性高・不変性低」の状態を数値から識別できることを示した。木構造モデルは線形モデルより分布シフト下での再現性を安定して維持する傾向が見られたが、統計的に有意な差は一部の条件に限られた。LunarLander-v3（実験7；付録4）への拡張では、勾配ブースティング木（GBT）Surrogate model が AA = 0.870 を達成し、MuJoCo Hopper-v5（実験8；付録5）では GBT+DAgger 蒸留により $R^2 = 0.968$・J_S が oracle 比 99.7% を達成し、連続行動空間においても Stage 1 通過と機能的方策性能を同時に確認した。分布シフト下では R^2 が大幅に低下し（gravity_hi: 0.326、gravity_lo: 0.056）、フレームワークがこの劣化を検出した。

今後の課題として、高次元観測空間への適用、シード数の増加による統計的信頼性の強化、分布シフトの選択基準の形式化が挙げられる。連続行動環境への本格的な適用については、本枠組みの評価パイプライン自体は連続行動空間にも適用可能であり（ε-合意による AA の再定義を含む）、実験 8 の GBT+DAgger がその一例を示した。より複雑な連続制御タスクへの適用と高次元観測空間への拡張は今後の課題である。また、Surrogate model の構造か

ら規則列や自然言語説明を生成し、それが不変性にどう対応するかを検討することが、説明可能性の実用化に向けた次のステップとなる。

[^1]: Chen, R., et al. (2022). Machine explanations and human understanding. *Transactions on Machine Learning Research*.

[^2]: Mindlin, D., et al. (2025). Towards co-constructed explanations. *International Conference on Human-Agent Interaction*.

[^3]: Vasic, M., et al. (2019). MoET: Interpretable and verifiable reinforcement learning via mixture of expert trees. *AAAI*.

[^4]: Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

[^5]: Arjovsky, M., et al. (2019). Invariant risk minimization. *arXiv:1907.02893*.

[^6]: Bastani, O., Pu, Y., & Solar-Lezama, A. (2018). Verifiable reinforcement learning via policy extraction. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^7]: Kolter, J. Z., & Ng, A. Y. (2009). Regularization and feature selection in least-squares temporal difference learning. *International Conference on Machine Learning (ICML)*.

[^8]: Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.

[^9]: Alvarez-Melis, D., & Jaakkola, T. S. (2018). Towards robust interpretability with self-explaining neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^10]: Samek, W., Wiegand, T., & Müller, K.-R. (2017). Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. *arXiv:1708.08296*.

[^11]: Koh, P. W., et al. (2020). Concept bottleneck models. *International Conference on Machine Learning (ICML)*.

[^12]: Greydanus, S., Koul, A., Dodge, J., & Fern, A. (2018). Visualizing and understanding Atari agents. *International Conference on Machine Learning (ICML)*.

[^13]: Yuksekgonul, M., Wang, M., Slack, D., Singh, S., Guestrin, C., & Lakkaraju, H. (2023). Post-hoc concept bottleneck models. *International Conference on Learning Representations (ICLR)*.

[^14]: Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518, 529–533.

[^15]: Gulrajani, I., & Lopez-Paz, D. (2021). In search of lost domain generalization. *International Conference on Learning Representations (ICLR)*.

[^16]: Sagawa, S., Koh, P. W., Hashimoto, T. B., & Liang, P. (2020). Distributionally robust neural networks for group shifts: On the importance of regularization for worst-case generalization. *International Conference on Learning Representations (ICLR)*.

[^17]: Puiutta, E., & Veith, E. M. S. P. (2020). Explainable reinforcement learning: A survey. *International Cross-Domain Conference for Machine Learning and Knowledge Extraction (CD-MAKE)*.

[^18]: Brockman, G., et al. (2016). OpenAI Gym. *arXiv:1606.01540*.

[^19]: Raffin, A., et al. (2021). Stable-baselines3: Reliable reinforcement learning implementations. *Journal of Machine Learning Research*, 22(268), 1–8.

[^20]: DeYoung, J., et al. (2020). ERASER: A benchmark to evaluate rationalized NLP models. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL)*.

付録

付録1. 実験4：CartPole モデル比較

実験設定。 実験1と同じ CartPole ノイズ拡張環境（$N \in 0, 4, 8, 16$）で、MoET（$K = 4, d = 5$）、単一決定木（$d = 5$）、ロジスティック回帰の三種を比較する。蒸留サンプル数 10,000、評価サンプル数 5,000、10シードで AA を報告する。

結果。 Table A3 に N ごとの AA を示す（10シード平均±標準偏差）。

Table A3: CartPole モデル比較（AA）

N	MoET	Tree	Linear
0	0.915±0.028	0.902±0.031	0.842±0.033
4	0.881±0.035	0.858±0.043	0.857±0.054
8	0.852±0.050	0.812±0.065	0.846±0.060
16	0.820±0.032	0.768±0.046	0.830±0.037

$N = 0$ では MoET が最も高い AA（0.915）を示し、Tree（0.902）がこれに続く。Linear は 0.842 と他の二種に比べて低い。$N = 4, 8$ では MoET が依然として優位を保つが差は縮小し、$N = 16$ では数値上 Linear（0.830）が MoET（0.820）をわずかに上回るが補正後に有意でない（$p_{\text{adj}} = 0.54$）。Welch の t 検定（Holm--Bonferroni 補正、全 12 比較）の結果、$N = 0$ では MoET・Tree ともに Linear より有意に高い AA を示した（MoET vs Linear: $p_{\text{adj}} < 0.001, d = 2.39$; Tree vs Linear: $p_{\text{adj}} < 0.01, d = 1.90$）が、MoET と Tree の差は有意でなかった（$p_{\text{adj}} = 0.36$）。$N = 16$ では Linear が Tree を有意に上回り（$p_{\text{adj}} = 0.037, d = 1.50$）、ノイズが多い条件では線形モデルが木構造より高い再現性を示した。$N = 4, 8$ ではいずれの差も有意でなかった（全 $p_{\text{adj}} > 0.4$）。なお、補正ファミリーは「3 モデル間ペアワイズ比較 × 4 N レベル = 12 比較」を一括して設定した（`pvalue_summary.csv` 参照）。N レベルごとに独立した 3 比較を族として定義する方法も考えられるが、本論文では透明性を優先して保守的な 12 比較一括補正を採用した。

付録2. 実験5：GridWorld モデル比較

実験設定。 実験2と同じ Spurious GridWorld（$p \in 0.0, 0.2, 0.5$、評価条件 train / random_c / reversed_c）で MoET・Tree・Linear の三種を比較する。

結果。 Table A4 に $p \in 0.0, 0.2, 0.5$ での AA を示す。

Table A4: GridWorld モデル比較（AA）

p	評価条件	MoET	Tree	Linear
0.0	train	0.985±0.014	0.971±0.012	0.903±0.052
0.0	random_c	0.958±0.035	0.930±0.044	0.836±0.079
0.0	reversed_c	0.930±0.063	0.887±0.084	0.771±0.133
0.2	train	0.996±0.003	0.990±0.009	0.971±0.021
0.2	random_c	0.959±0.100	0.931±0.107	0.920±0.048
0.2	reversed_c	0.922±0.200	0.872±0.211	0.867±0.102

p	評価条件	MoET	Tree	Linear
0.5	train	0.999±0.001	0.998±0.001	0.878±0.100
0.5	random_c	0.970±0.064	0.971±0.065	0.811±0.146
0.5	reversed_c	0.940±0.132	0.942±0.133	0.742±0.220

MoET と Tree はほぼ同等の AA を示し、Linear は全条件で低い傾向がある。Welch の t 検定（Holm--Bonferroni 補正、全 27 比較）では、補正後に有意であったのは $p = 0.0$ 条件における MoET vs Linear の 2 件のみであった（train: $p_{\text{adj}} = 0.019$, $d = 2.13$; random_c: $p_{\text{adj}} = 0.018$, $d = 2.00$）。27 比較の多重補正のもとでは大半の差が統計的有意性の基準を満たさず、木構造モデルが線形モデルより分布シフト下での再現性を安定して維持するという傾向は見られたものの、統計的に有意な差が広く確認されたわけではない点に留意が必要である。MoET と Tree の差はいずれの条件でも有意でなく（全 $p_{\text{adj}} > 0.5$）、両者の挙動の類似性は統計的に支持される。

$p = 0.2$ の reversed_c 条件（MoET: AA=0.922±0.200）および $p = 0.5$ の reversed_c 条件（AA=0.940±0.132）では標準偏差が大きいため、平均値に基づく閾値判断の信頼性について補足する。これらの条件でシードごとの AA を確認したところ、$p = 0.2$ では 10 シード中 9 シード（中央値 0.996、IQR 0.984--0.998）、$p = 0.5$ では 10 シード中 8 シード（中央値 0.998、IQR 0.962--0.999）が AA > 0.9 を達成していた。大きな標準偏差は少数の外れ値シード（スプリアス特徴への依存学習が弱かったシード）に起因しており、中央値ベースの判断では高 AA での依存複製は安定して観察される。

付録3. 実験6：蒸留データ量の感度分析

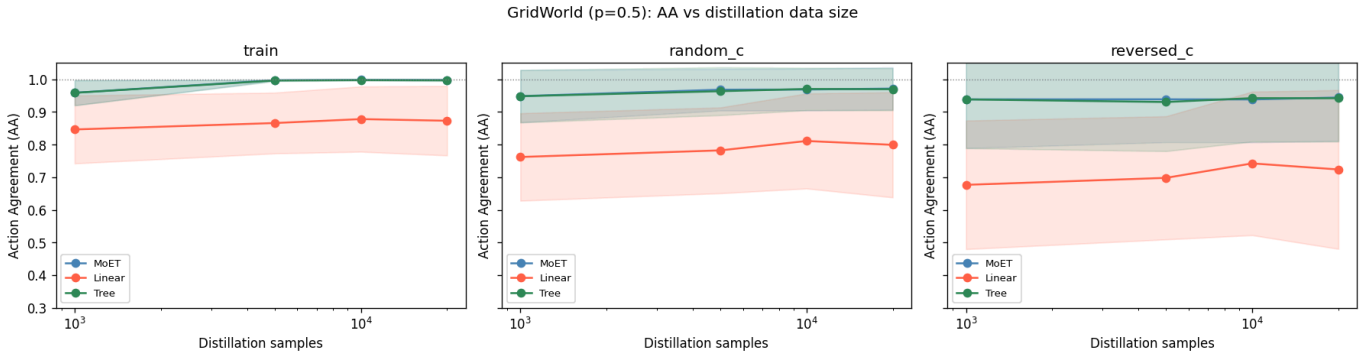
実験設定。 蒸留サンプル数 $n \in 1\text{k}, 5\text{k}, 10\text{k}, 20\text{k}$ を変化させ、CartPole（$N = 0$）と GridWorld（$p \in 0.0, 0.5$）の両環境で MoET・Tree・Linear を比較する。

結果。 Table A5 に CartPole（$N = 0$）の結果を示す。

Table A5: 蒸留データ量感度分析（CartPole $N = 0$、AA）

n	MoET	Tree	Linear
1k	0.888±0.020	0.881±0.028	0.823±0.051
5k	0.916±0.024	0.904±0.028	0.839±0.034
10k	0.915±0.028	0.903±0.031	0.842±0.033
20k	0.926±0.022	0.906±0.031	0.844±0.033

MoET と Tree は 5k 以降で AA がほぼ飽和し、Linear はデータ量とともに緩やかに上昇するが 20k でも 0.844 にとどまる。GridWorld $p = 0.5$ の reversed_c 条件では MoET と Linear の AA の差（約 0.22）がデータ量を 20 倍にしても解消されず（Welch t 検定 $p_{\text{adj}} < 0.01$）、分布シフト下での再現性の差が蒸留データ不足ではなくモデルの構造に起因することを示す（Figure 5）。



付録4. 実験7：LunarLander-v3 への拡張

実験設定。 LunarLander-v3（PPO oracle、$J_{\text{oracle}} = 260 \pm 13$）に対し、MoET・Tree・Linear・GBT の四種で蒸留する。重力係数 $g \in -10.0, -3.0, -11.5$ を分布シフト条件として用いる。各 10 シードで評価する。

結果。 Table A6 に訓練分布および分布シフト条件下の AA と J_S を示す。

Table A6: LunarLander-v3 実験7 結果（10シード平均±標準偏差）

モデル	AA（train）	AA（gravity_lo）	AA（gravity_hi）	J_S（train）	J_S（gravity_lo）	J_S（gravity_hi）
GBT	**0.870 ± 0.021**	0.712 ± 0.063	**0.878 ± 0.018**	**236.8 ± 18.8**	137.8 ± 39.1	**205.9 ± 25.3**
Linear	0.767 ± 0.046	0.713 ± 0.078	0.803 ± 0.032	178.3 ± 72.2	200.0 ± 30.5	157.7 ± 76.9
MoET	0.732 ± 0.026	0.547 ± 0.080	0.769 ± 0.029	−264.1 ± 90.2	−301.3 ± 122.3	−280.6 ± 106.6
Tree	0.711 ± 0.034	0.554 ± 0.087	0.752 ± 0.033	−293.8 ± 104.0	−316.3 ± 169.4	−293.2 ± 114.2

GBT は AA = 0.870 ± 0.021 を達成し、MoET（0.732）・Tree（0.711）・Linear（0.767）を大きく上回る。また GBT と Linear のみが実際に着陸に成功し（$J_S > 0$）、MoET・Tree は AA が約 0.72 あるにもかかわらず方策としては機能しない（$J_S \ll 0$）。この結果は、AA の差が方策性能に臨界的な影響を与えることを示す。

分布シフト下では、gravity_hi（$g = -11.5$、訓練比 +15%）で GBT は AA = 0.878 ± 0.018、$J_S = 206 \pm 25$ と訓練条件とほぼ同等の性能を維持する。gravity_lo（$g = -3.0$、月面相当）では AA = 0.712 ± 0.063、$J_S = 138 \pm 39$ と AA・J_S が同時に低下する。GBT の gravity_lo での AA 低下（Δ=0.158）は Welch t 検定で $p_{\text{adj}} < 0.001$（$d = 3.36$）、J_S の低下（Δ=99）も $p_{\text{adj}} < 0.001$（$d = 3.23$）と有意であった（Holm–Bonferroni 補正済み）。Section 3.3 の判定基準に照らすと、いずれの条件でも $\mathrm{AA}(D_{\text{shift}}) < \theta_{\text{AA}} = 0.9$ であるためスプリアス依存の判定は下されず、この劣化は非スプリアス環境で観察される CartPole 物理パラメータシフト（実験 3）と同じ「期待されたシフト後劣化」のパターンと一致する。

付録5. 実験8：MuJoCo Hopper-v5 への拡張

実験設定。 MuJoCo Hopper-v5（TD3 oracle、$J_{\text{oracle}} \approx 3500$）に対し、回帰型 Surrogate model を適用する。再現性の指標として R^2 および ε-agreement（$|\hat{a} - a|_2 < 0.2$）を用い、10シードで評価する。分布シフト条件には重力係数 $g \in -9.81, -5.0, -20.0$ と足接地摩擦係数スケール $f \in 0.7, 1.3$ を用いた。

構造制約ボトルネックの確認（BC）。 まず RegTree を用いた行動複製（BC）で構造制約の影響を確認した。深さを $d = 5$ に制限した場合、$R^2 = 0.698 \pm 0.009$ 止まりであったが、制約を緩和し $d = 12$ とすることで $R^2 = 0.922 \pm 0.008$ に到達した。連続環境においても構造制約が再現性に物理的な上限を課す「構造制約ボトルネック」の存在を確認した（主張1の再現）。ただし BC 蒸留では covariate shift により J_S が oracle の約 5% に留まり、不変性評価の土台として不十分であった。

GBT+DAgger による両基準の同時達成。 BC の covariate shift を修正するため、勾配ブースティング木（GBT）+ DAgger を適用した。各イテレーションで surrogate が踏む状態分布を oracle にラベリングさせ直す操作を 10 回繰り返す（初期 10,000 サンプル＋各イテレーション 10,000 サンプル追加、計 110,000 サンプル）。結果として、GBT+DAgger は $R^2 = 0.968 \pm 0.004$ を達成し Stage 1 基準（$R^2 > 0.9$）を明確に通過するとともに、$J_S = 3527 \pm 25$（oracle 比 99.7%）に達した（Table A7）。

Table A7: GBT+DAgger Surrogate の train 条件（Hopper-v5, 10シード平均±標準偏差）

手法	R^2（train）	AA_ε（$\varepsilon = 0.2$）	J_S	$J_S / J_{\mathrm{oracle}}$
GBT+DAgger	**0.968 ± 0.004**	0.808 ± 0.019	**3527 ± 25**	99.7 %

分布シフト下での不変性評価。 Table A8 に分布シフト条件での結果を示す。

Table A8: GBT+DAgger Surrogate の分布シフト下での結果（10シード平均±標準偏差）

条件	R^2	AA_ε	J_S	J_{oracle}	$J_S / J_{\mathrm{oracle}}$
train	0.968 ± 0.004	0.808 ± 0.019	3527 ± 25	3536	99.7 %
gravity_hi（$g = -20$）	0.326 ± 0.084	0.069 ± 0.019	299 ± 19	308	97.1 %
gravity_lo（$g = -5$）	0.056 ± 0.097	0.056 ± 0.011	678 ± 479	389	174 %
friction_hi（$f = 1.3$）	0.674 ± 0.032	0.281 ± 0.026	1110 ± 139	1403	79.1 %
friction_lo（$f = 0.7$）	0.505 ± 0.037	0.189 ± 0.014	1011 ± 241	1121	90.2 %

gravity_hi と gravity_lo では R^2 がそれぞれ 0.326・0.056 まで低下し、訓練時の高再現性（$R^2 = 0.968$）が分布シフト下で大幅に失われる。フレームワークはこの劣化を R^2 と J_S の両軸で検出しており、主張3の再現が確認された。gravity_lo では $J_S = 678 \pm 479$（oracle 比 174%）と surrogate が oracle を上回る逆転傾向が見られ、CartPole 実験3（pole_long 条件）と方向性が一致する。ただし標準偏差が非常に大きく（± 479）、この逆転は統計的に確定的でない。本実験により、連続行動空間においても再現性と不変性の二軸評価の論理が一貫して適用できることが実証された。

付録6. Comprehensiveness Faithfulness との比較（実験9）

目的。 訓練分布内の忠実性評価手法として広く用いられる Comprehensiveness faithfulness（以下 comp）を同一実験に適用し、本枠組みとの相補性を示す。

Comprehensiveness の定義。 特徴 i の Comprehensiveness を次式で定義する（DeYoung et al., 2020 に準じる）：

$$\mathrm{comp}_i = \mathrm{AA}(\text{all features}) - \mathrm{AA}(\text{feature } i \text{ masked to mean})$$

comp_i が大きいほど、Surrogate model が特徴 i に強く依存していることを訓練分布上で示す。

実験設定。 Spurious GridWorld の exp002 oracle（各 p・各シード）を再利用し、同一設定（MoET $K = 4, d = 5$、蒸留 10,000 サンプル）で Surrogate model を再蒸留して comp_c（スプリアス特徴 c）を計算した。既存の不変性評価結果（exp002 の reversed_c 条件）と並置する。

Table A9: Comprehensiveness vs. 不変性評価（Spurious GridWorld, MoET $K = 4, d = 5$, 10シード平均±標準偏差）

p	comp_c	comp_x	comp_y	$\mathrm{AA}_{\mathrm{train}}$	$\mathrm{AA}_{\mathrm{rev_c}}$	$J_S^{\mathrm{rev_c}}$
0.0	**0.484±0.013**	0.316±0.070	0.324±0.069	0.985±0.014	0.942±0.056	**−1.00±0.00**
0.2	0.303±0.098	0.582±0.228	0.593±0.154	0.996±0.003	0.929±0.201	**−1.00±0.00**
0.5	0.103±0.099	0.600±0.249	0.392±0.178	0.999±0.001	0.940±0.132	−0.30±0.31

結果の解釈。 comp_c は p の増加とともに単調に低下しており、Comprehensiveness は Oracle の c 依存度を訓練分布上で正しく反映している。$p = 0.0$ では $\mathrm{comp}_c = 0.484$ と位置特徴（$\mathrm{comp}_x = 0.316, \mathrm{comp}_y = 0.324$）を大きく上回り、Surrogate が c に最も強く依存していることが確認できる。

しかし Comprehensiveness は訓練分布内評価であるため、この依存がスプリアスか因果的かを判定する手段を持たない。実際、$p = 0.0$ では comp_c が高いにもかかわらず、$reversed_c$ 下で *J_S = -1.00*（全シード一様に壊滅的失敗）となる。$Comprehensiveness$ は「$Surrogate$ が c に依存している」ことは教えるが、「その依存が分布シフト下で破綻する」ことは教えない。本枠組みの不変性評価（$\mathrm{AA}_{\mathrm{rev_c}}$・$J_S^{\mathrm{rev_c}}$）はこの gap を直接測定し、スプリアス依存の実害を実証する。

相補性の結論。 Comprehensiveness と不変性評価は競合するものではなく相補的である。Comprehensiveness は「Surrogate が何をどれだけ使っているか」を訓練分布上で定量化し、不変性評価は「その利用がシフト後も有効か」を診断する。両軸を組み合わせることで、Surrogate model の説明品質をより完全に評価できる。