再現性と分布不変性に基づく強化学習方策の説明可能性の定義

要旨

強化学習（RL）方策の説明可能性研究は、SHAP や LIME のような特徴寄与手法から方策蒸留まで、「どう説明するか」に注力してきた。しかしこれらの手法は、生成した説明が元の方策の意思決定を本当に反映しているか──とりわけ、方策がスプリアスな特徴依存に陥っていないか──を判断する基準を与えない。本研究は、この空白を埋めるために、RL 方策の説明可能性を操作的に定義する枠組みを提案する。定義の核心は二つの軸である。**再現性**は、構造制約付きモデル（Reasoned model）が訓練分布上で元の方策（Intuitive policy）の行動をどれだけ忠実に再現できるかを測る。**不変性**は、その再現が入力分布を変えた条件下でも維持されるかを測る。CartPole の拡張環境とスプリアス相関を埋め込んだ GridWorld を用いた実験では、スプリアス方策が行動一致率 AA=0.95 を維持しながら累積報酬 $J = -1.000$ まで崩壊する（再現性高・不変性低）のに対し、スプリアスのない方策は重力とポール長の複数シフト下でも $J > 100$ を保つ（再現性高・不変性高）ことを示す。本枠組みは外部ラベルや人手アノテーションを必要とせず、既存の蒸留ベースの説明手法に不変性の評価軸を追加することで、説明の有効性を実証的に測定する。

1. 序論

強化学習における説明可能性の研究は、長らく「何を説明の出力形式とするか」という問いを中心に進んできた。決定木による方策の近似、個別の状態への特徴寄与の帰属、あるいは自然言語による行動理由の生成といった手法は、いずれも人間が読める形式での説明を目標とする。しかし、「説明を生成できること」と「説明が方策の意思決定を正しく反映していること」は別の問いである。SHAP のような事後的説明は、現在の方策がどの特徴に依存しているかを示すことはできても、その依存が入力分布の変化に対して有効であるかどうかは問わない。方策蒸留は行動の再現精度を最大化するが、再現精度が高い代理モデルが、元の方策と同じスプリアスな依存を写し取っている場合を検出する仕組みを持たない。

この状況が生む問題は、説明の「正確さ」に関する操作的な基準の欠如である。ある構造制約付きモデルが訓練分布上で高い行動一致率を達成したとき、それは（a）方策の依存構造を正しく捉えているのか、それとも（b）スプリアスな相関ごと忠実に模倣しているのかを区別できない。この区別が重要なのは、二つのケースで説明の実用的な価値がまったく異なるからである。（a）であれば、その説明は分布変化に対して頑健な理解の基盤を与えうる。（b）であれば、説明は訓練分布の内側でのみ成立する仮像であり、環境が変わった途端に無効化される。

本研究は、この区別を操作可能にするために、RL 方策の説明可能性を再現性と不変性の二軸の組として定義する。再現性は、構造制約付きモデル（Reasoned model）が元の方策（Intuitive policy）の行動をどれだけ再現できるかを訓練分布上で測る既存の指標に対応する。不変性は、その再現が訓練時とは異なる入力分布の下でも維持されるかを測る、本研究が追加する評価軸である。この二軸の組み合わせにより、「再現できるが誤っている」（スプリアス依存の忠実な複製）と「再現でき、かつ正しい」（依存の有効性が分布シフト下でも確認できる）状態を実験的に区別する枠組みが構成される。

本研究の貢献は三点にある。

1. RL 方策の説明可能性を、構造制約下での再現性と分布不変性の二軸で構成される操作的定義として定式化する。

2. スプリアス相関を埋め込んだ GridWorld を用い、行動一致率が高くとも不変性が低い「再現できるが誤っている」ケースを数値的に示す。
3. スプリアスのない CartPole 環境で重力とポール長の複数シフトを与え、再現性と不変性がともに高い「説明可能性が高い」状態の実験的証拠を提供する。

2. 関連研究

2.1 方策蒸留と代理モデル

ブラックボックス方策を解釈可能なモデルで近似する研究は、方策蒸留の文脈で活発に進められてきた。Vasic ら（2019）の Mixture of Expert Trees（MoET）は、ニューラルネットワーク方策をソフトゲーティング付きの決定木混合モデルに蒸留し、解釈可能性と精度を両立する。決定木を用いた方策の蒸留（Bastani et al., 2018）や、線形モデルによる近似（Kolter & Ng, 2009）も同様に、方策の行動を保存しながら構造的な単純さを実現することを目標とする。本研究はこれらの手法を、行動再現のツールとして位置づけるのではなく、不変性の評価と組み合わせることで説明の有効性を測る枠組みの構成要素として用いる点で異なる。

2.2 事後的説明手法と Faithfulness

LIME（Ribeiro et al., 2016）と SHAP（Lundberg & Lee, 2017）は、個々の予測に対する局所的な特徴寄与を算出する手法として広く用いられる。これらの手法は「方策が現在どの特徴に依存しているか」を示すが、その依存が分布変化に対して有効かどうかを問わない。事後的説明の忠実性（faithfulness）に関する研究（Alvarez-Melis & Jaakkola, 2018; Samek et al., 2017）は、説明が元のモデルの挙動を正確に反映しているかを評価しようとするが、忠実性の評価は訓練分布内に限られる場合が多い。本研究の不変性の概念は、分布外での忠実性の維持を直接評価する点でこれらの研究を補完する。

2.3 不変性と分布シフトの解釈可能性

不変リスク最小化（IRM; Arjovsky et al., 2019）は、複数の環境で一貫して有効な特徴表現を学習することで、スプリアス相関への依存を回避しようとする。概念ボトルネックモデル（Koh et al., 2020）は、人間が定義した概念を中間表現として用い、概念ベースの説明の因果的な意味を高めることを目指す。これらの研究が、スプリアス依存を避けながら学習することを目標とするのに対し、本研究は既に学習された方策について、その依存がスプリアスかどうかを事後的に測定する枠組みを提供する。学習戦略と事後評価という役割の違いが、本研究の独自の立ち位置を形成する。

2.4 RL における説明可能性

強化学習の文脈では、注意機構の可視化（Greydanus et al., 2018）や重要な状態の特定（Huang et al., 2018）などの説明手法が提案されてきた。Puiutta & Veith（2020）は RL の説明可能性研究を包括的にサーベイし、説明の対象（状態・行動・報酬）と形式（規則・視覚化・テキスト）の多様性を整理している。本研究はこれらの手法と直接競合するものではなく、「生成した説明が方策の行動を本当に捉えているか」という横断的な問いに答える評価軸として位置づけられる。

3. 問題設定と定義

3.1 Intuitive Policy と Reasoned Model

状態空間を S、行動空間を A とし、Intuitive policy を $\pi_I : S \to \Delta(A)$ と書く。これは強化学習で学習されたブラックボックス方策であり、内部表現の意味的な解釈を前提としない。Reasoned model は、Intuitive

policy を模倣するために学習される構造制約付きのモデルである。状態 s を制約された中間表現 $z \in Z$ に写像する関数 R と、そこから行動分布を出力する関数 D を用いると、

$$z = R(s), \qquad \pi_R(a \mid s) = D(R(s))$$

と書ける。Z は低次元性・単純性・解釈可能性を持つ表現空間であり、その具体例として線形モデル、深さ制限付き決定木、Mixture of Expert Trees（MoET）が挙げられる。Reasoned model を「人間が読む説明を直接生成するモデル」としてではなく、元の方策の行動をどこまで保存できるかを測るための制約付き代理として位置づける点が、本研究の定式化の起点である。

3.2 説明可能性の二軸定義

本研究では、方策の説明可能性を単一のスカラーとして評価するのではなく、次の二軸の積として定義する。

再現性（Reproducibility）は、Reasoned model が訓練分布 D_{train} 上で Intuitive policy の行動をどれだけ一致して再現できるかを測る。主指標は行動一致率 $\mathrm{AA}(D) = \mathbb{E}_{s \sim D}[\mathbf{1}[\pi_I(s) = \pi_R(s)]]$ であり、補助指標として KL divergence を用いる。

不変性（Invariance）は、分布シフト $D_{\text{shift}} \neq D_{\text{train}}$ 下で、再現性に加えて累積報酬が維持されるかを測る。相対性能低下 $\mathrm{RPD} = (J_I - J_R)/J_I$ （J_I, J_R はそれぞれ Intuitive policy と Reasoned model の累積報酬）が小さく保たれる場合、かつ両者の J が分布シフト下でも正常範囲に留まる場合に、不変性が高いと判定する。

この二軸を組み合わせると、以下の四状態が得られる。

	不変性：高	**不変性：低**
再現性：高	依存構造が分布シフト下で有効	スプリアスな依存の忠実な複製
再現性：低	構造制約の過剰、または容量不足	再現も保存も不成立

この分類は確率的な判定ではなく、観測された分布の範囲での実験的な位置づけである。不変性が高いことは依存の因果的正当性を保証しないが、検証した分布シフトの範囲で依存が有効に機能していることの証拠となる。

3.3 Reasoned Model の実装：Soft MoET

本研究では Reasoned model として Soft Mixture of Expert Trees（MoET; Vasic et al., 2019）を用いる。MoET はソフトゲーティング機構（PyTorch 線形層 + softmax）と K 本の決定木（scikit-learn DecisionTreeClassifier、最大深さ d）から構成される。ゲーティングパラメータは Intuitive policy の行動を教師信号とした交差エントロピーで最適化し、決定木はゲート重みで重み付けされたサンプルで EM 風に繰り返し更新する。MoET を採用する理由は、専門家数 K と深さ d の組み合わせによって構造制約の強さを連続的に変化させられ、再現性の構造的上限を実験的に観察しやすいためである。

3.4 学習手順

Reasoned model の学習は二段階で行う。まず、Intuitive policy を強化学習（DQN; Mnih et al., 2015）で学習する。次に、Intuitive policy を固定し、そのロールアウトから収集した (s, a) ペアを教師信号として Reasoned model を蒸留する。蒸留データと評価データは独立したシードで収集し、蒸留の記憶ではなく再現の汎化を測る。

4. 実験

4.1 実験の目的と設計

実験は定義の三つの側面を実証するために設計した。第一に、構造制約の強さが再現性に構造的な上限を課すことを示す（実験1）。第二に、再現性が高くとも不変性が低いケースを生成し、二軸定義の必要性を示す（実験2）。第三に、再現性と不変性がともに高い状態を、異なる種類の分布シフトで複数回示す（実験3）。各実験は乱数シード 42, 123, 456 の3シードで実行し、平均±標準偏差を報告する。

4.2 実験1：CartPole ノイズ拡張

標準的な CartPole-v1 の状態（4次元）に独立なガウスノイズを $N \in 0, 4, 8, 16$ 次元追加した拡張状態で DQN を学習する。Reasoned model には MoET を用い、専門家数 $K \in 2, 3, 4$、深さ $d \in 1, 2, 3, 4, 5$ の全組み合わせを評価する。この実験はスプリアス依存を扱わず、構造制約が厳しくなるにつれて再現性がどこで頭打ちになるかを観察する基準実験である。

4.3 実験2：Spurious GridWorld

エージェントの位置 (x, y) とスプリアス変数 c を状態とし、ゴール位置を直接観測しない GridWorld 環境を設計する。c は確率 p でゴールの方向を正しく示し、$1 - p$ でランダムな値を取る。$p = 0$ の場合、c は決定論的にゴールを指すが、分布シフトとして c を反転させると方策は完全に失敗する。評価条件は訓練分布（train）、c をランダム化した条件（random_c）、c を反転した条件（reversed_c）の3種類である。

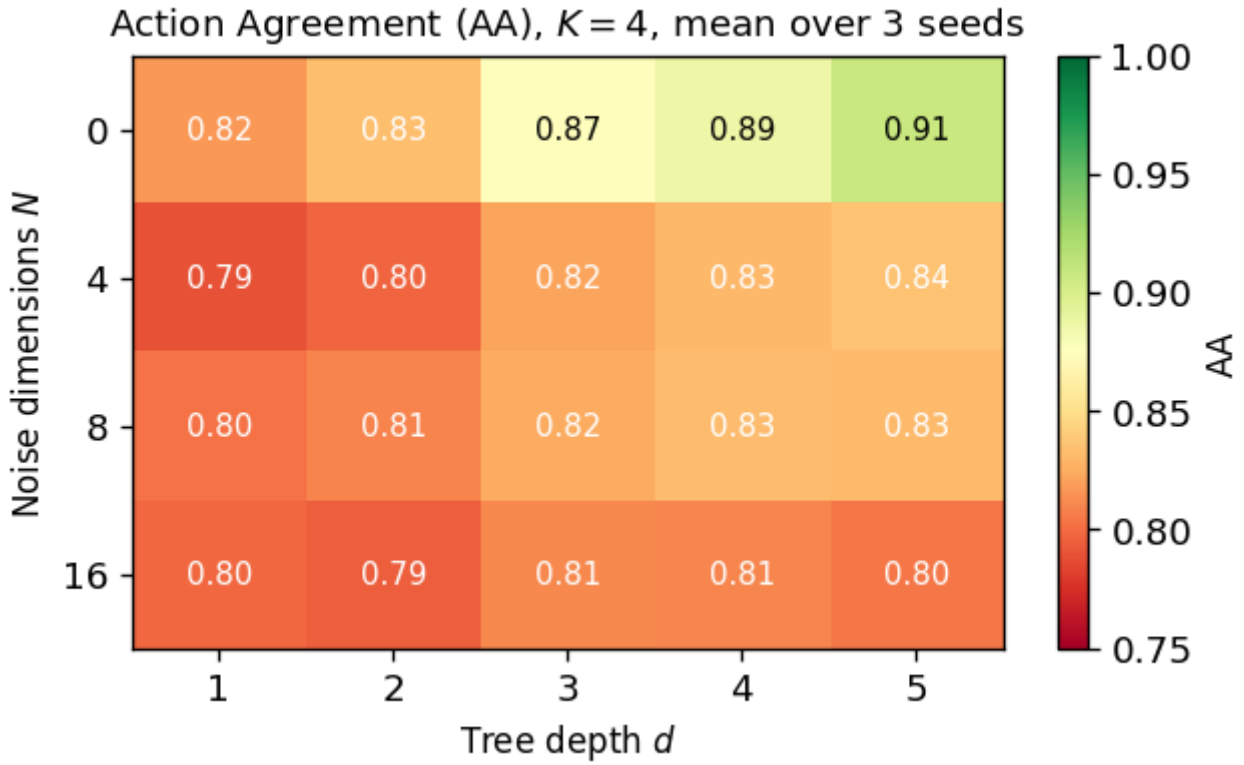
4.4 実験3：CartPole 物理パラメータシフト

スプリアス特徴を含まない CartPole（$N = 0$）を対象とし、訓練後に物理パラメータを変えることで分布シフトを与える。重力 $g \in 9.8, 5.0, 20.0$ とポール半長 $\ell \in 0.5, 0.25, 1.0$ を独立に変化させた5条件（train, gravity_lo, gravity_hi, pole_short, pole_long）で評価し、異なる種類の分布シフトに対して不変性が再現されるかを確認する。Intuitive policy は実験1の $N = 0$ 学習済みモデルを再利用し、Reasoned model には最良設定の MoET（$K = 4$, $d = 5$）を用いた。

5. 実験結果

5.1 実験1：再現性の構造的上限

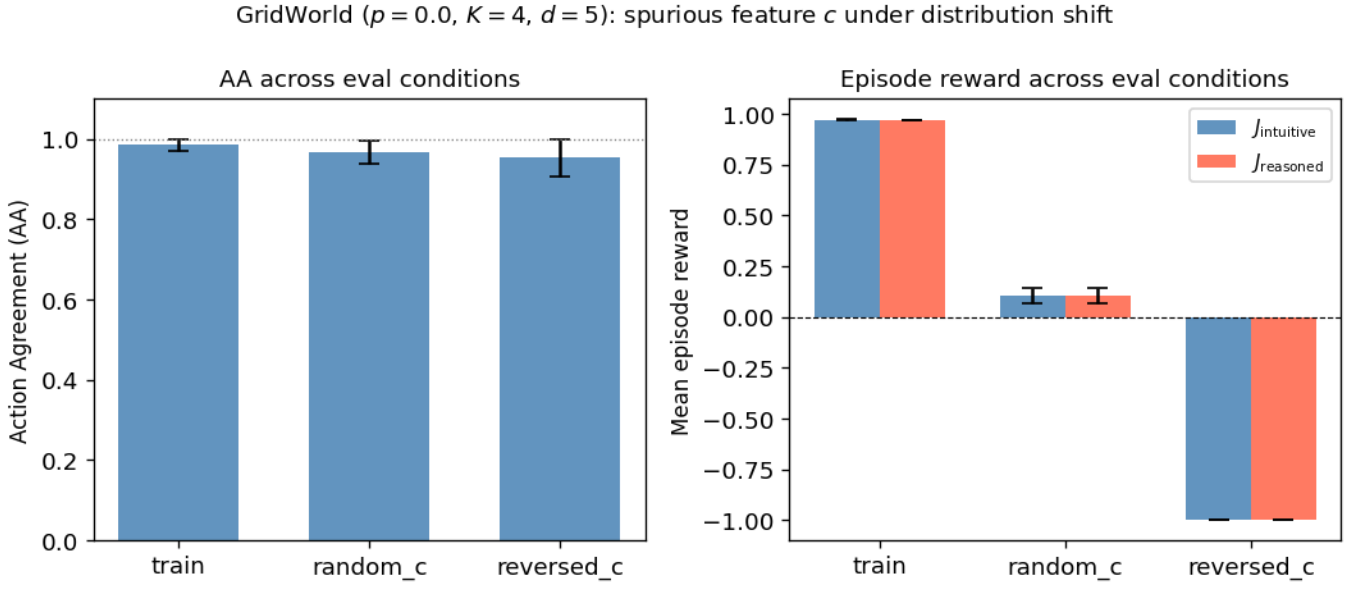
CartPole にノイズ次元を追加すると、MoET の再現性は深さに応じて改善するが、ノイズが増えるほど上限が下がる。Figure 1 が示すように、$N = 0$ では深さ $d = 5$ で AA が 0.91 に達する一方、$N = 16$ では同じ深さでも AA は 0.80 にとどまる。この結果は、方策の説明可能性が Reasoned model の構造だけでなく、入力空間の複雑さにも規定されることを示す。CartPole は天井効果により RPD が不安定なため、本実験の主要な指標は AA とする。



5.2 実験2：再現性高・不変性低の実証

GridWorld の $p = 0$ 条件では、訓練分布上で Intuitive policy と Reasoned model の両者が高い AA（最良設定で 0.985）を達成し、累積報酬もほぼ一致する。ところが、c を反転した reversed_c 条件では、AA=0.954 と高い行動一致率を維持したまま、$J_{\text{intuitive}} = J_{\text{reasoned}} = -1.000$ まで崩壊する（Figure 2）。これが定義における「再現性高・不変性低」の状態であり、Reasoned model が Intuitive policy のスプリアスな依存をそのまま複製した結果として解釈される。

SHAP（KernelExplainer）を同一の Intuitive policy に適用した場合、スプリアス特徴 c の重要度は train と reversed_c の両条件でほぼ同値（Mean $|\text{SHAP}|$ = 0.0181）となる（Figure 4）。SHAP は「方策が c に依存している」という事実を捉えるが、その依存が分布シフト後に無効化される事実は示せない。本研究の枠組みは、この隙間を不変性の評価によって補う。



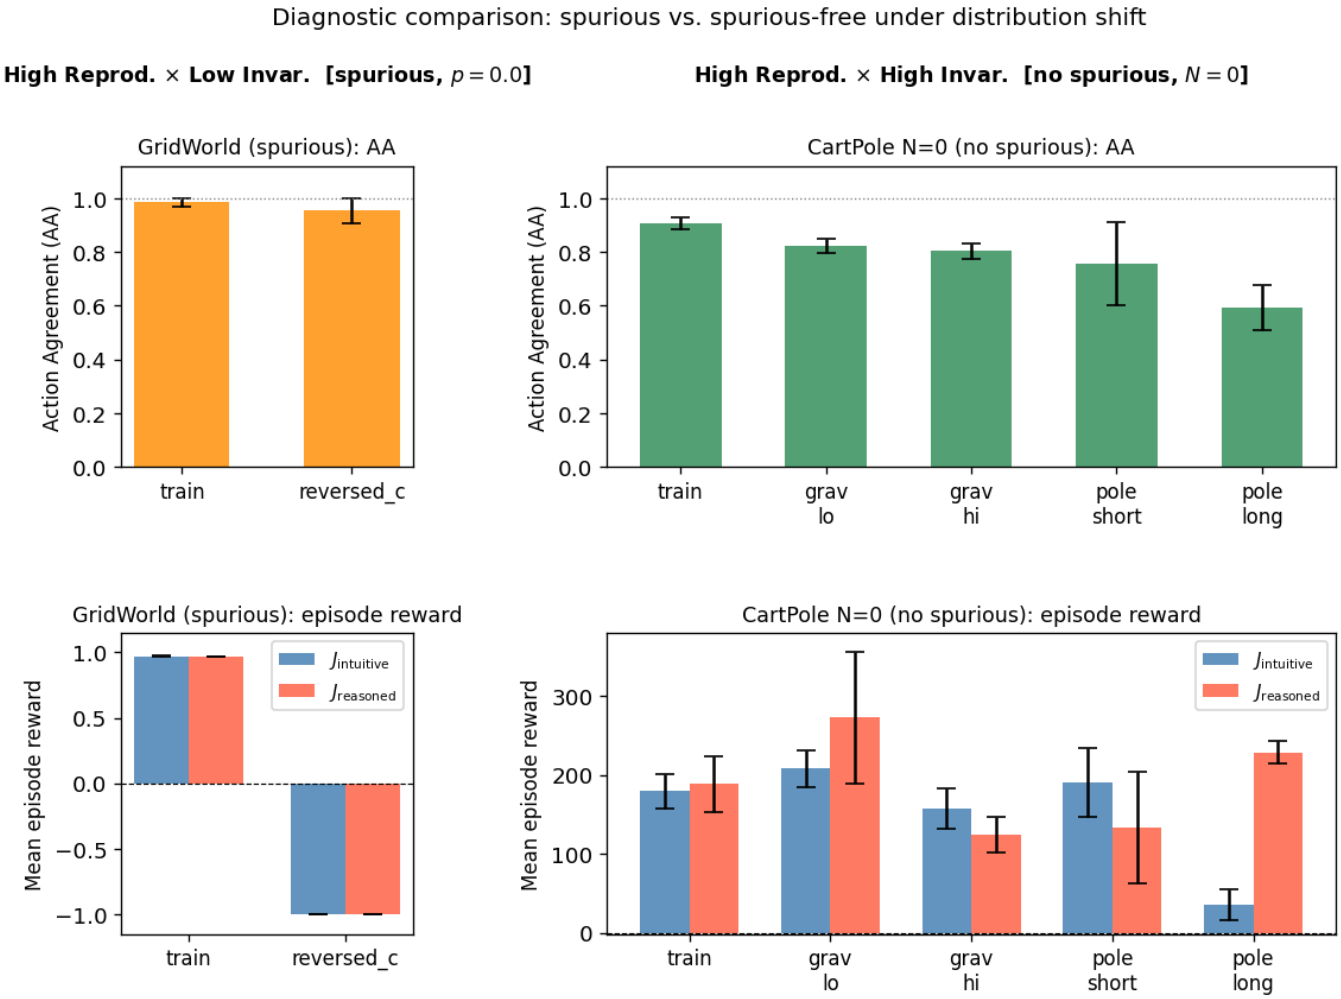
5.3 実験3：再現性高・不変性高の実証

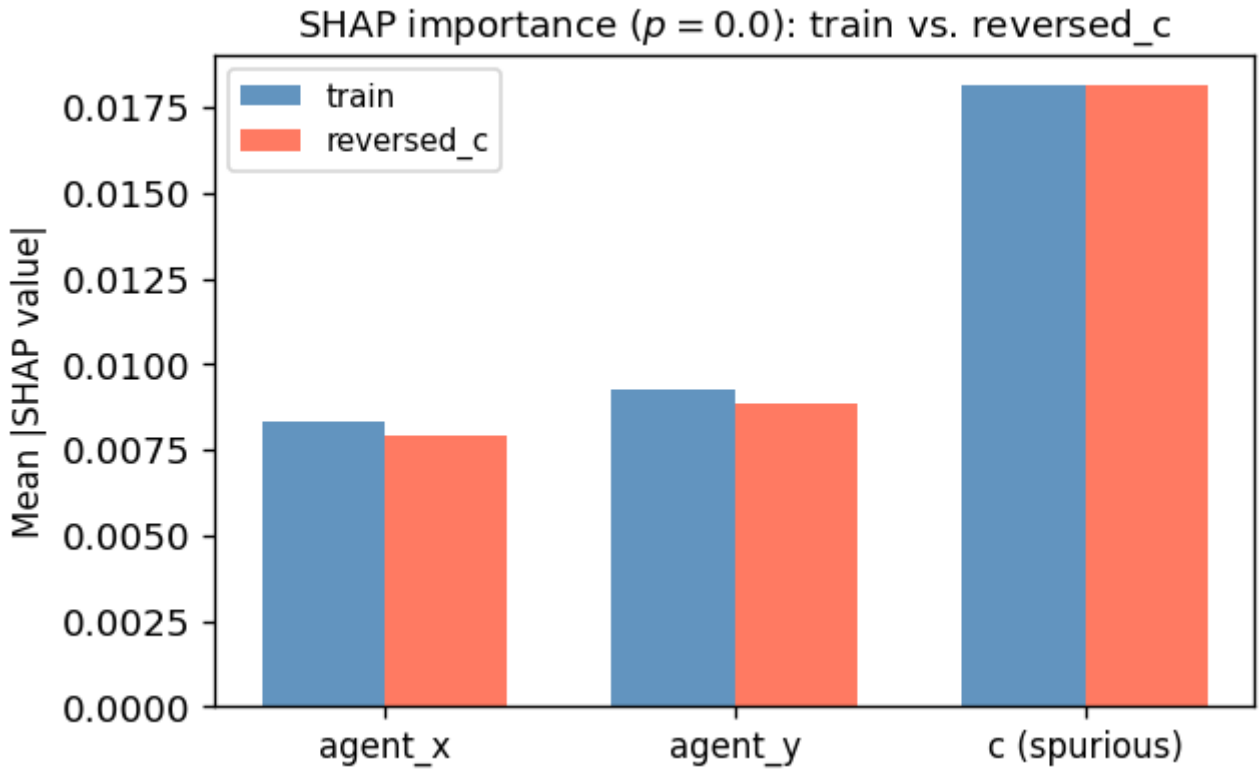
スプリアス特徴を含まない環境での物理パラメータシフトは、定義の「再現性高・不変性高」状態を実証する機会を与える。結果を Table 1 に示す（3シード平均±標準偏差）。

評価条件	**AA**	$J_{\text{intuitive}}$	J_{reasoned}	**RPD**
train ($g = 9.8$, $\ell = 0.5$)	0.907±0.021	179.6	188.3	−0.048±0.152
gravity_lo ($g = 5.0$, $\ell = 0.5$)	0.822±0.026	208.2	272.4	−0.305±0.367
gravity_hi ($g = 20.0$, $\ell = 0.5$)	0.804±0.029	158.1	124.2	+0.207±0.159
pole_short ($g = 9.8$, $\ell = 0.25$)	0.757±0.153	190.3	133.5	+0.301±0.359
pole_long ($g = 9.8$, $\ell = 1.0$)	0.594±0.085	35.3	228.8	−7.955±6.786

重力シフト（gravity_lo, gravity_hi）とポール短縮（pole_short）の3条件では、AA は 0.76〜0.82 を維持し、$J_{\text{intuitive}}$ と J_{reasoned} はともに正常範囲に留まる。実験2の reversed_c 条件（$J = -1.000$）と比較して、J の振る舞いは対照的であり、スプリアス依存による崩壊は見られない。この対比を Figure 3 に示す。重力とポール長という異なる種類の物理パラメータシフトで同じ傾向が確認されたことは、高不変性が重力シフト固有の偶然でないことを示している。

ポール延長（pole_long, $\ell = 1.0$）は異なる様相を示す。AA が 0.59 まで低下し、$J_{\text{intuitive}} = 35.3$ に対して $J_{\text{reasoned}} = 228.8$ という大きな乖離が生じる。これは Intuitive policy 自体が訓練時の2倍の長さのポールに対処できず機能不全に陥ったためであり、スプリアス依存の崩壊とは性質が異なる。Intuitive policy が OOD で動作しなくなった分布では AA の解釈が困難になるという枠組みの限界を示すケースとして、Section 6 で議論する。


Diagnostic comparison: spurious vs. spurious-free under distribution shift
High Reprod. × Low Invar. [spurious, $p = 0.0$]
High Reprod. × High Invar. [no spurious, $N = 0$]
GridWorld (spurious): AA
CartPole N=0 (no spurious): AA
Action Agreement (AA)
train
reversed_c
grav lo
grav hi
pole short
pole long
GridWorld (spurious): episode reward
CartPole N=0 (no spurious): episode reward
Mean episode reward
$J_{intuitive}$
$J_{reasoned}$


SHAP importance ($p = 0.0$): train vs. reversed_c
Mean |SHAP value|
train
reversed_c
agent_x
agent_y
c (spurious)

6. 議論

本研究が提案する定義の中心的な主張は、再現性が説明可能性の必要条件であるが十分条件ではないという点にある。実験2が示した通り、Reasoned model の高い行動一致率は、それが元の方策の正しい依存構造を捉えていることを保証しない。スプリアス相関が存在する場合、Reasoned model は Intuitive policy の誤った依存をそのまま複製し、訓練分布では高い AA を示しながら分布シフト下で両者ともに失敗する。不変性の評価を加えることで初めて、このケースを「再現性高・不変性低」として実験2の数値から明示的に識別できる。

実験3の結果は、定義の反対側の状態──「再現性高・不変性高」──が実験的に観察可能であることを示す。スプリアスのない CartPole では、訓練とは異なる重力とポール長の下でも AA が 0.76〜0.82 を維持し、両者の J が正常範囲に留まった。これは、Reasoned model が Intuitive policy の依存構造を正しく写し取っており、その依存が物理パラメータの変化に対して実際に有効であることを示唆する。

ただし、pole_long の結果は枠組みの適用限界を明確にする。Intuitive policy 自体が OOD で機能しなくなった分布では、AA の低下が「Reasoned model の不変性の欠如」を意味するのか、「Intuitive policy の失敗に伴う必然的な乖離」を意味するのかを本枠組みは区別しない。このため、不変性の評価は、Intuitive policy が評価分布上でも最低限の性能を維持している条件に限定して解釈するのが妥当である。本枠組みはいずれにせよ、観察された分布の範囲での一致性を測るものであり、因果的な正当性の証明を意図しない。

SHAP との比較が示す含意も重要である。SHAP は「現在の方策がどの特徴に依存しているか」を訓練分布内で明確に示す点で有用だが、その依存が環境の変化に対して維持されるかどうかは問えない。本研究の不変性の評価は SHAP を置き換えるものではなく、SHAP だけでは見えない情報──依存の有効性──を補完的に提供するものとして位置づけられる。

7. 限界

本研究の枠組みには四つの具体的な限界がある。第一に、実験は CartPole と GridWorld という小規模な離散制御環境に限定されており、高次元観測空間や連続行動空間への適用可能性は未確認である。第二に、各条件の統計的信頼性は乱数シード3本に基づいており、特に分散の大きい pole_short 条件（AA の標準偏差 0.153）では追加シードによる検証が望ましい。第三に、本枠組みは Intuitive policy が評価分布上でも動作することを前提とし、Intuitive policy 自体が OOD で破綻した場合（pole_long がその例）には不変性の解釈が困難になる。第四に、分布シフトの選択（重力・ポール長・c の反転）が恣意的であり、どのようなシフトを用いるかが不変性の評価結果に影響しうる。

8. 結論

本研究は、強化学習方策の説明可能性を「構造制約付きモデルによる再現性」と「分布シフト下での不変性」の二軸で定義する枠組みを提案した。三つの実験を通じて、再現性が高くとも不変性が低いケース（スプリアス依存の複製）と、再現性・不変性がともに高いケース（依存の有効性が複数の分布シフトで確認される）の対比を数値的に示した。この定義は外部ラベルを必要とせず、既存の蒸留ベースの説明手法に分布シフト下での評価を追加することで実施できる。

今後の課題として、連続制御や高次元観測を持つ環境への拡張、統計的信頼性を高めるためのシード数の増加、および分布シフトの選択基準の形式化が挙げられる。より長期的には、本枠組みを基盤として、Reasoned model の構造から規則列や自然言語説明を生成し、それが不変性とどう対応するかを検討することが、説明可能性の実用化に向けた次のステップとなる。

[^1]: Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. NeurIPS.

[^2]: Vasic, M., et al. (2019). MoET: Interpretable and verifiable reinforcement learning via mixture of expert trees. AAAI.

[^3]: Arjovsky, M., et al. (2019). Invariant risk minimization. arXiv:1907.02893.

[^4]: Ribeiro, M. T., et al. (2016). "Why should I trust you?": Explaining the predictions of any classifier. KDD.

[^5]: Koh, P. W., et al. (2020). Concept bottleneck models. ICML.