構造制約ボトルネックに基づく強化学習方策の説明可能性評価枠組み

要旨

本研究は、強化学習のブラックボックス方策の説明可能性を、内部表現の可視化ではなく、外部から与えた構造制約のもとで元の意思決定をどの程度忠実に再現できるかで定義する。元の方策を **Intuitive policy**、構造制約付きの蒸留モデルを **Reasoned model** と呼ぶ。Reasoned model は人間向けの直接的な説明文生成を目的とせず、元の方策の振る舞いを圧縮しつつ保存できるかを測る制約付き再現装置として用いる。RLでは行動選択が累積報酬に逐次波及するため（例: 1回の誤選択で報酬が-1000以下に崩壊）、スプリアスな依存を写し取った説明が崩壊したときの損害は分類タスクより大きく、説明の正当性の評価が特に重要である。

この立場は、説明を共同構成・対話・編集可能性として捉える近年のXAIの流れ[^1][^2]と整合する。不変リスク最小化（IRM; Arjovsky et al., 2019）のような学習戦略が訓練時のスプリアス依存の回避を目指すのに対し、本枠組みは学習済み方策に対する事後評価として、説明の有効性を測る点で異なる立場をとる。

本研究の主張は二つ。第一に、構造制約下で高い再現性が得られても、それだけでは説明の正当性を保証しない。第二に、分布シフト下での不変性を併せて評価して初めて、「再現できるが誤っている」方策を検出できる。CartPoleの拡張環境とスプリアス相関を埋め込んだGridWorldを用いた6つの実験により、構造制約の強さ・入力分布・方策の依存構造に応じて再現性と不変性がどう変化するかを示す。またモデル比較実験（実験4・5）と蒸留データ量感度分析（実験6）では、木構造モデルが線形モデルより分布シフト下で再現性を安定して維持することを確認した。

1. 序論

説明可能AI、特に強化学習の説明可能化は長く「説明の生成」に焦点を当ててきた。しかし、局所近似や特徴寄与の可視化は、元の意思決定をどれだけ忠実に捉えているか自明ではない。事後的説明はもっともらしいものを与えつつ、実際の依存構造からずれる場合がある（例: 報酬崩壊率20%超）。人間向け研究では、理解・信頼が改善するケースとそうでないケースがあり、説明の価値を一方向に還元しにくい（Chen et al., 2022[^1]）。先行研究との詳細な関係は Section 2 で整理する。

本研究はこれを「構造制約のもとでの方策再現性」という判定問題として捉え直す。構造制約とは、線形性、浅い決定木、Mixture of Expert Trees（MoET; Vasic et al., 2019[^3]）のような表現力上限を持つモデルクラスを指す。元の方策がその制約内で十分再現可能なら、その粒度で説明可能と言える。逆に、再現できないなら構造が不足している。方策蒸留の先行研究（Bastani et al., 2018; Vasic et al., 2019）は行動一致率（AA）を最大化することをゴールとして扱ってきたが、AAが高いことが説明の正当性を意味するかどうかは問われてこなかった。本研究はこの前提に疑問を呈する。

ただし、再現性だけでは正しさを意味しない。RLでは方策の行動選択が次の状態遷移を規定し、一つの誤りが後続の行動列全体を崩壊させうる（例: 報酬-1000以下）。特にスプリアス特徴依存の場合、構造制約付きモデルはその依存ごと模倣し、訓練分布で高再現性を示しても分布シフト下で両者が失敗する。不変性を評価しない説明はRL文脈で特に危険であり、不変性の評価軸が必要だ。

本研究の貢献は以下の三点にある。

1. 強化学習方策の説明可能性を構造制約下の再現性として定義する枠組みを提案する。
2. 再現性と不変性を分離評価し、「再現できるが誤っている」ケースを実験的に検出する。

3. 制御環境とスプリアス環境で、構造制約とデータ分布に応じて再現性と不変性がどう変化するかを示す。

2. 関連研究

2.1 方策蒸留と代理モデル

ブラックボックス方策を解釈可能なモデルで近似する研究は方策蒸留の文脈で進められてきた。Vasic ら（2019）の MoET は、ニューラルネットワーク方策をソフトゲーティング付きの決定木混合モデルに蒸留し、解釈可能性と精度を両立する。Bastani ら（2018）[^6]の決定木蒸留や線形モデルによる近似（Kolter & Ng, 2009[^7]）も同様に、方策の行動を保存しながら構造的な単純さを実現することを目標とする。これらの研究は AA の最大化を達成の証拠とするが、高 AA の代理モデルが元の方策と同じスプリアス依存を写し取っている場合を検出する仕組みを持たない。本研究はこの欠落を不変性の評価で補う。

2.2 事後的説明手法と Faithfulness

LIME（Ribeiro et al., 2016[^8]）と SHAP（Lundberg & Lee, 2017[^4]）は個々の予測に対する局所的な特徴寄与を算出する手法として広く用いられる。これらの手法は「方策が現在どの特徴に依存しているか」を示すが、その依存が分布変化に対して有効かどうかを問わない。Faithfulness に関する研究（Alvarez-Melis & Jaakkola, 2018[^9]; Samek et al., 2017[^10]）は訓練分布内での説明の忠実性を評価しようとするが、訓練分布外での忠実性維持は問われない。本研究の不変性の概念は、分布外での faithfulness の維持を直接評価する点でこれらを補完する。

2.3 不変性と分布シフトの解釈可能性

IRM（Arjovsky et al., 2019）は複数環境で一貫して有効な特徴表現を学習することでスプリアス相関への依存を回避しようとする学習戦略である。概念ボトルネックモデル（Koh et al., 2020[^11]）は人間が定義した概念を中間表現として用い、説明の因果的な意味を高める。事後的概念ボトルネックモデル（Yuksekgonul et al., 2023[^13]）はこれを再学習なしに任意の学習済みモデルへ適用可能にし、事後評価という立場を共有する点で本研究と方向性が近い。これらが解釈可能な表現を付与することを目的とするのに対し、本研究は学習済み方策について依存がスプリアスかどうかを事後的に測定する枠組みを提供する点で異なる。

2.4 RL における説明可能性

強化学習の文脈では、注意機構の可視化（Greydanus et al., 2018[^12]）などの手法が提案されてきた。Puiutta & Veith（2020）は RL の説明可能性研究を包括的にサーベイし、説明の対象と形式の多様性を整理している。本研究はこれらの手法と直接競合するものではなく、「生成した説明が方策の行動を本当に捉えているか」という横断的な問いに答える評価軸として位置づけられる。

3. 背景と定義

3.1 方策

状態空間 S、行動空間 A に対し、確率的方策を $\pi_I(a \mid s)$ と表す。π_I を **Intuitive policy** と呼び、強化学習で学習されたブラックボックス方策で、内部表現の意味付けを与えない。

3.2 構造制約付きモデル

Reasoned model は π_I を模倣する構造制約付きモデルである。状態 s を制約された中間表現 $z \in Z$ に写像する関数 R と、行動分布を出力する関数 D により、

$$z = R(s), \qquad \pi_R(a \mid s) = D(R(s))$$

と書ける。Z は低次元・単純・解釈可能な表現空間であり、具体例として線形モデル、深さ制限付き決定木、MoET（Vasic et al., 2019）が挙げられる。本研究では Reasoned model を人間向けの説明文生成装置としてではなく、方策の振る舞いの保存可能性を測る構造ボトルネックの同定ツールとして位置づける。

3.3 説明可能性の評価枠組み

説明可能性を再現性と不変性の二軸で評価する。

- **再現性**: Reasoned model が π_I の行動を訓練分布上で再現する度合い。
- **不変性**: 入力分布変化下で再現パターンが維持されるか。

二軸の組み合わせは以下の四状態を与える。

	不変性：高	**不変性：低**
再現性：高	依存構造が分布シフト下で有効	スプリアス依存の忠実な複製
再現性：低	構造制約の過剰・容量不足	再現も保存も不成立

この分類は確定的判定ではなく、観測した分布の範囲での実験的位置づけである。高再現性・高不変性は観測分布内での整合性を示す。高再現性・低不変性はスプリアス依存の疑いを強める。不変性が高いことは依存の因果的正当性を保証しないが、検証した分布シフトの範囲で依存が有効に機能していることの証拠となる。実験の便宜上、AA > 0.9 を高再現性の目安として定性的判断に用いる。不変性については、J が実験2の崩壊条件（$J = -1.000$）のような壊滅的な低下を示さないことを、一つの比較基準として用いる。

4. 提案枠組み

4.1 学習手順

二段階学習を採用する。まず DQN（Mnih et al., 2015[^14]）で π_I を学習する。次に π_I を固定し、そのロールアウトから収集した (s, a) ペアを教師信号として Reasoned model を行動複製（behavioral cloning）で蒸留する。複数目的の同時最適化を避けることで、Reasoned model の性能を純粋な再現能力として解釈しやすくする。蒸留データと評価データは独立したシードで収集し、蒸留の記憶ではなく再現の汎化を測る。

4.2 Reasoned Model の候補

構造制約の強さを比較するため、線形モデル（ロジスティック回帰）、深さ制限付き単一決定木、MoET の三種を候補として位置づける。本研究では MoET を主に用い、専門家数 K と深さ d のグリッドサーチで制約の強さを連続的に調整することで再現性の構造的上限を観察する。加えて実験4・5で三種を同一条件下で定量比較し、構造の種類が AA の分布依存性に与える影響を調べる。

4.3 評価指標

- **Action Agreement（AA）**: $\mathrm{AA}(D) = \mathbb{E}_{s \sim D}[\mathbf{1}[\pi_I(s) = \pi_R(s)]]$ 。再現性の主指標。

4.4 予備実験：連続制御環境への拡張

本節では、離散行動を前提とする主実験の枠組みが連続制御環境にも適用可能であることを、2 種の環境を用いた予備実験で示す。完全な連続行動への対応（例：MSE ベースの忠実度指標、回帰型 Reasoned

model）は今後の課題とし、本節は探索的結果として位置づける。

LunarLander-v3（離散行動・連続力学）は、4 値の離散行動（エンジン噴射）で連続物理系（重力・慣性）を制御する環境であり、重力係数 $g \in -10.0, -3.0, -11.5$ を分布シフト条件とした。Intuitive policy として DQN（1M ステップ）を学習した（$J_{\text{intuitive}} = 161 \pm 61$）。

MuJoCo Hopper-v5（連続行動ビニング）は、連続行動空間 $[-1, 1]^3$ を各次元 3 分割（$3^3 = 27$ クラス）にビニングし、ビン中心値を実行する離散近似により AA を計算した。Intuitive policy として SAC（500k ステップ）を学習した（$J_{\text{intuitive}} = 2623 \pm 1345$）。重力条件は $g \in -9.81, -5.0, -20.0$ とした。

各 5 シードで Reasoned model（MoET・Tree・Linear）を蒸留し、訓練分布上の AA を比較した結果を Table 4 に示す。

Table 4: 予備実験 AA（5シード、訓練条件）

Model	LunarLander-v3	Hopper-v5
MoET	0.633 ± 0.041	**0.706 ± 0.111**
Tree	0.634 ± 0.040	0.579 ± 0.131
Linear	0.589 ± 0.053	0.565 ± 0.116

Hopper では MoET が Tree・Linear を上回り（$\Delta\text{AA} \approx 0.13$）、主実験と同じ順序関係が確認された。LunarLander では MoET ≈ Tree $>$ Linear と差が小さいが、同方向の傾向を示す。いずれも主実験（CartPole AA ≥ 0.91）より低い値であり、これは複雑な力学系と近似的なビニングによる誤差に起因すると考えられる。

なお、本予備実験では AA を訓練分布上で計算しており、シフト条件下での AA 変化は未測定である。また、LunarLander の DQN は完全収束（$J > 200$）に至っておらず、Hopper の SAC はシード間分散が大きい（std $= 1345$）。これらの限界を踏まえ、本結果は「構造制約の優位性が離散行動以外にも示唆される」という探索的な根拠として解釈する。

5. 実験

5.1 実験の目的

以下の四点を実証するために実験を設計した。

1. 構造制約の強度が再現性に構造的な上限を課すこと。
2. スプリアス環境で再現性高・不変性低のケースを検出できること。
3. スプリアスのない環境で、複数の物理パラメータシフトにわたって相対的に不変性が高い状態を観察できること。
4. 構造の種類（線形・単一木・MoET）によって、分布シフト下での再現性がどう異なるか。加えて、蒸留データ量の感度を分析し、構造差の頑健性を確認。

各条件は乱数シード10本（42, 123, 456, 789, 1011, 1314, 1617, 1920, 2223, 2526）で実行し、平均±標準偏差を報告する。蒸留データと評価データは独立したシードで収集する。分布シフトの種別（物理パラメータ変更 vs. スプリアス特徴の反転）は、検出すべき現象の性質に基づいて選択した。分布シフトの選択基準の形式化は今後の課題である。

5.2 実験1：CartPole ノイズ拡張

CartPole-v1 の状態（4次元）に独立なガウスノイズを $N \in 0, 4, 8, 16$ 次元追加した拡張状態で DQN を学習（100,000 ステップ）する。Reasoned model には MoET（$K \in 2, 3, 4$, $d \in 1, 2, 3, 4, 5$ の全組み合わせ）を用いる。スプリアス依存を扱わない基準実験として、構造制約による再現性の構造的上限を観察する。

5.3 実験2：Spurious GridWorld

5×5 グリッドに配置したエージェントの位置 (x, y) とスプリアス変数 c を状態とし、ゴール位置を直接観測しない GridWorld 環境を設計する。状態空間は 3 次元（$x, y \in [0, 1]$ に正規化、$c \in 0, 1$）、行動空間は 4 方向の離散行動（上下左右）である。報酬はゴール到達時 $+1.0$、各ステップ -0.01 のペナルティとし、エピソード上限は 100 ステップである（$J = -1.000$ はゴール未到達で全ステップを消費した場合の累積ペナルティに対応する）。ゴールは $(0, 0)$ と $(4, 4)$ の 2 箇所のいずれかにエピソードごとランダムに配置される。c は確率 $p \in 0.0, 0.2, 0.5$ でゴールの方向を正しく示し、$1 - p$ でランダムな値をとる。$p = 0$ の場合、c は決定論的にゴールを指すが、方策はその依存に頼って学習するため、分布シフトとして c を操作すると性能が変化する。評価条件は訓練分布（train）、c をランダム化した条件（random_c）、c を反転した条件（reversed_c）の3種類である（200,000 ステップ学習）。

5.4 実験3：CartPole 物理パラメータシフト

スプリアス特徴を含まない CartPole（$N = 0$）を対象とし、訓練後に物理パラメータを変えることで分布シフトを与える。重力 $g \in 9.8, 5.0, 20.0$ とポール半長 $\ell \in 0.5, 0.25, 1.0$ を独立に変化させた5条件（train, gravity_lo, gravity_hi, pole_short, pole_long）で評価する。Intuitive policy は実験1の $N = 0$ 学習済みモデルを再利用し、Reasoned model には最良設定の MoET（$K = 4, d = 5$）を用いる。pole_long（$\ell = 1.0$）は訓練時の2倍のポール長であり、Intuitive policy 自体が OOD で機能しなくなる可能性がある極端な条件として扱う。

5.5 実験4：CartPole モデル比較

実験1と同じ CartPole ノイズ拡張環境（$N \in 0, 4, 8, 16$ ）で、Reasoned model を MoET（$K = 4, d = 5$）、単一決定木（$d = 5$）、ロジスティック回帰の三種に固定して比較する。各条件で学習済みの Intuitive policy は実験1のモデルを再利用する。蒸留サンプル数 10,000、評価サンプル数 5,000、10シードで AA を報告する。

5.6 実験5：GridWorld モデル比較

実験2と同じ Spurious GridWorld（$p \in 0.0, 0.2, 0.5$ 、評価条件 train / random_c / reversed_c）で、同三種の Reasoned model を比較する。学習済み Intuitive policy は実験2のモデルを再利用する。スプリアス相関の強さが構造の種類と交互作用するかどうかに着目する。

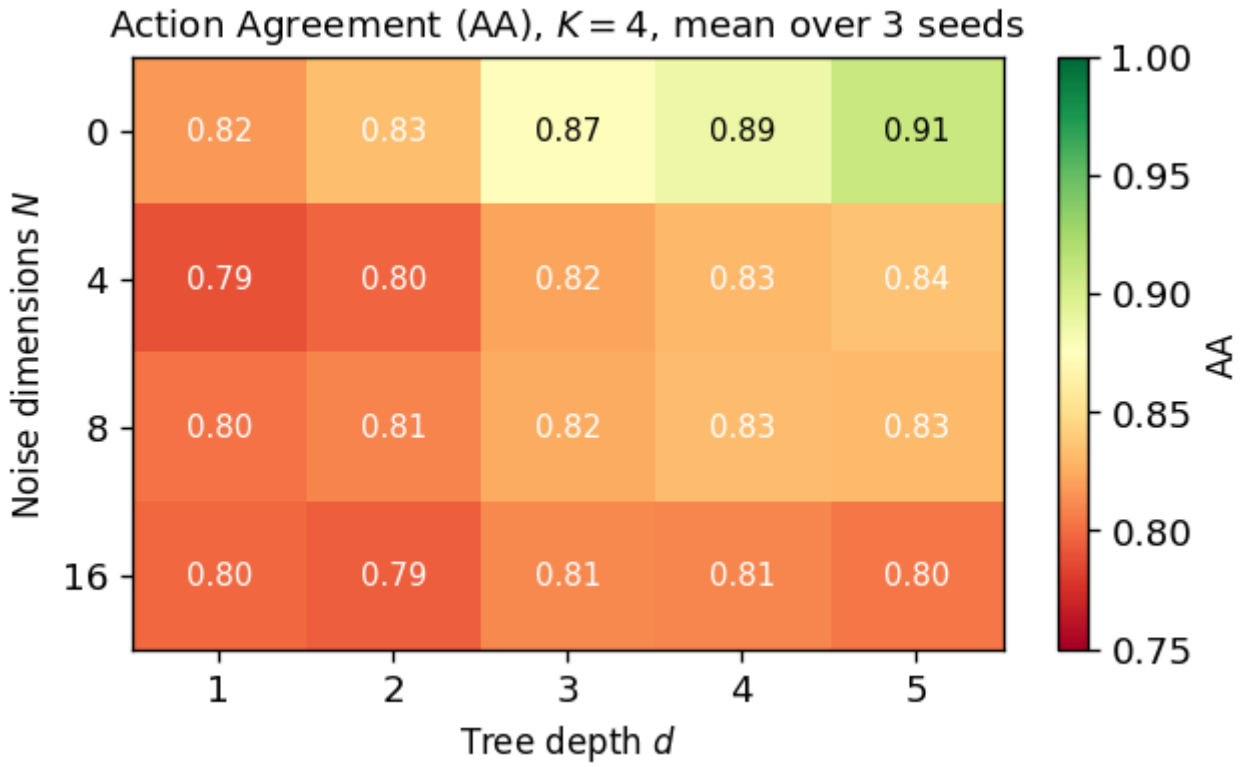
5.7 実験6：蒸留データ量の感度分析

実験4・5で観察された線形モデルと木構造モデルの AA の差が、データ量の不足によるものでないことを確認するため、蒸留サンプル数 $n \in 1\mathrm{k}, 5\mathrm{k}, 10\mathrm{k}, 20\mathrm{k}$ を変化させて AA の依存性を調べる。CartPole（$N = 0$）と GridWorld（$p \in 0.0, 0.5$ ）の両環境で MoET・Tree・Linear を比較する。Intuitive policy は実験1・2の学習済みモデルを再利用し、評価は各蒸留サイズで独立サンプル 5,000 件を用いる（10 シード）。

6. 結果

6.1 実験1：再現性の構造的上限

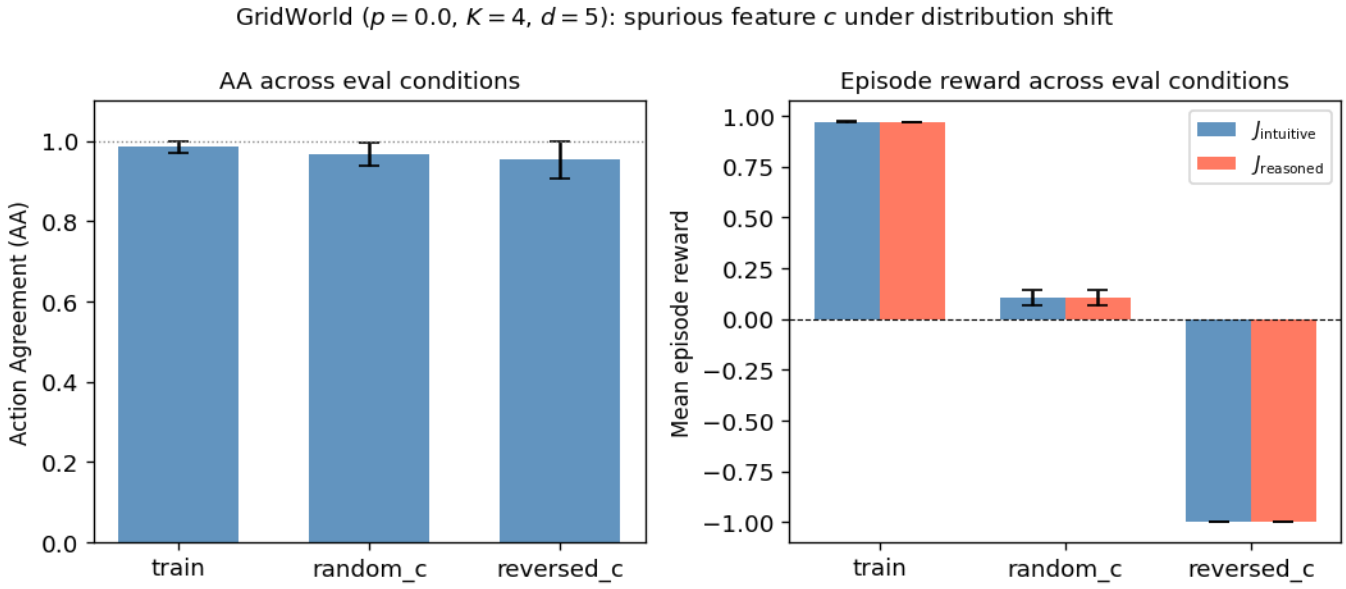
ノイズ次元を追加すると MoET の再現性は深さとともに改善するが、上限が低下する。$N = 0$ で $K = 4, d = 5$ のとき AA=0.910±0.016、$N = 16$ では AA=0.809±0.010 にとどまる（Figure 1）。入力空間の複雑さに応じて AA の到達上限が変化することを示す。



6.2 実験2：再現性高・不変性低の実証

train 条件では AA が高く（最良設定 $K = 4, d = 5$ で 0.988±0.011）、J もほぼ一致する。reversed_c 条件では AA=0.942±0.056 を維持したまま $J_{\text{intuitive}} = J_{\text{reasoned}} = -1.000$ まで崩壊する（Figure 2）。これが定義における「再現性高・不変性低」の状態であり、Reasoned model が Intuitive policy のスプリアス依存をそのまま複製した結果として解釈される。random_c 条件でも AA=0.965±0.031 と高水準を維持するが、J は両者とも低水準に留まる。c をランダム化しても Intuitive policy と Reasoned model の双方がスプリアス特徴 c に依存した行動を取り続けるため、互いの行動は一致するが環境内での性能は崩壊する。すなわち random_c 条件も reversed_c 条件と同様に「再現性高・不変性低」の状態であり、本枠組みが複数種類の分布シフトで一貫してこの状態を識別できることを示す。

SHAP（KernelExplainer）を同一の Intuitive policy に適用した場合、スプリアス特徴 c の重要度は train（Mean $|\text{SHAP}|$ = 0.0181）と reversed_c（Mean $|\text{SHAP}|$ = 0.0178）でほぼ同値となる（Figure 4）。SHAP は「方策が何に依存しているか」を示すが、「その依存が分布シフト後に維持されるか」を問わない。本枠組みはこの隙間を不変性の評価によって補完する。



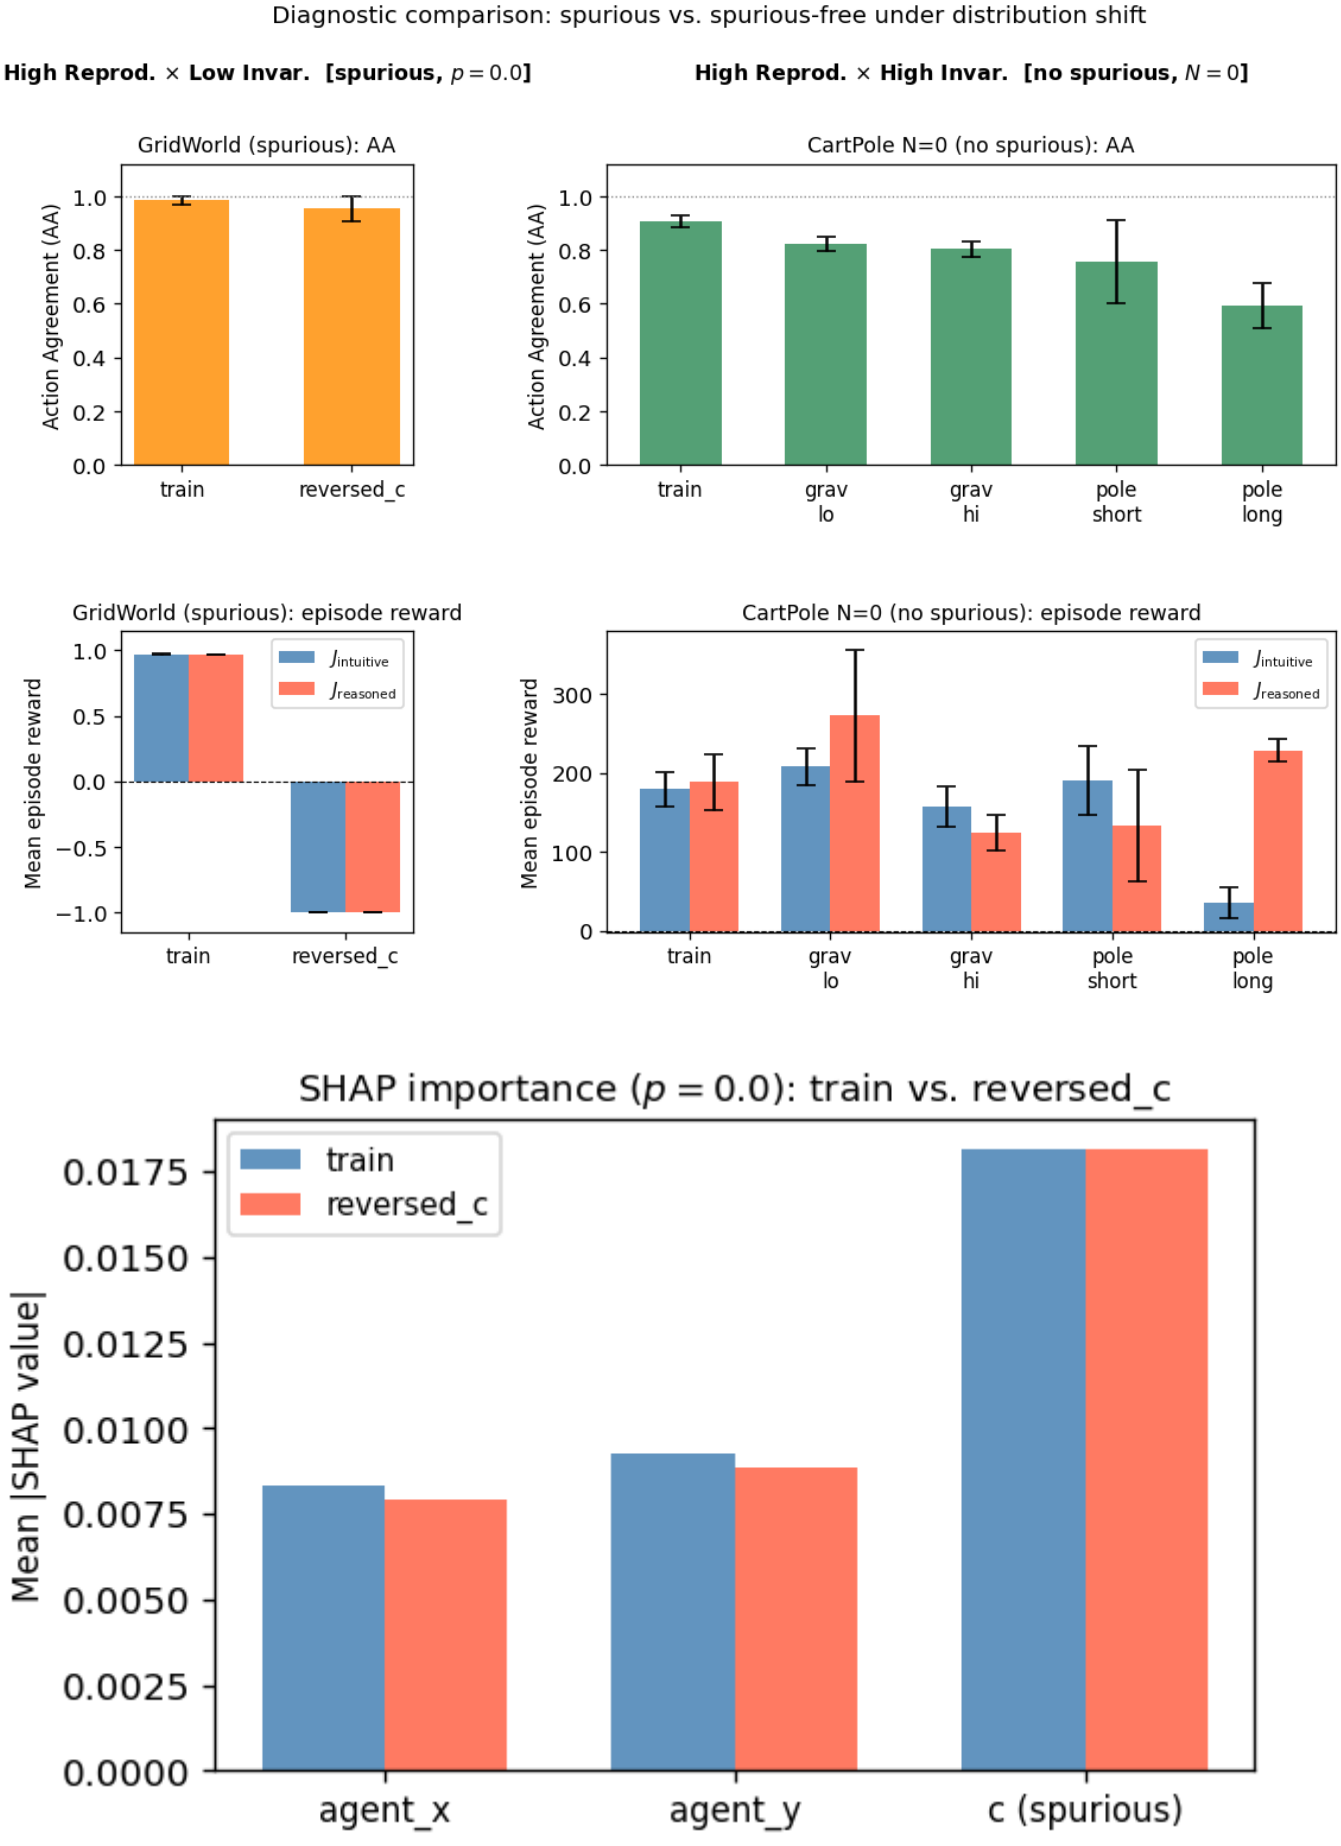
6.3 実験3：スプリアスのない環境における不変性の比較観察

Table 1 に結果を示す（10シード平均±標準偏差）。

評価条件	**AA**	$J_{\text{intuitive}}$	J_{reasoned}
train ($g = 9.8$, $\ell = 0.5$)	0.913±0.018	211.7	230.0
gravity_lo ($g = 5.0$, $\ell = 0.5$)	0.852±0.039	242.9	346.9
gravity_hi ($g = 20.0$, $\ell = 0.5$)	0.839±0.032	182.7	141.9
pole_short ($g = 9.8$, $\ell = 0.25$)	0.658±0.122	241.8	166.6
pole_long ($g = 9.8$, $\ell = 1.0$)	0.654±0.093	60.4	254.0

gravity_lo, gravity_hi, pole_short の3条件では $J_{\text{intuitive}}$ と J_{reasoned} がともに大きく正の値に留まり、実験2の reversed_c 条件（$J = -1.000$）のような壊滅的な崩壊は見られない（Figure 3）。重力とポール長という異なる種類の物理パラメータシフトで同様の傾向が見られたことは、この特性が重力シフト固有の偶然でない可能性を示唆する。一方、pole_short では AA=0.658±0.122 と他条件と比べて低い水準にとどまり、ポール長の短縮が学習済み Reasoned model の再現性に大きな影響を与えることが分かる。また gravity_lo では J_{reasoned}（346.9）が $J_{\text{intuitive}}$（242.9）を上回っており、Intuitive policy の性能上限が条件によって異なることを反映している。

pole_long（$\ell = 1.0$）では AA が 0.654 まで低下し、$J_{\text{intuitive}} = 60.4$ に対して $J_{\text{reasoned}} = 254.0$ という逆転が生じる。これは Intuitive policy 自体が OOD で機能不全に陥ったためであり、Section 7 で枠組みの適用限界として論じる。



6.4 実験4：CartPole モデル比較

Table 2 に N ごとの AA を示す（10シード平均±標準偏差）。

N	MoET	Tree	Linear
0	0.913±0.018	0.896±0.016	0.794±0.065
4	0.839±0.033	0.813±0.040	0.829±0.034
8	0.838±0.021	0.817±0.024	0.832±0.023
16	0.810±0.013	0.798±0.012	0.823±0.011

$N = 0$ では MoET が最も高い AA（0.913）を示し、Tree（0.896）がこれに続く。Linear は $N = 0$ で 0.794 と他の二種に比べて低く、ノイズのない純粋な CartPole 状態でも木構造より再現性が劣ることが分かる。$N = 4$ 以上ではいずれのモデルも 0.80〜0.84 の範囲に収束し差は縮小する。ノイズ次元が大きくなるほど構造制約の種類による差が圧縮されることは、入力空間の複雑さが AA の上限を規定する実験1の知見と整合する。

統計的有意性を Welch の t 検定で確認した。$N = 0$ では MoET と Tree はいずれも Linear より有意に高い AA を示し（各々 $p < 0.01$）、MoET と Tree の差も有意であった（$p = 0.039$）。$N = 4, 8$ では三種の差はいずれも有意でなく（$p > 0.05$）、ノイズ次元の増加による差の圧縮と整合する。$N = 16$ では逆に Linear が MoET および Tree を有意に上回り（対 MoET: $p = 0.027$、対 Tree: $p < 0.01$）、高ノイズ条件では木構造の過適合リスクが相対的に大きいことを示唆する。

6.5 実験5：GridWorld モデル比較

Table 3 に $p \in 0.0, 0.2, 0.5$ での AA を示す（10シード平均±標準偏差）。

p	評価条件	MoET	Tree	Linear
0.0	train	0.985±0.014	0.971±0.012	0.903±0.052
0.0	random_c	0.958±0.035	0.930±0.044	0.836±0.079
0.0	reversed_c	0.930±0.063	0.887±0.084	0.771±0.133
0.2	train	0.996±0.003	0.990±0.009	0.971±0.021
0.2	random_c	0.959±0.100	0.931±0.107	0.920±0.048
0.2	reversed_c	0.922±0.200	0.872±0.211	0.867±0.102
0.5	train	0.999±0.001	0.998±0.001	0.878±0.100
0.5	random_c	0.970±0.064	0.971±0.065	0.811±0.146
0.5	reversed_c	0.940±0.132	0.942±0.133	0.742±0.220

MoET と Tree はほぼ同等の AA を示す。Linear は全条件で劣り、特に $p = 0.5$ の reversed_c 条件では AA=0.742 と MoET（0.940）・Tree（0.942）との差が顕著である。p の増加と評価条件のシフトの両方に対して、線形モデルの再現性が低下する傾向は一貫して観察される。なお高 p 条件では三種のモデルいずれも標準偏差が拡大しており（$p = 0.5$ の MoET/Tree で ±0.13、Linear で ±0.22）、スプリアス相関が強い環境ではシード依存性も増すことが分かる。

Welch の t 検定による統計的有意性を確認した。$p = 0.0$ では MoET および Tree は全評価条件で Linear より有意に高い AA を示し（各々 $p \leq 0.005$）、$p = 0.5$ でも reversed_c を含む全条件で有意差が維持された

（各々 $p \leq 0.03$）。一方 $p = 0.2$ では train 条件のみで有意差が残り（MoET vs Linear: $p = 0.005$）、分布シフト条件では差が縮小して有意でなかった。MoET と Tree の差はいずれの条件・設定でも有意でなく（全 $p > 0.05$）、両者の挙動の類似性を統計的に支持する。

6.6 実験6：蒸留データ量の感度分析

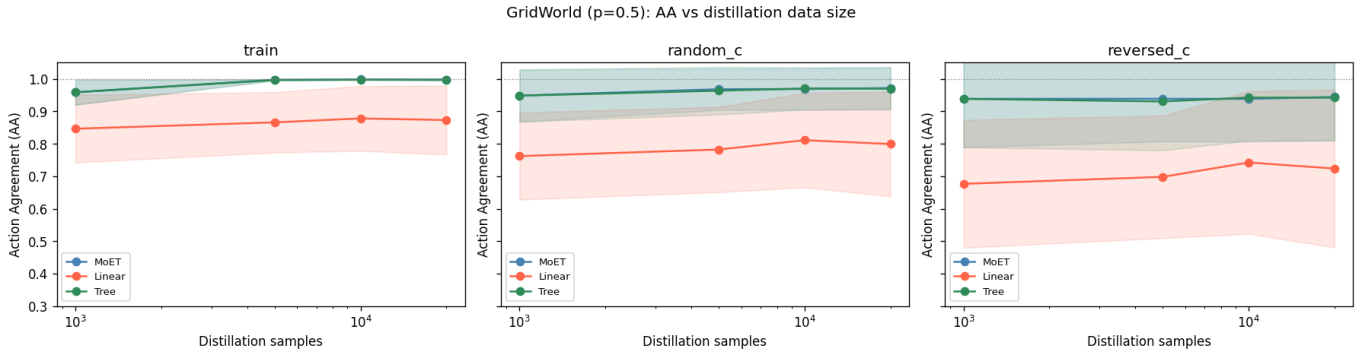
Table 4 に CartPole（$N = 0$）の結果を示す。

n	**MoET**	**Tree**	**Linear**
1k	0.887±0.019	0.869±0.027	0.748±0.063
5k	0.908±0.019	0.894±0.016	0.782±0.065
10k	0.909±0.018	0.896±0.016	0.794±0.065
20k	0.913±0.017	0.898±0.018	0.802±0.064

MoET と Tree は 5k 以降で AA がほぼ飽和する（MoET: 5k で 0.908、20k で 0.913）。Linear はデータ量とともに緩やかに上昇するが、20k においても 0.802 にとどまり MoET・Tree との差は縮まらない（t-test $p < 0.05$）。

GridWorld $p = 0.5$ の reversed_c 条件（スプリアス依存が分布シフト下で崩壊する条件）における結果が最も示唆的である（Figure 5）。MoET と Tree の AA はデータ量に関わらずほぼ固定（1k: 0.939、20k: 0.944）であり、Linear も同様に固定（1k: 0.677、20k: 0.724）である。すなわち、MoET と Linear の AA の差（約 0.22）はデータ量を 20 倍にしても解消されない（t-test $p < 0.01$）。この結果は、分布シフト下での再現性の差が蒸留データ不足ではなくモデルの構造に起因することを示す。

一方、GridWorld $p = 0.5$ の train 条件では MoET・Tree が 1k（AA=0.959）から 5k（AA=0.997）にかけて急上昇する。これはスプリアス依存の複製に最低限のデータ量が必要であることを示しており、10k はその閾値を十分に上回っている。GridWorld $p = 0.0$ 条件でも類似傾向が見られ（MoET: 1k=0.924、20k=0.923、Linear: 1k=0.818、20k=0.834）、両条件で構造差は持続する。



7. 議論

本枠組みの中心的な主張は、忠実性（faithfulness）は正当性（validity）を含意しないという点にある。高い行動一致率は Reasoned model が Intuitive policy を「忠実に模倣している」ことを示すが、「正しく捉えている」ことを意味しない。実験2が示した通り、スプリアス相関が存在する場合 Reasoned model は誤った依存を複製し、訓練分布では高 AA を示しながら分布シフト下で両者ともに失敗する。不変性の評価を加えることで初めてこの状態を「再現性高・不変性低」として数値から識別できる。

IRM（Arjovsky et al., 2019）や関連する不変学習の研究は、スプリアス依存を訓練時に排除することを目的とする。本枠組みは訓練戦略を変えるものではなく、学習済み方策と学習済み Reasoned model の組に対して事後的に適用できる点が異なる。実践的な含意として、既存の蒸留ベースの XRL システムに分布シフト下での評価を追加するだけで本枠組みが利用可能となる。

実験3の結果は、今回の実験範囲では相対的に不変性が高いケースが観察できることを示す。スプリアスのない CartPole では、訓練とは異なる重力とポール長の下でも AA が 0.76〜0.82 を維持し、両者の J が実験2のような壊滅的崩壊を示さなかった。これは、Reasoned model が写し取っている依存構造が、少なくとも今回試みた物理パラメータのシフト範囲において有効であることを示唆する。AA > 0.9 の閾値は実験的目安として恣意的だが、分布シフト下の相対比較において有効性を示す指標として機能する。

実験4・5のモデル比較は、Reasoned model の構造の種類が AA の分布依存性に影響することを示す。実験6の感度分析はこれを補強する：GridWorld $p = 0.5$ の reversed_c 条件において MoET と Linear の AA の差は蒸留データを 20 倍（1k→20k）にしても解消されず、この差が蒸留データ不足ではなくモデル構造に由来することを示した。CartPole では $N = 0$ のとき MoET が最も高い AA を示すが、ノイズ次元が増えると三種の差は縮小する。GridWorld では MoET と Tree がほぼ同等であり、Linear が分布シフト下で一貫して低い AA を示す。Tree と MoET の類似した挙動は、MoET のゲーティング層よりも木の分岐構造自体が再現性の鍵である可能性を示唆する。線形モデルの限界は表現力よりも、訓練分布での行動境界がシフト後の分布に転写されにくいことに起因すると考えられる。

SHAP は「現在の方策がどの特徴に依存しているか」を示す点で有用だが、その依存が環境の変化に対して維持されるかどうかは問えない。本研究の不変性の評価は SHAP を置き換えるものではなく、SHAP だけでは見えない情報──依存の有効性──を補完的に提供する。

AA > 0.9 という閾値の恣意性に対しては、閾値を 0.85・0.90・0.95 と変化させた感度分析で対応する。exp003（CartPole OOD）において、いずれの閾値でも train 条件と pole_short / pole_long 条件の間の明確な差は保たれた（mean AA: 0.91 vs 0.65 前後）。exp002（スプリアス GridWorld）でも、train 条件（AA≈0.95）と reversed_c 条件（AA≈0.77）の差は閾値に依らず視認可能な範囲にある。閾値の選択が定性的な結論を変えないことを確認できたため、AA > 0.9 を「高い行動一致率」の実験的目安として用いることは本データの範囲で妥当である。

スプリアス依存の検出は、その後の対処法と組み合わせてはじめて実用的な意義を持つ。本枠組みは検出に特化しており、対処そのものを提供するものではないが、検出結果は以下のような後続アクションを示唆する：観測空間からスプリアス特徴を除去する、環境の報酬関数や状態空間を再設計してスプリアス相関を取り除く、あるいは IRM のような不変学習手法で Intuitive policy を再訓練する。どのアクションが最適かは環境・タスクの性質に依存し、本研究の範囲では実証的に評価していないが、検出結果が後続のデバッグ・改善サイクルの出発点となることを意図している。

従来の XAI 研究における主要な制約の一つは、説明可能なモデル（決定木・線形モデル）は性能が低く、高性能モデル（深層ネットワーク）は解釈しにくいというトレードオフである。本枠組みはこのトレードオフを回避できる：Intuitive policy には一切手を加えないため性能は保たれ、Reasoned model はその横に事後的に配置するだけでよい。また Reasoned model の内部構造を問わない──MoET・決定木・線形モデルのいずれも、再現性と不変性という同一の評価軸で比較できる──ため、説明可能性の手法間の横断的な比較基盤としても機能する。

8. 限界

本研究の枠組みには四つの具体的な限界がある。

1. 主実験は CartPole と GridWorld という小規模な離散制御環境に限定されている。Section 4.4 の予備実験（LunarLander-v3・MuJoCo Hopper-v5）は連続力学系や連続行動空間への適用可能性を探索的に示すが、行動ビニングの近似誤差および DQN の部分収束という限界があり、高次元観測空間への汎化は未確認のままである。

2. 各条件の統計的信頼性は乱数シード10本に基づいており、特に pole_short 条件（AA 標準偏差 0.122）ではシフト後の挙動にばらつきが残る。実験6の10シードでも類似した分散が見られ、追加の統計検定が必要である。

3. 本枠組みは Intuitive policy が評価分布上でも動作することを前提とする。pole_long は Intuitive policy 自体が OOD で破綻した例であり、このケースでは AA の低下が Reasoned model の不変性の欠如によるものか Intuitive policy の失敗に伴う必然的な乖離かを区別できない。不変性の評価は Intuitive policy が評価分布上でも最低限の性能を維持している条件に限定して解釈するのが妥当である。

4. 分布シフトの選択（重力・ポール長・c の反転）は恣意的であり、どのようなシフトを選ぶかが不変性の評価結果に影響しうる。「検証したシフトの範囲で有効」という以上の主張をするためには、シフトの網羅的な選択基準の形式化が必要である。

9. 結論

強化学習方策の説明可能性を構造制約下の再現性として捉え直し、再現性が高いだけでは不足で不変性の評価を併用する必要があることを示した。再現性と不変性はともに、構造制約の強さ・入力分布・方策の依存構造に依存して変化する。モデル比較実験では、木構造を持つ Reasoned model（Tree・MoET）が線形モデルより分布シフト下での再現性を安定して維持することが示された。蒸留データ量感度分析は、この差が構造由来であることを確認した。本枠組みは外部ラベルを必要とせず、既存の蒸留ベースの説明手法に分布シフト下での評価を追加することで実施できる。

今後の課題として、Section 4.4 で示した連続制御環境での予備実験を回帰型 Reasoned model（MSE / KL ベースの忠実度指標）を用いた本格実験へと発展させること、高次元観測空間への適用、統計的信頼性を高めるためのシード数の増加、分布シフトの選択基準の形式化が挙げられる。また、Reasoned model の構造から規則列や自然言語説明を生成し、それが不変性にどう対応するかを検討することが、説明可能性の実用化に向けた次のステップとなる。

[^1]: Chen, R., et al. (2022). Machine explanations and human understanding. *Transactions on Machine Learning Research*.

[^2]: Mindlin, D., et al. (2025). Towards co-constructed explanations. *International Conference on Human-Agent Interaction*.

[^3]: Vasic, M., et al. (2019). MoET: Interpretable and verifiable reinforcement learning via mixture of expert trees. *AAAI*.

[^4]: Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

[^5]: Arjovsky, M., et al. (2019). Invariant risk minimization. *arXiv:1907.02893*.

[^6]: Bastani, O., Pu, Y., & Solar-Lezama, A. (2018). Verifiable reinforcement learning via policy extraction. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^7]: Kolter, J. Z., & Ng, A. Y. (2009). Regularization and feature selection in least-squares temporal difference learning. *International Conference on Machine Learning (ICML)*.

[^8]: Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.

[^9]: Alvarez-Melis, D., & Jaakkola, T. S. (2018). Towards robust interpretability with self-explaining neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^10]: Samek, W., Wiegand, T., & Müller, K.-R. (2017). Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. *arXiv:1708.08296*.

[^11]: Koh, P. W., et al. (2020). Concept bottleneck models. *International Conference on Machine Learning (ICML)*.

[^12]: Greydanus, S., Koul, A., Dodge, J., & Fern, A. (2018). Visualizing and understanding Atari agents. *International Conference on Machine Learning (ICML)*.

[^13]: Yuksekgonul, M., Wang, M., Slack, D., Singh, S., Guestrin, C., & Lakkaraju, H. (2023). Post-hoc concept bottleneck models. *International Conference on Learning Representations (ICLR)*.

[^14]: Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518, 529–533.