構造制約ボトルネックに基づく強化学習方策の説明可能性評価枠組み

要旨

XAI の根本的なジレンマは、説明可能なモデルは性能が低く、高性能なモデルは解釈しにくいというトレードオフにある。本研究はこのトレードオフを**分離（decoupling）**によって回避する。強化学習で学習したブラックボックス方策（**Oracle policy**）には一切手を加えず、その横に構造制約付きの蒸留モデル（**Surrogate model**）を事後的に配置する。性能は Oracle policy が担保し、説明の構造的な候補は Surrogate model が担う。Surrogate model の内部構造を問わないため、決定木・MoET・線形モデルのいずれも共通の評価軸で比較でき、どの説明可能性手法が優れているかを横断的に評価する基盤としても機能する。

しかし、Surrogate model の行動一致率（AA）が高いことは説明の信頼性を保証しない。本研究の中心的主張は、**高 AA は説明の候補となるための必要条件に過ぎない**という点にある。スプリアス特徴依存を含む方策から Surrogate model を蒸留すると、誤った依存構造ごと忠実に再現され、訓練分布では高 AA を示しながら分布シフト下で崩壊する。RL では行動選択が累積報酬に逐次波及するため、この崩壊の損害は分類タスクより大きい。「再現できるが誤っている」状態は AA だけでは検出できず、**分布シフト下での不変性**を追加の評価軸として用いて初めて識別できる。

CartPole の拡張環境とスプリアス相関を埋め込んだ GridWorld を用いた 6 つの実験により、高 AA を維持しながら分布シフト下で崩壊するケース（スプリアス依存の複製）と、シフトを経ても AA が比較的保たれるケースを実験的に示す。モデル比較（実験4・5）では木構造モデルが線形モデルより分布シフト下での再現性を安定して維持し、この差が蒸留データ不足ではなくモデル構造に由来することを感度分析（実験6）で確認した。

1. 序論

XAI の根本的な制約として、説明可能なモデルは性能が低く、高性能なモデルは解釈しにくいというトレードオフが長く指摘されてきた。決定木や線形モデルは構造が読みやすい一方、強化学習のような逐次意思決定では性能が大きく劣る。LIME（Ribeiro et al., 2016[^8]）や SHAP（Lundberg & Lee, 2017[^4]）のような事後的説明手法は元のモデルに手を加えないが、元の方策の振る舞いをどれだけ忠実に捉えているかは自明でなく、説明の価値を一方向に還元しにくい（Chen et al., 2022[^1]）。先行研究との詳細な関係は Section 2 で整理する。

本研究はこのトレードオフを**分離（decoupling）**によって回避する。強化学習で学習した高性能なブラックボックス方策（**Oracle policy**）には一切手を加えず、その横に構造制約付きの蒸留モデル（**Surrogate model**）を事後的に配置する。Oracle policy が性能を担い、Surrogate model が説明の構造的な候補を担う。Surrogate model の内部構造を問わないため、決定木・Mixture of Expert Trees（MoET; Vasic et al., 2019[^3]）・線形モデルのいずれも共通の評価軸で比較でき、どの説明可能性手法が優れているかを横断的に評価する基盤としても機能する。

しかし、Surrogate model が高い行動一致率（AA）で Oracle policy を模倣できたとして、その説明を信頼してよいか。方策蒸留の先行研究（Bastani et al., 2018[^6]; Vasic et al., 2019[^3]）は AA の最大化をゴールとしてきたが、AA が高い代理モデルが元の方策と同じスプリアス依存を写し取っている場合を検出する仕組みを持たない。behavioral cloning によって蒸留されたモデルがスプリアス依存を複製すること自体は、蒸留の構

造から見れば自明である。問題は、この複製が起きているかどうかを AA だけでは判別できないことにある。RL では方策の行動選択が次の状態遷移を規定し、一つの誤りが後続の行動列全体を崩壊させうる（例: 報酬 -1000 以下）。スプリアス依存を忠実に再現した Surrogate model は、訓練分布では問題なく見えながら分布シフト下で壊滅的に失敗する。**忠実性（faithfulness）は正当性（validity）を含意しない**。

本研究は**不変性の評価**を追加することでこの問題に対処する。高 AA は Surrogate model が意味のある説明候補となるための必要条件であり、分布シフト下での不変性の検査がその信頼性を評価する追加軸を提供する。分布シフト下でも Surrogate model が Oracle policy の行動を再現できるなら、それが捉えている依存構造は検証した分布の範囲で有効であると言える。逆に訓練分布では高 AA を示しながら分布シフト下で崩壊するなら、スプリアス依存を写し取っている疑いが強まる。

本研究の貢献は以下の三点にある。

1. 説明可能性と性能のトレードオフを分離によって回避し、Oracle policy の性能を一切損なわずに、任意の Surrogate model の説明品質を事後的に評価する枠組みを提案する。Surrogate model の内部構造を問わないため、決定木・MoET・線形モデルをはじめ将来登場するどの解釈可能モデルも、共通の評価軸（再現性・不変性）で横断比較できる。
2. 再現性（AA）と不変性（分布シフト下の AA・J_S）を組み合わせた二段階評価方法論を提供し、「高 AA だが誤っている」状態を数値から識別できることを実験的に示す。
3. CartPole とスプリアス GridWorld を用いた 6 つの実験で、構造制約の強さ・入力分布・依存構造に応じて再現性と不変性がどう変化するかを示し、本枠組みが多様な RL 環境で一貫した評価軸として機能することを確認する。

2. 関連研究

2.1 方策蒸留と代理モデル

ブラックボックス方策を解釈可能なモデルで近似する研究は方策蒸留の文脈で進められてきた。Vasic ら（2019）の MoET は、ニューラルネットワーク方策をソフトゲーティング付きの決定木混合モデルに蒸留し、解釈可能性と精度を両立する。Bastani ら（2018）[^6]の決定木蒸留や線形モデルによる近似（Kolter & Ng, 2009[^7]）も同様に、方策の行動を保存しながら構造的な単純さを実現することを目標とする。これらの研究は AA の最大化を達成の証拠とするが、高 AA の代理モデルが元の方策と同じスプリアス依存を写し取っている場合を検出する仕組みを持たない。本研究はこの欠落を不変性の評価で補う。

2.2 事後的説明手法と Faithfulness

LIME（Ribeiro et al., 2016[^8]）と SHAP（Lundberg & Lee, 2017[^4]）は個々の予測に対する局所的な特徴寄与を算出する手法として広く用いられる。これらの手法は「方策が現在どの特徴に依存しているか」を示すが、その依存が分布変化に対して有効かどうかを問わない。Faithfulness に関する研究（Alvarez-Melis & Jaakkola, 2018[^9]; Samek et al., 2017[^10]）は訓練分布内での説明の忠実性を評価しようとするが、訓練分布外での忠実性維持は問われない。本研究の不変性の概念は、分布外での faithfulness の維持を直接評価する点でこれらを補完する。

2.3 不変性と分布シフトの解釈可能性

IRM（Arjovsky et al., 2019[^5]）は複数環境で一貫して有効な特徴表現を学習することでスプリアス相関への依存を回避しようとする学習戦略である。概念ボトルネックモデル（Koh et al., 2020[^11]）は人間が定義した概念を中間表現として用い、説明の因果的な意味を高める。事後的概念ボトルネックモデル（Yuksekgonul et al., 2023[^13]）はこれを再学習なしに任意の学習済みモデルへ適用可能にし、事後評価と

いう立場を共有する点で本研究と方向性が近い。これらが解釈可能な表現を付与することを目的とするのに対し、本研究は学習済み方策について依存がスプリアスかどうかを事後的に測定する枠組みを提供する点で異なる。

なお、分布シフト下でのモデル評価という操作は OOD ロバスト性研究（Gulrajani & Lopez-Paz, 2021; Sagawa et al., 2020）でも用いられるが、目的が根本的に異なる。OOD ロバスト性研究はシフト後の性能向上を目指す訓練戦略を問う。本枠組みは訓練戦略を変えるものではなく、分布シフトを既存の蒸留済み Surrogate model の説明品質を診断するための事後的ツールとして用いる。目的はロバスト性の実現ではなく、任意の解釈可能モデルに対して共通の評価軸を提供する評価方法論の確立にある。

2.4 RL における説明可能性

強化学習の文脈では、注意機構の可視化（Greydanus et al., 2018[^12]）などの手法が提案されてきた。Puiutta & Veith（2020）は RL の説明可能性研究を包括的にサーベイし、説明の対象と形式の多様性を整理している。本研究はこれらの手法と直接競合するものではなく、「生成した説明が方策の行動を本当に捉えているか」という横断的な問いに答える評価軸として位置づけられる。

3. 背景と定義

3.1 方策

状態空間 $\mathcal{S}$、行動空間 A に対し、確率的方策を $\pi_O(a \mid s)$ と表す。π_O を **Oracle policy** と呼び、強化学習で学習されたブラックボックス方策で、内部表現の意味付けを与えない。

3.2 構造制約付きモデル

Surrogate model は π_O を模倣する構造制約付きモデルである。状態 s を制約された中間表現 $z \in Z$ に写像する関数 ϕ と、行動分布を出力する関数 D により、

$$z = \phi(s), \qquad \pi_S(a \mid s) = D(\phi(s))$$

と書ける。Z は低次元・単純・解釈可能な表現空間であり、具体例として線形モデル、深さ制限付き決定木、MoET（Vasic et al., 2019）が挙げられる。本枠組みは π_S の具体的な実装を問わない。決定木・MoET・線形モデルのいずれを選んでも、あるいは将来登場する新たな解釈可能モデルを採用しても、再現性（AA）と不変性（J_S under shift）という同一の評価軸で比較できる。本研究では Surrogate model を人間向けの説明文生成装置としてではなく、方策の振る舞いの保存可能性を測る構造ボトルネックの同定ツールとして位置づける。

3.3 説明可能性の評価枠組み

本研究では Surrogate model による説明の質を二段階で評価する。

第一段階：再現性の確認。 Surrogate model が π_O の行動を訓練分布上で十分に再現できなければ、そのモデルは方策の近似としてそもそも成立しない。行動一致率（AA）が高いことは、意味のある説明候補となるための**必要条件**である。実験の便宜上、AA > 0.9 を高再現性の目安として用いる。ただし、極端な物理パラメータシフト（pole_long, pole_short）では AA が 0.9 を下回る場合があり、この閾値はすべての条件で普遍的に達成されることを意味しない。

第二段階：不変性の検査。 高 AA を達成した Surrogate model であっても、スプリアス依存を含む方策から蒸留された場合、その依存構造ごと写し取り、訓練分布では高 AA を示しながら分布シフト下で崩壊する。

分布シフト $D_{\text{train}} \to D_{\text{shift}}$ に対し、$(\mathrm{AA}(D_{\text{shift}}), ; J_S(D_{\text{shift}}))$ の組を不変性の評価指標として報告する。スプリアス依存が存在する場合、$\mathrm{AA}(D_{\text{shift}})$ は高いまま $J_S(D_{\text{shift}})$ が崩壊する（「再現できるが誤っている」状態）。スプリアス依存が存在しない場合、$\mathrm{AA}(D_{\text{shift}})$ が低下しても $J_S(D_{\text{shift}})$ は壊滅的な崩壊を示さない。この対比が診断の根拠となる。

不変性が高いことは依存の**因果的正当性**を保証しない。検証した分布シフトの範囲で依存が有効に機能していることの証拠に留まる。この評価枠組みは確定的な判定を与えるものではなく、「高 AA を達成した Surrogate model がスプリアス依存を写し取っていないかどうか」を診断する実験的指標として機能する。

4. 提案枠組み

4.1 学習手順

二段階学習を採用する。まず DQN（Mnih et al., 2015[^14]）で π_O を学習する。次に π_O を固定し、そのロールアウトから収集した (s, a) ペアを教師信号として Surrogate model を行動複製（behavioral cloning; Bastani et al., 2018[^6]）で蒸留する。複数目的の同時最適化を避けることで、Surrogate model の性能を純粋な再現能力として解釈しやすくする。蒸留データと評価データは独立したシードで収集し、蒸留の記憶ではなく再現の汎化を測る。

4.2 Surrogate Model の候補

構造制約の強さを比較するため、線形モデル（ロジスティック回帰）、深さ制限付き単一決定木、MoET の三種を候補として位置づける。本研究では MoET を主に用い、専門家数 K と深さ d のグリッドサーチで制約の強さを連続的に調整することで再現性の構造的上限を観察する。加えて実験4・5で三種を同一条件下で定量比較し、構造の種類が AA の分布依存性に与える影響を調べる。

4.3 評価指標

- **Action Agreement（AA）**: $\mathrm{AA}(D) = \mathbb{E}_{s \sim D}[\mathbf{1}[\pi_O(s) = \pi_S(s)]]$ 。再現性の指標。
- **方策性能（J_S）**: $J_S(D) = \mathbb{E}_{s_0 \sim D,; \tau \sim \pi_S}\left[\sum_{t=0}^{T} r_t\right]$。不変性評価の指標。

4.4 予備実験：連続制御環境への拡張

本節では、離散行動を前提とする主実験の枠組みが連続制御環境にも適用可能であることを、2 種の環境を用いた予備実験で示す。完全な連続行動への対応（例：MSE ベースの忠実度指標、回帰型 Surrogate model）は今後の課題とし、本節は探索的結果として位置づける。

LunarLander-v3（離散行動・連続力学）は、4 値の離散行動（エンジン噴射）で連続物理系（重力・慣性）を制御する環境であり、重力係数 $g \in -10.0, -3.0, -11.5$ を分布シフト条件とした。Oracle policy として DQN（RL Zoo 推奨パラメータ、2M ステップ）を学習した（$J_{\text{oracle}} = 203 \pm 57$）。また DQN のシード間分散が大きいため、PPO による追加実験（1M ステップ、n_envs=8）も実施した（$J_{\text{oracle}} = 260 \pm 13$）。

MuJoCo Hopper-v5（連続行動ビニング）は、連続行動空間 $[-1, 1]^3$ を各次元 3 分割（$3^3 = 27$ クラス）にビニングし、ビン中心値を実行する離散近似により AA を計算した。Oracle policy として SAC（500k ステップ）を学習した（$J_{\text{oracle}} = 2623 \pm 1345$）。重力条件は $g \in -9.81, -5.0, -20.0$ とした。

各 5 シードで Surrogate model（MoET・Tree・Linear）を蒸留し、訓練分布上の AA を比較した結果を Table 1 に示す。

Table 1: 予備実験 AA（5シード、訓練条件）

Model	LunarLander DQN	LunarLander PPO	Hopper-v5
MoET	0.698 ± 0.058	0.734 ± 0.028	**0.706 ± 0.111**
Tree	0.693 ± 0.063	0.725 ± 0.032	0.579 ± 0.131
Linear	0.575 ± 0.038	**0.764 ± 0.045**	0.565 ± 0.116

Hopper では MoET が Tree・Linear を上回り（$\Delta\mathrm{AA} \approx 0.13$）、主実験と同じ順序関係が確認された。LunarLander DQN では MoET ≈ Tree $>$ Linear だが、PPO oracle では Linear が最も高い AA（0.764）を示し、CartPole とは異なる順序関係が観察される。いずれも主実験（CartPole AA ≥ 0.91）より低い値であり、これは複雑な力学系の難易度に起因すると考えられる。

なお、本予備実験では AA を訓練条件・シフト条件（重力変化）の両方で計算した。LunarLander PPO は $J_{\mathrm{oracle}} = 260 \pm 13$ と安定して収束した一方、DQN はシード間分散が大きく（$J_{\mathrm{oracle}} = 203 \pm 57$）、seed=1011 で $J = 107$ と基準値未達のものがあった。Hopper の SAC はシード間分散が大きい（std $= 1345$）。これらの限界を踏まえ、本結果は「構造制約の優位性が離散行動以外にも示唆される」という探索的な根拠として解釈する。

5. 実験

5.1 実験の目的

以下の四点を実証するために実験を設計した。

1. 構造制約の強度が再現性に構造的な上限を課すこと。
2. スプリアス環境で再現性高・不変性低のケースを検出できること。
3. スプリアスのない環境で、複数の物理パラメータシフトにわたって相対的に不変性が高い状態を観察できること。
4. 構造の種類（線形・単一木・MoET）によって、分布シフト下での再現性がどう異なるか。加えて、蒸留データ量の感度を分析し、構造差の頑健性を確認。

各条件は乱数シード10本（42, 123, 456, 789, 1011, 1314, 1617, 1920, 2223, 2526）で実行し、平均±標準偏差を報告する。蒸留データと評価データは独立したシードで収集する。分布シフトの種別（物理パラメータ変更 vs. スプリアス特徴の反転）は、検出すべき現象の性質に基づいて選択した。分布シフトの選択基準の形式化は今後の課題である。

5.2 実験1：CartPole ノイズ拡張

CartPole-v1 の状態（4次元）に独立なガウスノイズを $N \in 0, 4, 8, 16$ 次元追加した拡張状態で DQN を学習（200,000 ステップ、EvalCallback によるベストモデル保存）する。Surrogate model には MoET（$K \in 2, 3, 4$, $d \in 1, 2, 3, 4, 5$ の全組み合わせ）を用いる。スプリアス依存を扱わない基準実験として、構造制約による再現性の構造的上限を観察する。

5.3 実験2：Spurious GridWorld

5×5 グリッドに配置したエージェントの位置 (x, y) とスプリアス変数 c を状態とし、ゴール位置を直接観測しない GridWorld 環境を設計する。状態空間は 3 次元（$x, y \in [0, 1]$ に正規化、$c \in 0, 1$）、行動空間は 4 方向の離散行動（上下左右）である。報酬はゴール到達時 $+1.0$、各ステップ -0.01 のペナルティとし、エ

ピソード上限は 100 ステップである（$J = -1.000$ はゴール未到達で全ステップを消費した場合の累積ペナルティに対応する）。ゴールは $(0, 0)$ と $(4, 4)$ の 2 箇所のいずれかにエピソードごとランダムに配置される。c はスプリアスノイズ確率 $p \in 0.0, 0.2, 0.5$ で制御される：確率 $1 - p$ でゴールの方向を正しく示し、確率 p でランダムな値をとる。$p = 0$ の場合 c は決定論的にゴールを指し、p が大きいほど c の信頼性が低下する。方策はいずれの p 条件でも c への依存を学習するため、分布シフトとして c を操作すると性能が変化する。評価条件は訓練分布（train）、c をランダム化した条件（random_c）、c を反転した条件（reversed_c）の3種類である（200,000 ステップ学習）。

5.4 実験3：CartPole 物理パラメータシフト

スプリアス特徴を含まない CartPole（$N = 0$）を対象とし、訓練後に物理パラメータを変えることで分布シフトを与える。重力 $g \in 9.8, 5.0, 20.0$ とポール半長 $\ell \in 0.5, 0.25, 1.0$ を独立に変化させた5条件（train, gravity_lo, gravity_hi, pole_short, pole_long）で評価する。Oracle policy は実験1の $N = 0$ 学習済みモデルを再利用し、Surrogate model には最良設定の MoET（$K = 4$, $d = 5$）を用いる。pole_long（$\ell = 1.0$）は訓練時の2倍のポール長であり、Oracle policy 自体が OOD で機能しなくなる可能性がある極端な条件として扱う。

5.5 実験4：CartPole モデル比較

実験1と同じ CartPole ノイズ拡張環境（$N \in 0, 4, 8, 16$ ）で、Surrogate model を MoET（$K = 4$, $d = 5$）、単一決定木（$d = 5$）、ロジスティック回帰の三種に固定して比較する。各条件で学習済みの Oracle policy は実験1のモデルを再利用する。蒸留サンプル数 10,000、評価サンプル数 5,000、10シードで AA を報告する。

5.6 実験5：GridWorld モデル比較

実験2と同じ Spurious GridWorld（$p \in 0.0, 0.2, 0.5$ 、評価条件 train / random_c / reversed_c）で、同三種の Surrogate model を比較する。学習済み Oracle policy は実験2のモデルを再利用する。スプリアス相関の強さが構造の種類と交互作用するかどうかに着目する。

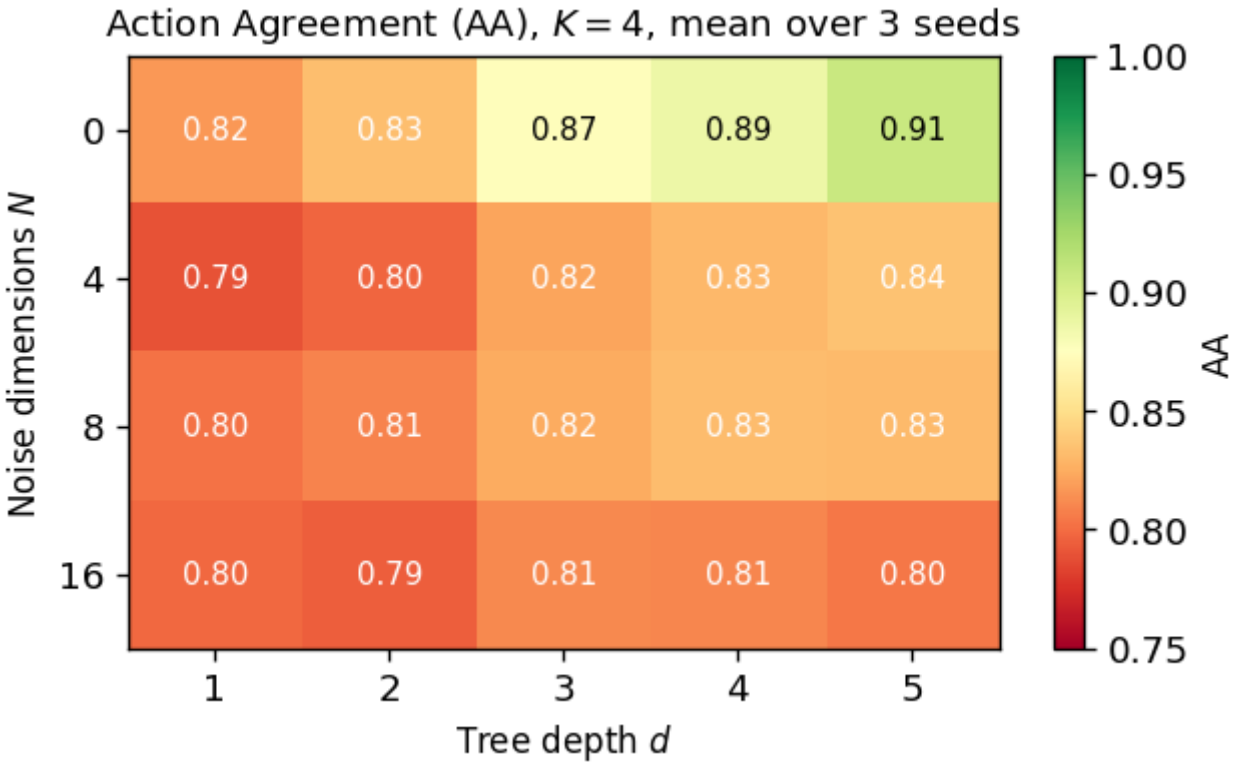
5.7 実験6：蒸留データ量の感度分析

実験4・5で観察された線形モデルと木構造モデルの AA の差が、データ量の不足によるものでないことを確認するため、蒸留サンプル数 $n \in 1\mathrm{k}, 5\mathrm{k}, 10\mathrm{k}, 20\mathrm{k}$ を変化させて AA の依存性を調べる。CartPole（$N = 0$）と GridWorld（$p \in 0.0, 0.5$ ）の両環境で MoET・Tree・Linear を比較する。Oracle policy は実験1・2の学習済みモデルを再利用し、評価は各蒸留サイズで独立サンプル 5,000 件を用いる（10 シード）。

6. 結果

6.1 実験1：再現性の構造的上限

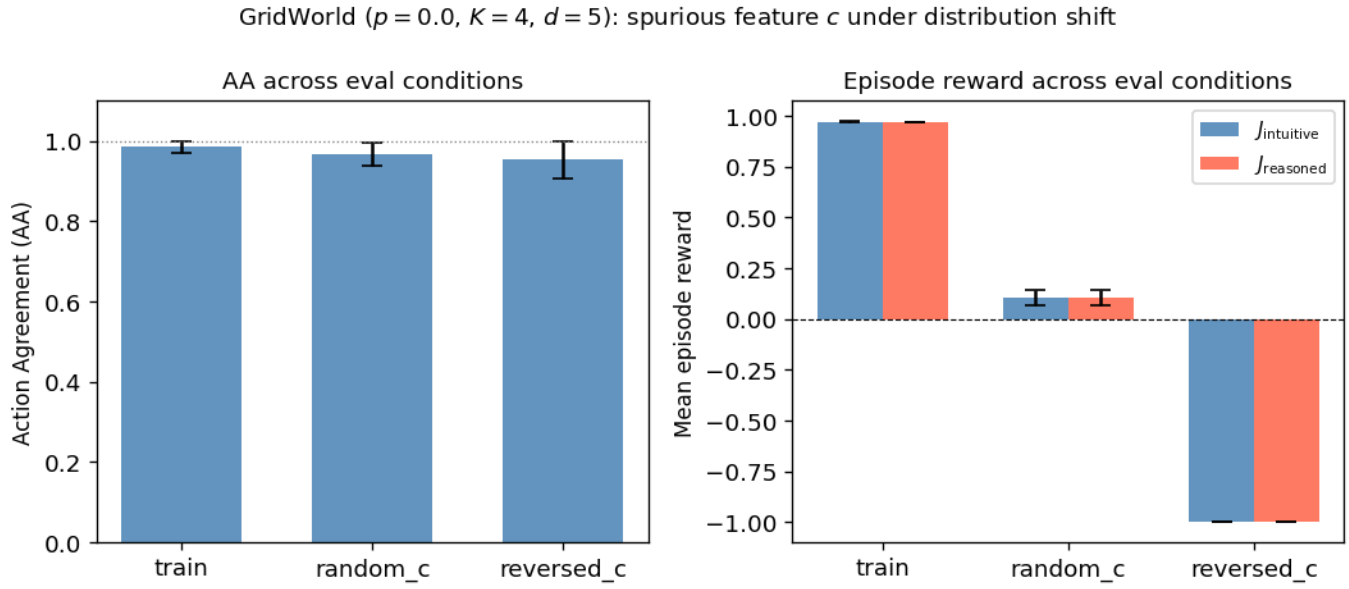
ノイズ次元を追加すると MoET の再現性は深さとともに改善するが、上限が低下する。$N = 0$ で $K = 4, d = 5$ のとき AA=0.916±0.027、$N = 16$ では AA=0.819±0.033 にとどまる（Figure 1）。入力空間の複雑さに応じて AA の到達上限が変化することを示す。



6.2 実験2：再現性高・不変性低の実証

train 条件では AA が高く（最良設定 $K = 4, d = 5$ で 0.988±0.011）、J もほぼ一致する。reversed_c 条件では AA=0.942±0.056 を維持したまま $J_{\text{oracle}} = J_{\text{surrogate}} = -1.000$ まで崩壊する（Figure 2）。これが定義における「再現性高・不変性低」の状態であり、Surrogate model が Oracle policy のスプリアス依存をそのまま複製した結果として解釈される。random_c 条件でも AA=0.965±0.031 と高水準を維持するが、J は両者とも低水準に留まる。c をランダム化しても Oracle policy と Surrogate model の双方がスプリアス特徴 c に依存した行動を取り続けるため、互いの行動は一致するが環境内での性能は崩壊する。すなわち random_c 条件も reversed_c 条件と同様に「再現性高・不変性低」の状態であり、本枠組みが複数種類の分布シフトで一貫してこの状態を識別できることを示す。

SHAP（KernelExplainer）を同一の Oracle policy に適用した場合、スプリアス特徴 c の重要度は train（Mean $|\text{SHAP}|$ = 0.0181）と reversed_c（Mean $|\text{SHAP}|$ = 0.0178）でほぼ同値となる（Figure 4）。SHAP は「方策が何に依存しているか」を示すが、「その依存が分布シフト後に維持されるか」を問わない。本枠組みはこの隙間を不変性の評価によって補完する。



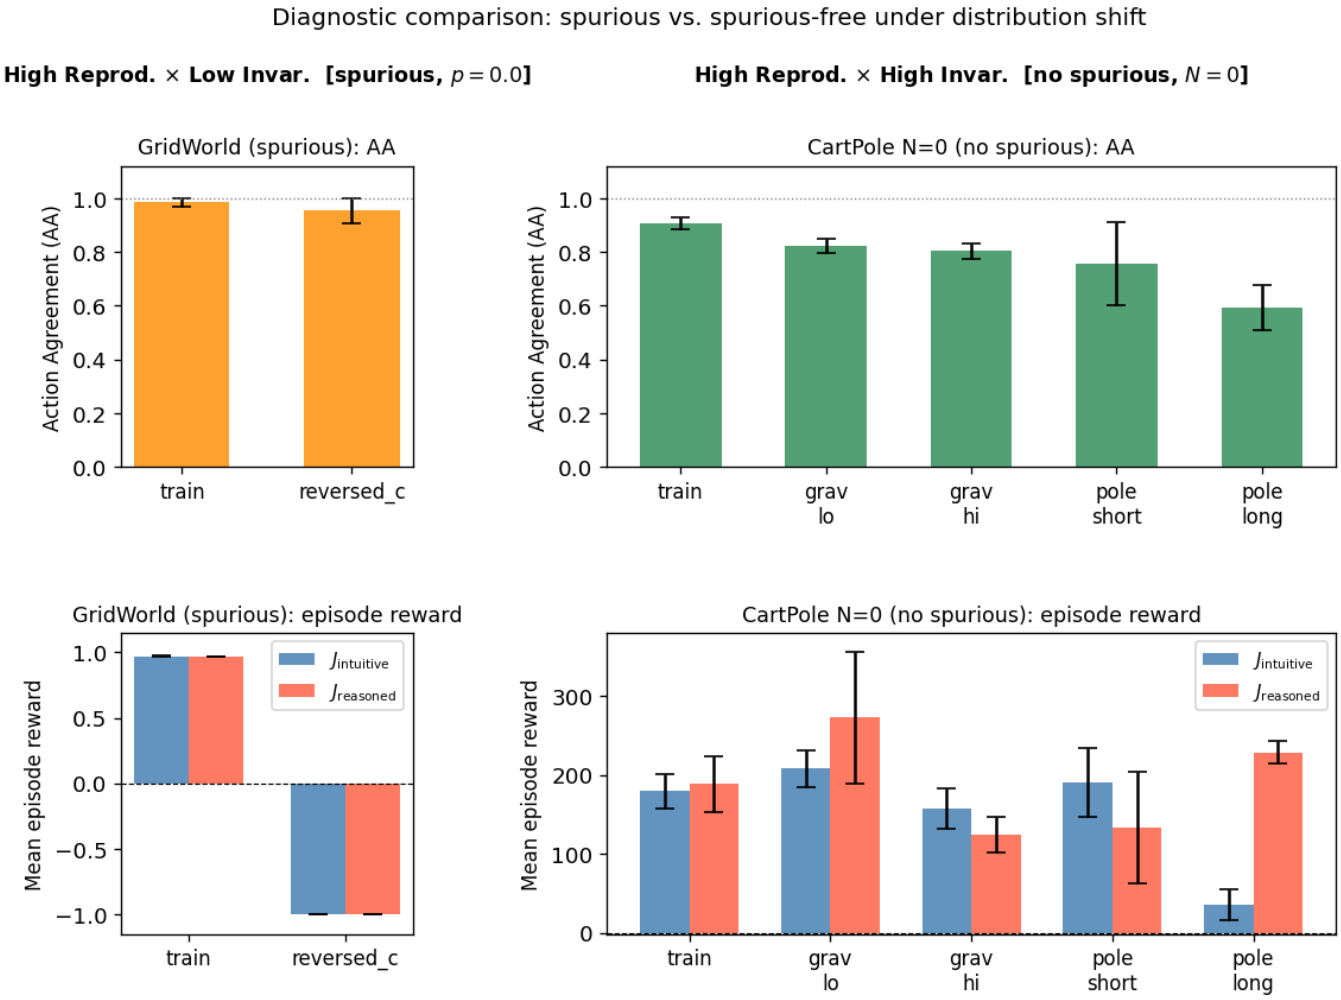
6.3 実験3：スプリアスのない環境における不変性の比較観察

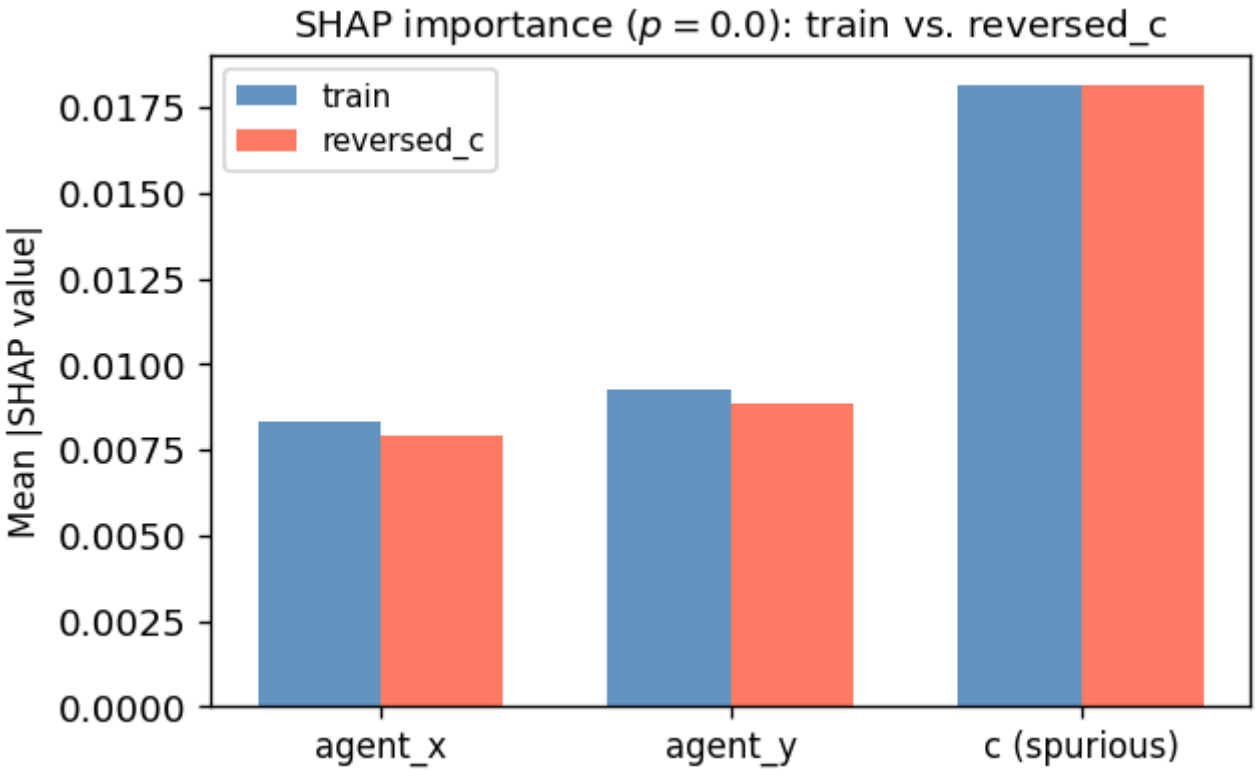
Table 2 に結果を示す（10シード平均±標準偏差）。

評価条件	**AA**	J_{oracle}	$J_{\text{surrogate}}$
train ($g = 9.8$, $\ell = 0.5$)	0.915±0.028	428.1±148.5	417.9±143.5
gravity_lo ($g = 5.0$, $\ell = 0.5$)	0.883±0.049	436.5±134.0	425.8±120.8
gravity_hi ($g = 20.0$, $\ell = 0.5$)	0.861±0.063	336.2±180.1	347.4±177.7
pole_short ($g = 9.8$, $\ell = 0.25$)	0.846±0.115	406.8±161.4	361.1±156.0
pole_long ($g = 9.8$, $\ell = 1.0$)	0.759±0.078	376.5±160.5	426.5±133.8

全条件で J_{oracle} と $J_{\text{surrogate}}$ がともに大きく正の値に留まり、実験2の reversed_c 条件（$J = -1.000$）のような壊滅的な崩壊は見られない（Figure 3）。重力変化は CartPole の運動方程式に対するスケーリング的な外乱であるのに対し、ポール長の変化は振り子の慣性モーメントを直接変形させる質的に異なる外乱である。この二種で同様の傾向が見られたことは、この特性が重力シフト固有の偶然でない可能性を示唆する。なお、J_{oracle} の標準偏差が訓練条件で 148.5 と大きいのは、DQN の確率的な収束特性（10 シード中 2 シード程度が収束に失敗する）によるものである。gravity_lo, gravity_hi では $J_{\text{surrogate}}$ が J_{oracle} をわずかに上回る場合があり、蒸留の正則化効果（シンプルな構造への汎化）の可能性を示唆する。

pole_long（$\ell = 1.0$）では AA が 0.759 と全条件で最低値を示す。$J_{\text{oracle}} = 376.5$ に対して $J_{\text{surrogate}} = 426.5$ という逆転が生じており、Surrogate model がポール長の変化に対して Oracle policy より適応的に振る舞っていることを示す。この逆転現象の解釈については Section 8 で論じる。





6.4 実験4：CartPole モデル比較

Table 3 に N ごとの AA を示す（10シード平均±標準偏差）。

N	MoET	Tree	Linear
0	0.915±0.028	0.902±0.031	0.842±0.033
4	0.881±0.035	0.858±0.043	0.857±0.054
8	0.852±0.050	0.812±0.065	0.846±0.060
16	0.820±0.032	0.768±0.046	0.830±0.037

$N = 0$ では MoET が最も高い AA（0.915）を示し、Tree（0.902）がこれに続く。Linear は $N = 0$ で 0.842 と他の二種に比べて低く、ノイズのない純粋な CartPole 状態でも木構造より再現性が劣ることが分かる。$N = 4, 8$ では MoET が依然として優位を保つが差は縮小する。$N = 16$ では数値上 Linear（0.830）が MoET（0.820）をわずかに上回るが、この差は補正後に有意でなく（$p_{\text{adj}} = 0.54$）、Tree（0.768）は有意に最低値となる。ノイズ次元が大きくなるほど構造制約の種類による差が圧縮されることは、入力空間の複雑さが AA の上限を規定する実験1の知見と整合する。

統計的有意性を Welch の t 検定（Holm--Bonferroni 補正、全 12 比較）で確認した。$N = 0$ では MoET および Tree はいずれも Linear より有意に高い AA を示した（MoET: $p_{\text{adj}} < 0.001$、Tree: $p_{\text{adj}} < 0.01$）が、MoET と Tree の差は補正後に有意でなかった（$p_{\text{adj}} = 0.36$）。$N = 4, 8$ では三種の差はいずれも有意でなく（全 $p_{\text{adj}} > 0.4$）、ノイズ次元の増加による差の圧縮と整合する。$N = 16$ では Tree と Linear の差（$p_{\text{adj}} = 0.011$）および MoET と Tree の差（$p_{\text{adj}} = 0.018$）が有意であり、Tree が有意に最低値を示した。MoET と Linear の差は補正後に有意でなかった（$p_{\text{adj}} = 0.54$）。

6.5 実験5：GridWorld モデル比較

Table 4 に $p \in 0.0, 0.2, 0.5$ での AA を示す（10シード平均±標準偏差）。

p	評価条件	MoET	Tree	Linear
0.0	train	0.985±0.014	0.971±0.012	0.903±0.052
0.0	random_c	0.958±0.035	0.930±0.044	0.836±0.079
0.0	reversed_c	0.930±0.063	0.887±0.084	0.771±0.133
0.2	train	0.996±0.003	0.990±0.009	0.971±0.021
0.2	random_c	0.959±0.100	0.931±0.107	0.920±0.048
0.2	reversed_c	0.922±0.200	0.872±0.211	0.867±0.102
0.5	train	0.999±0.001	0.998±0.001	0.878±0.100
0.5	random_c	0.970±0.064	0.971±0.065	0.811±0.146
0.5	reversed_c	0.940±0.132	0.942±0.133	0.742±0.220

MoET と Tree はほぼ同等の AA を示す。Linear は全条件で劣り、特に $p = 0.5$ の reversed_c 条件では AA=0.742 と MoET（0.940）・Tree（0.942）との差が顕著である。p の増加と評価条件のシフトの両方に対して、線形モデルの再現性が低下する傾向は一貫して観察される。なお高 p 条件では三種のモデルいずれも標準偏差が拡大しており（$p = 0.5$ の MoET/Tree で ±0.13、Linear で ±0.22）、スプリアス相関が強い環境ではシード依存性も増すことが分かる。

Welch の t 検定（Holm--Bonferroni 補正、全 27 比較）による統計的有意性を確認した。27 比較のうち補正後に有意であったのは 2 件のみで、いずれも $p = 0.0$ 条件における MoET vs Linear の差であった（train: $p_{\text{adj}} = 0.018$、random_c: $p_{\text{adj}} = 0.018$）。Tree vs Linear の差、$p = 0.2$ および $p = 0.5$ の各条件における差はすべて補正後に有意でなかった（全 $p_{\text{adj}} > 0.05$）。平均値の傾向（Linear の AA が他の 2 種より低い）は各セルで一貫して観察されるが、27 比較の多重補正のもとでは大半の差が統計的有意性の基準を満たさないことに留意が必要である。MoET と Tree の差はいずれの条件でも有意でなく（全 $p_{\text{adj}} > 0.5$）、両者の挙動の類似性は統計的に支持される。

6.6 実験6：蒸留データ量の感度分析

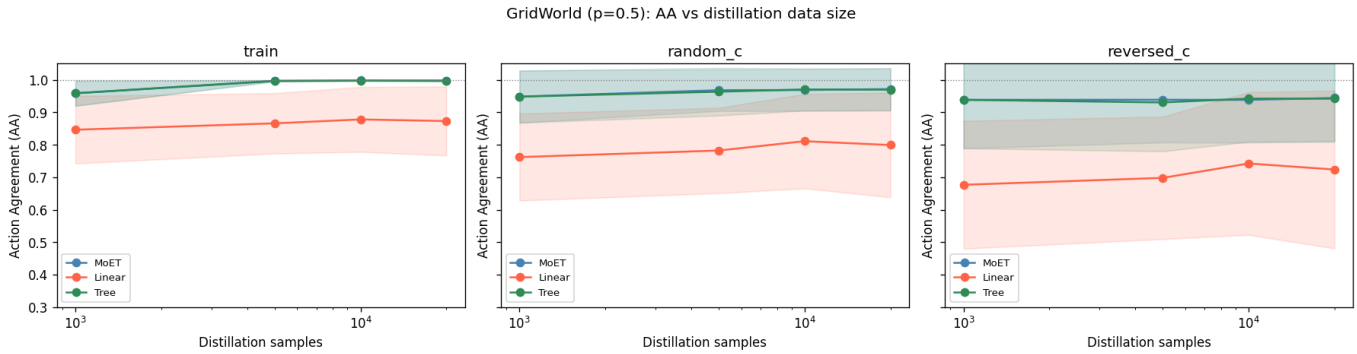
Table 5 に CartPole（$N = 0$）の結果を示す。

n	**MoET**	**Tree**	**Linear**
1k	0.888±0.020	0.881±0.028	0.823±0.051
5k	0.916±0.024	0.904±0.028	0.839±0.034
10k	0.915±0.028	0.903±0.031	0.842±0.033
20k	0.926±0.022	0.906±0.031	0.844±0.033

MoET と Tree は 5k 以降で AA がほぼ飽和する（MoET: 5k で 0.916、20k で 0.926）。Linear はデータ量とともに緩やかに上昇するが、20k においても 0.844 にとどまり MoET・Tree との差は縮まらない（t-test $p < 0.05$）。

GridWorld $p = 0.5$ の reversed_c 条件（スプリアス依存が分布シフト下で崩壊する条件）における結果が最も示唆的である（Figure 5）。MoET と Tree の AA はデータ量に関わらずほぼ固定（1k: 0.939、20k: 0.944）であり、Linear も同様に固定（1k: 0.677、20k: 0.724）である。すなわち、MoET と Linear の AA の差（約 0.22）はデータ量を 20 倍にしても解消されない（t-test $p < 0.01$）。この結果は、分布シフト下での再現性の差が蒸留データ不足ではなくモデルの構造に起因することを示す。

一方、GridWorld $p = 0.5$ の train 条件では MoET・Tree が 1k（AA=0.959）から 5k（AA=0.997）にかけて急上昇する。これはスプリアス依存の複製に最低限のデータ量が必要であることを示しており、10k はその閾値を十分に上回っている。GridWorld $p = 0.0$ 条件でも類似傾向が見られ（MoET: 1k=0.924、20k=0.923、Linear: 1k=0.818、20k=0.834）、両条件で構造差は持続する。



7. 議論

本枠組みの中心的な主張は、忠実性（faithfulness）は正当性（validity）を含意しないという点にある。behavioral cloning によってスプリアス依存が複製されること自体は蒸留の構造から自明だが、その複製が

AA の数値上は見えないという点が問題の核心である。実験2が示した通り、スプリアス相関が存在する場合 Surrogate model は誤った依存を複製し、訓練分布では高 AA を示しながら分布シフト下で両者ともに失敗する。AA の数値はこの破綻を予告しない。不変性の評価——$(\mathrm{AA}(D_{\text{shift}}), ; J_S(D_{\text{shift}}))$ の組の観察——を加えることで初めてこの状態を「再現性高・不変性低」として数値から識別できる。本研究の貢献は複製が起きることの指摘ではなく、それを定量的・体系的に検出する枠組みの提供にある。

IRM（Arjovsky et al., 2019[^5]）や関連する不変学習の研究は、スプリアス依存を訓練時に排除することを目的とする。本枠組みは訓練戦略を変えるものではなく、学習済み方策と学習済み Surrogate model の組に対して事後的に適用できる点が異なる。実践的な含意として、既存の蒸留ベースの XRL システムに分布シフト下での評価を追加するだけで本枠組みが利用可能となる。

実験3の結果は、今回の実験範囲では相対的に不変性が高いケースが観察できることを示す。スプリアスのない CartPole では、訓練とは異なる重力とポール長の下でも AA が 0.76〜0.82 を維持し、両者の J が実験2のような壊滅的崩壊を示さなかった。これは、Surrogate model が写し取っている依存構造が、少なくとも今回試みた物理パラメータのシフト範囲において有効であることを示唆する。AA > 0.9 の閾値は実験的目安として恣意的だが、分布シフト下の相対比較において有効性を示す指標として機能する。

実験4・5のモデル比較は、Surrogate model の構造の種類が AA の分布依存性に影響することを示す。実験6の感度分析はこれを補強する：GridWorld $p = 0.5$ の reversed_c 条件において MoET と Linear の AA の差は蒸留データを 20 倍（1k→20k）にしても解消されず、この差が蒸留データ不足ではなくモデル構造に由来することを示した。CartPole では $N = 0$ のとき MoET が最も高い AA を示すが、ノイズ次元が増えると三種の差は縮小する。GridWorld では MoET と Tree がほぼ同等であり、Linear が分布シフト下で一貫して低い AA を示す。Tree と MoET の類似した挙動は、MoET のゲーティング層よりも木の分岐構造自体が再現性の鍵である可能性を示唆する。線形モデルの限界は表現力よりも、訓練分布での行動境界がシフト後の分布に転写されにくいことに起因すると考えられる。

SHAP は「現在の方策がどの特徴に依存しているか」を示す点で有用だが、その依存が環境の変化に対して維持されるかどうかは問えない。本研究の不変性の評価は SHAP を置き換えるものではなく、SHAP だけでは見えない情報──依存の有効性──を補完的に提供する。

AA > 0.9 という閾値の恣意性に対しては、閾値を 0.85・0.90・0.95 と変化させた感度分析で対応する。Table 6 に主要条件の AA 平均値と各閾値に対する超過判定を示す。

Table 6: AA 閾値感度分析（主要条件）

実験	評価条件	AA (mean)	> 0.85	> 0.90	> 0.95
exp003 (CartPole)	train	0.915	✓	✓	—
exp003 (CartPole)	gravity_lo	0.883	✓	—	—
exp003 (CartPole)	gravity_hi	0.861	✓	—	—
exp003 (CartPole)	pole_short	0.846	✓	—	—
exp003 (CartPole)	pole_long	0.759	—	—	—
exp002 (GridWorld, $p = 0.0$)	train	0.988	✓	✓	✓
exp002 (GridWorld, $p = 0.0$)	reversed_c	0.942	✓	✓	—

閾値を 0.85・0.90・0.95 のいずれに設定しても、CartPole では train（0.915）と pole_long（0.759）の間に一貫した差が維持され、GridWorld では train と reversed_c の差が視認可能な範囲に留まる。pole_short・gravity_hi は改善された Oracle policy のもとでいずれの閾値でも train より低い値を示し、pole_long のみが 0.85 の閾値を下回る。閾値の選択が定性的な結論（pole_long が最も困難な条件である）を変えないことを確認できたため、AA > 0.9 を「高い行動一致率」の実験的目安として用いることは本データの範囲で妥当である。

スプリアス依存の検出は、その後の対処法と組み合わせてはじめて実用的な意義を持つ。本枠組みは検出に特化しており、対処そのものを提供するものではないが、検出結果は以下のような後続アクションを示唆する：観測空間からスプリアス特徴を除去する、環境の報酬関数や状態空間を再設計してスプリアス相関を取り除く、あるいは IRM のような不変学習手法で Oracle policy を再訓練する。どのアクションが最適かは環境・タスクの性質に依存し、本研究の範囲では実証的に評価していないが、検出結果が後続のデバッグ・改善サイクルの出発点となることを意図している。

従来の XAI 研究における主要な制約の一つは、説明可能なモデル（決定木・線形モデル）は性能が低く、高性能モデル（深層ネットワーク）は解釈しにくいというトレードオフである。本枠組みはこのトレードオフを回避できる：Oracle policy には一切手を加えないため性能は保たれ、Surrogate model はその横に事後的に配置するだけでよい。また Surrogate model の内部構造を問わない──MoET・決定木・線形モデルのいずれも、再現性と不変性という同一の評価軸で比較できる──ため、説明可能性の手法間の横断的な比較基盤としても機能する。

本研究の本質的な貢献は、特定の説明可能性手法の提案ではなく、RL 方策に対する**説明品質の評価方法論**の提供にある。どの Surrogate model を選ぶかは研究者・実務者の目的に委ねられ、本枠組みはその選択を定量的に評価する共通の土台を提供する。分布シフトを診断ツールとして使うという操作自体は OOD ロバスト性研究でも用いられるが、本研究の目的はロバスト性の向上ではない。「説明と呼べる候補が存在するか（再現性）」「その説明が捉えた依存は検証した範囲で有効か（不変性）」という二つの問いに数値で答えることで、XRL における説明手法の比較・選択・改善のサイクルを支える評価基盤を構築することが本研究の目指すところである。

8. 限界

本研究の枠組みには四つの具体的な限界がある。

1. 主実験は CartPole と GridWorld という小規模な離散制御環境に限定されている。Section 4.4 の予備実験（LunarLander-v3・MuJoCo Hopper-v5）は連続力学系や連続行動空間への適用可能性を探索的に示すが、行動ビニングの近似誤差および DQN のシード間分散（J_{oracle} std $= 57$）という限界があり、高次元観測空間への汎化は未確認のままである。また、pole_long 条件での Surrogate model の J 逆転（$J_{\text{surrogate}} > J_{\text{oracle}}$）は蒸留の正則化効果として興味深いが、そのメカニズムの解明は今後の課題である。

2. 各条件の統計的信頼性は乱数シード10本に基づいており、特に pole_short 条件（AA 標準偏差 0.122）ではシフト後の挙動にばらつきが残る。実験6の10シードでも類似した分散が見られ、追加の統計検定が必要である。

3. 本枠組みは Oracle policy が評価分布上でも動作することを前提とする。本実験では pole_long 条件でも Oracle policy は $J_{\text{oracle}} = 376.5$ と動作しており、Surrogate model が $J_{\text{surrogate}} = 426.5$ と逆転する現象が観察された。この逆転は蒸留の正則化効果（より単純な構造への圧縮がシフト後の汎化を助ける）を示唆するが、メカニズムの解明は今後の課題である。仮に Oracle policy が OOD で機能不全

に陥る条件では、AA の低下が Surrogate model の不変性の欠如によるものか Oracle policy の失敗に伴う必然的な乖離かを区別できないため、注意が必要である。

4. 分布シフトの選択（重力・ポール長・c の反転）は恣意的であり、どのようなシフトを選ぶかが不変性の評価結果に影響しうる。実問題への適用において「何をシフトすべきか」は自明でなく、本枠組みの適用に際しての実践的な問いとなる。シフト候補の特定に向けては、既存の手法が参照点を提供する。SHAP（Lundberg & Lee, 2017[^4]）のような特徴重要度手法は方策がどの特徴に依存しているかの候補を示し、依存度の高い特徴をシフト操作の対象として優先することができる。IRM（Arjovsky et al., 2019[^5]）は複数の訓練環境が利用可能な場合に不変特徴と環境依存特徴を区別する枠組みを提供し、スプリアス候補の事前絞り込みに応用できる。ただしこれらはシフト候補の探索を補助するものであり、網羅的な選択基準の形式化は今後の課題として残る。

9. 結論

強化学習方策の説明可能性を構造制約下の再現性として捉え直し、再現性が高いだけでは不足で不変性の評価を併用する必要があることを示した。再現性と不変性はともに、構造制約の強さ・入力分布・方策の依存構造に依存して変化する。モデル比較実験では、木構造を持つ Surrogate model（Tree・MoET）が線形モデルより分布シフト下での再現性を安定して維持することが示された。蒸留データ量感度分析は、この差が構造由来であることを確認した。本枠組みは外部ラベルを必要とせず、既存の蒸留ベースの説明手法に分布シフト下での評価を追加することで実施できる。

今後の課題として、Section 4.4 で示した連続制御環境での予備実験を回帰型 Surrogate model（MSE / KL ベースの忠実度指標）を用いた本格実験へと発展させること、高次元観測空間への適用、統計的信頼性を高めるためのシード数の増加、分布シフトの選択基準の形式化が挙げられる。また、Surrogate model の構造から規則列や自然言語説明を生成し、それが不変性にどう対応するかを検討することが、説明可能性の実用化に向けた次のステップとなる。

[^1]: Chen, R., et al. (2022). Machine explanations and human understanding. *Transactions on Machine Learning Research*.

[^2]: Mindlin, D., et al. (2025). Towards co-constructed explanations. *International Conference on Human-Agent Interaction*.

[^3]: Vasic, M., et al. (2019). MoET: Interpretable and verifiable reinforcement learning via mixture of expert trees. *AAAI*.

[^4]: Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *NeurIPS*.

[^5]: Arjovsky, M., et al. (2019). Invariant risk minimization. *arXiv:1907.02893*.

[^6]: Bastani, O., Pu, Y., & Solar-Lezama, A. (2018). Verifiable reinforcement learning via policy extraction. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^7]: Kolter, J. Z., & Ng, A. Y. (2009). Regularization and feature selection in least-squares temporal difference learning. *International Conference on Machine Learning (ICML)*.

[^8]: Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*.

[^9]: Alvarez-Melis, D., & Jaakkola, T. S. (2018). Towards robust interpretability with self-explaining neural networks. *Advances in Neural Information Processing Systems (NeurIPS)*.

[^10]: Samek, W., Wiegand, T., & Müller, K.-R. (2017). Explainable artificial intelligence: Understanding, visualizing and interpreting deep learning models. *arXiv:1708.08296*.

[^11]: Koh, P. W., et al. (2020). Concept bottleneck models. *International Conference on Machine Learning (ICML)*.

[^12]: Greydanus, S., Koul, A., Dodge, J., & Fern, A. (2018). Visualizing and understanding Atari agents. *International Conference on Machine Learning (ICML)*.

[^13]: Yuksekgonul, M., Wang, M., Slack, D., Singh, S., Guestrin, C., & Lakkaraju, H. (2023). Post-hoc concept bottleneck models. *International Conference on Learning Representations (ICLR)*.

[^14]: Mnih, V., et al. (2015). Human-level control through deep reinforcement learning. *Nature*, 518, 529–533.